```
Name: count, dtype: int64
```

[41]:

```python
### Construimos la distribucion de probabilidad (para todos)

for col in data.columns:

    x_obs = [0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0]
    x = [1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11,12,13,14,15,16,17] # en la distribucion geómetrica x empieza en 1 y no tiene límite
    count = 0
    ## ponemos un contador a resetear cada vez que tengamos un caso de exito

    if data[col][1]==0:
        a=1
        for i in range(2,len(data[col])): # empezamos a contar desde el cuarto caso, el anterior sabemos que es varon
            count += 1 ## Aumenta 1 para ver hasta que punto se alcanza otro varón

            if (data[col][i]==0): ## en el caso que encuentre un varón
                x_obs[count-1] += 1 ## en este caso aumenta la frecuencia para la correspondente intento x
                #(índice -1 por index python)
                count=0

        print(col,'->',x_obs,a)  # contiene la frecuencia observada
        plt.scatter(x,x_obs,color='red') # graficamos la distribucion
        plt.show()

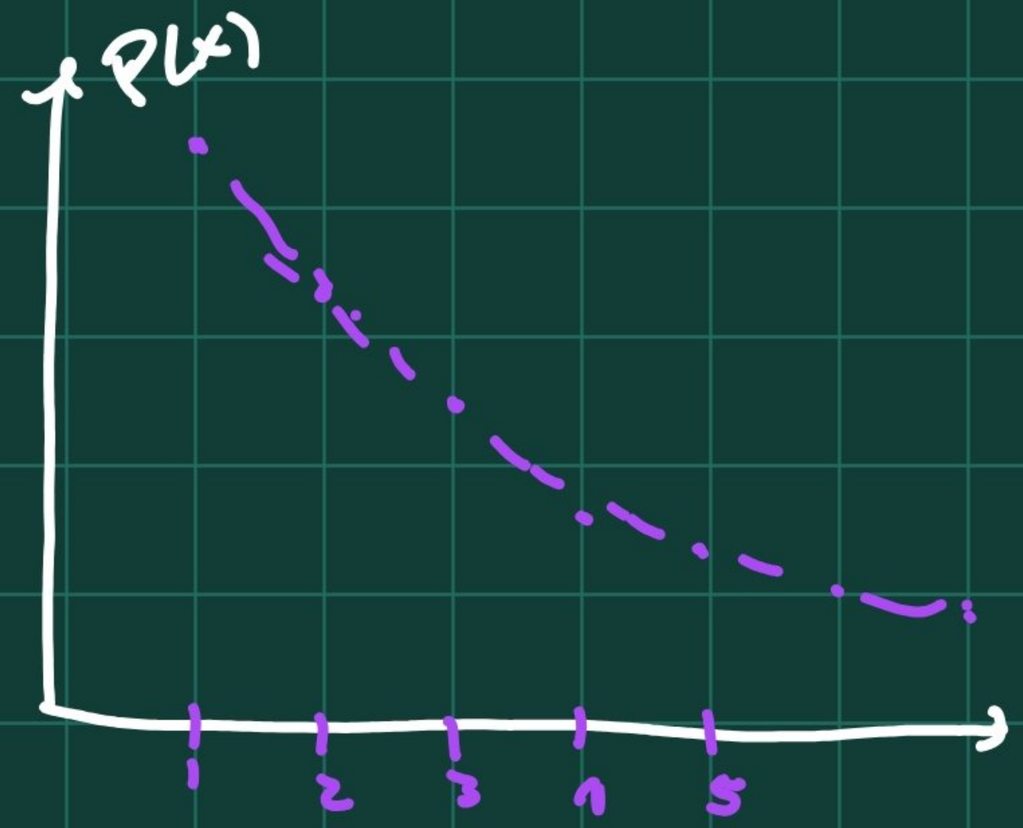
    if data[col][1]==1:
        a=2
        for i in range(2,len(data[col])): # empezamos a contar desde el cuarto caso, el anterior sabemos que es varon
            count += 1 ## Aumenta 1 para ver hasta que punto se alcanza otro varón

            if (data[col][i]==1): ## en el caso que encuentre un varón
                x_obs[count-1] += 1 ## en este caso aumenta la frecuencia para la correspondente intento x
                #(índice -1 por index python)

                count = 0 #reseteamos el contador

        print(col,'->',x_obs,a)  # contiene la frecuencia observada
        plt.scatter(x,x_obs,color='red') # graficamos la distribucion
        plt.show()
```

```
Evaristo -> [23. 22. 1. 1. 2. 1. 1. 0. 0. 0. 0. 0. 0. 0. 0. 0. 0] 1
```

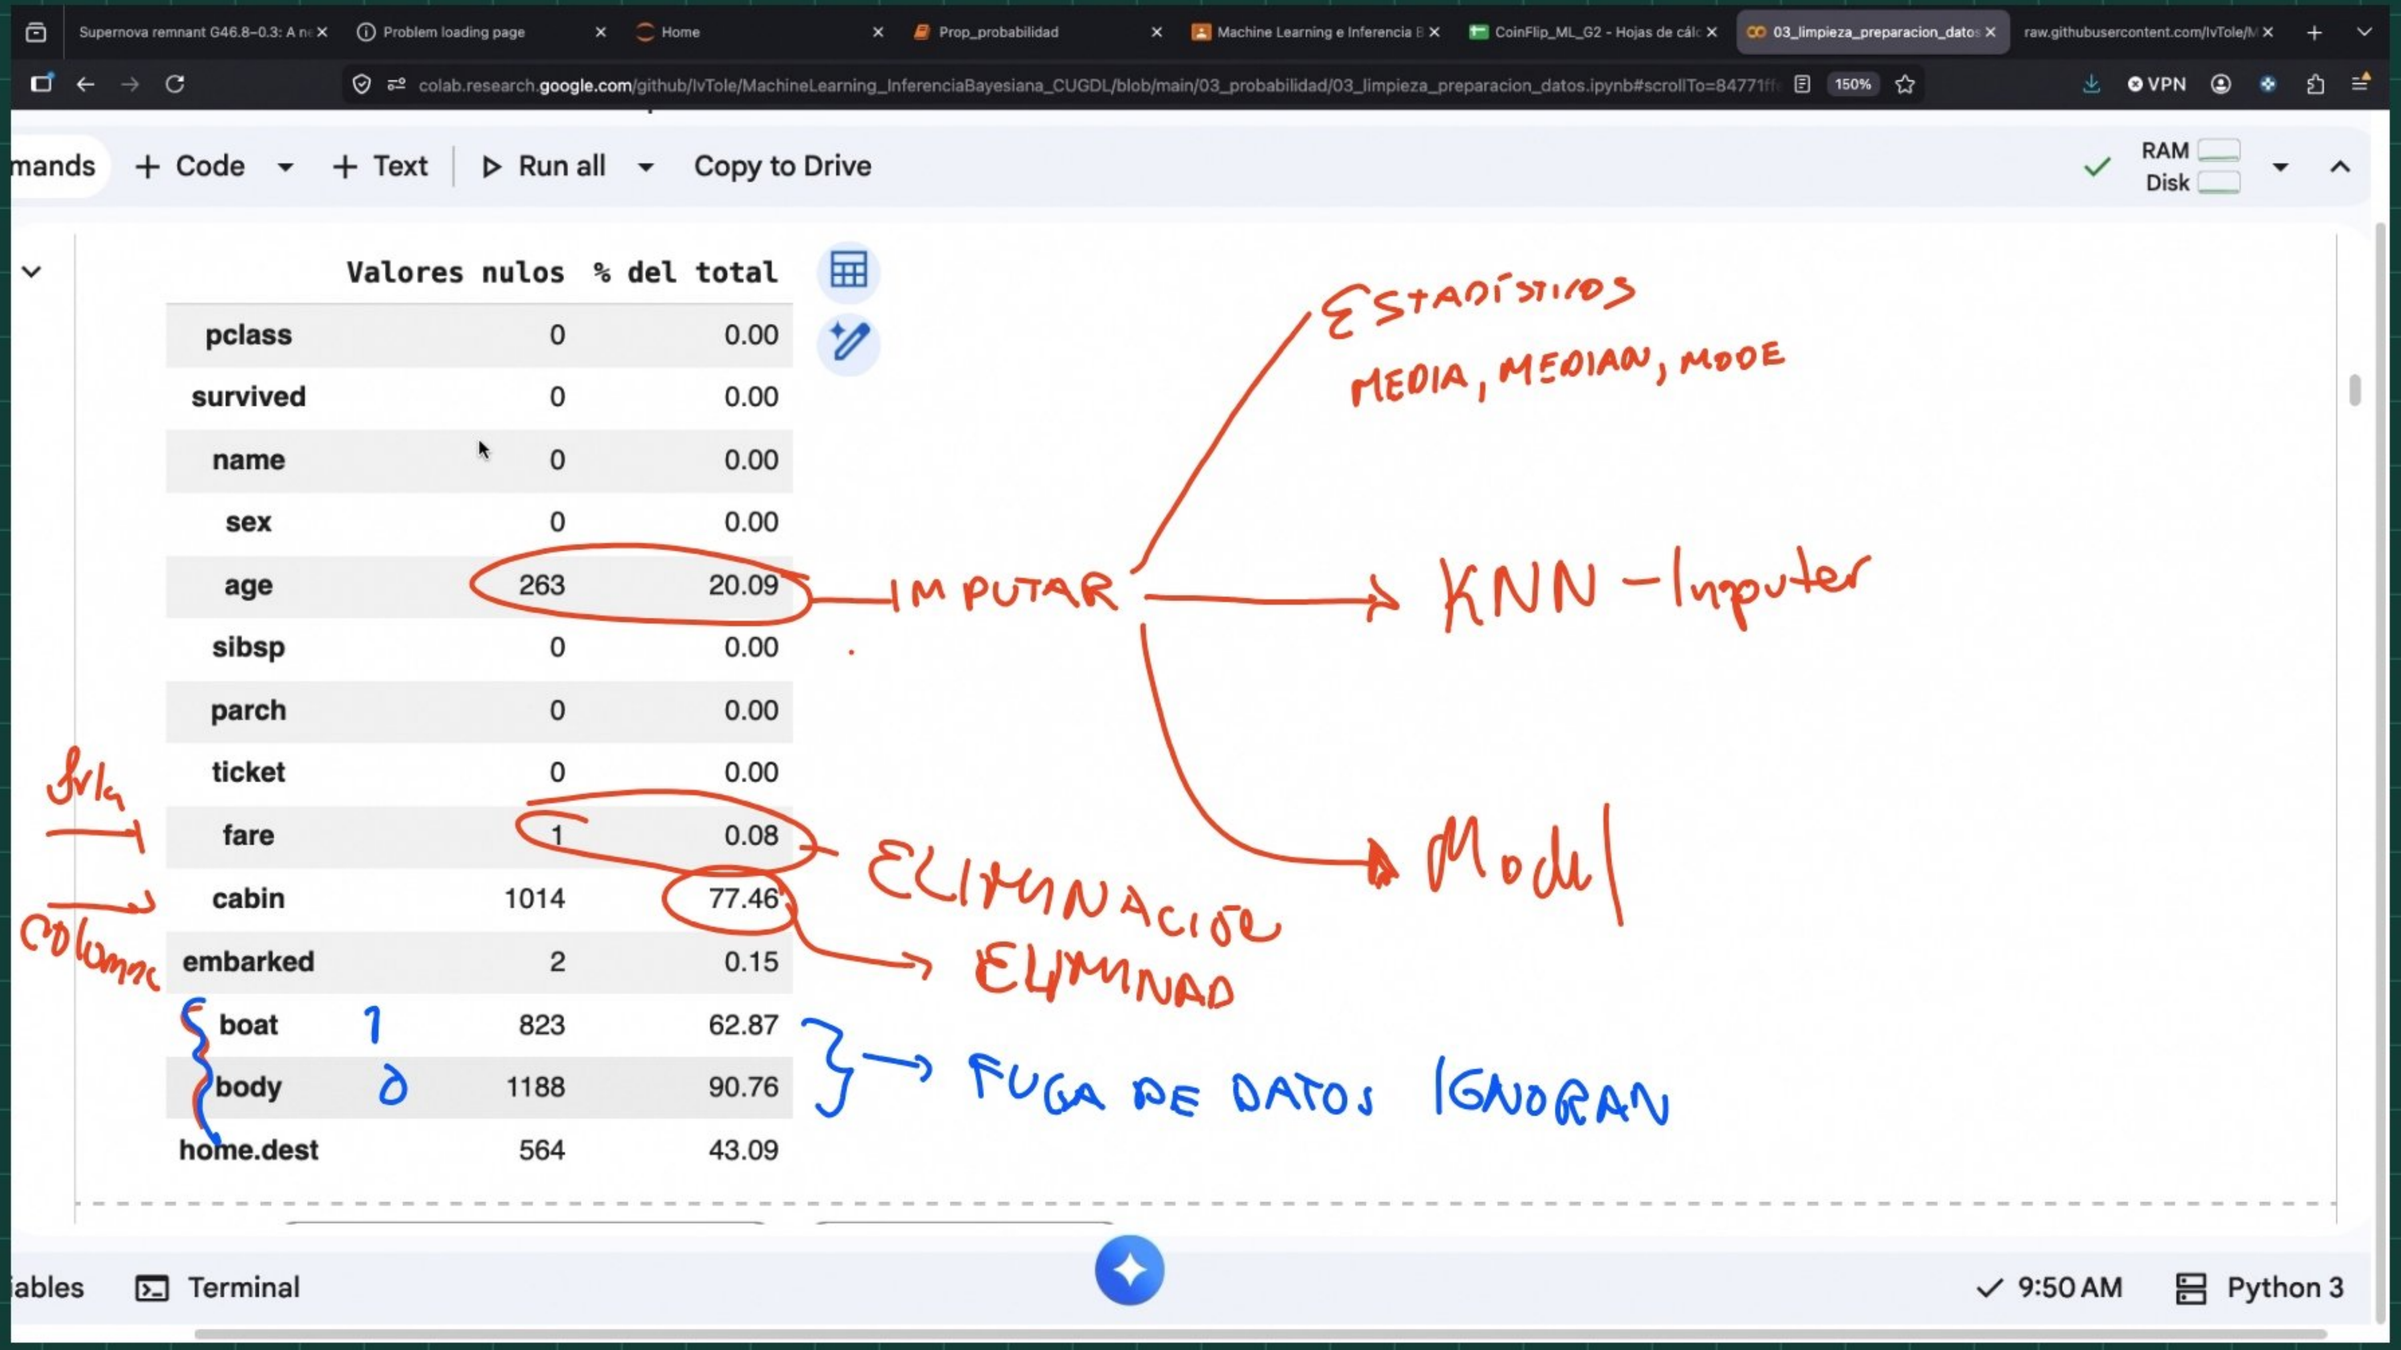


$$P(x=k) = q^{k-1} p$$

x - N de fallos hasta 1 éxito

1 1 1 0

1 1 1 1 0


Supernova remnant G46.8–0.3: A n
Problem loading page
Home
Prop_probabilidad
Machine Learning e Inferencia B
CoinFlip_ML_G2 - Hojas de cál
03_limpieza_preparacion_datos
raw.githubusercontent.com/IvTole/M
colab.research.google.com/github/IvTole/MachineLearning_InferenciaBayesiana_CUGDL/blob/main/03_probabilidad/03_limpieza_preparacion_datos.ipynb#scrollTo=84771ff
150%
VPN
mands
+ Code
+ Text
Run all
Copy to Drive
RAM
Disk
Valores nulos
% del total
pclass 0 0.00
survived 0 0.00
name 0 0.00
sex 0 0.00
age 263 20.09
sibsp 0 0.00
parch 0 0.00
ticket 0 0.00
fare 1 0.08
cabin 1014 77.46
embarked 2 0.15
boat 823 62.87
body 1188 90.76
home.dest 564 43.09
ESTADÍSTICOS
MEDIA, MEDIAN, MODE
IMPUTAR
KNN-Imputer
Moda
ELIMINACIÓN
ELIMINAD
FUGA DE DATOS IGNORAN
Terminal
9:50 AM
Python 3

Supernova remnant G46.8−0.3: A ne | Problem loading page | Home | Prop_probabilidad | Machine Learning e Inferencia B | CoinFlip_ML_G2 - Hojas de cálc | 03_limpieza_preparacion_datos | raw.githubusercontent.com/IvTole/M
colab.research.google.com/github/IvTole/MachineLearning_InferenciaBayesiana_CUGDL/blob/main/03_probabilidad/03_limpieza_preparacion_datos.ipynb#scrollTo=e19ac51 150% VPN

```
# Valores únicos de home.dest
df_titanic_clean['home.dest'].unique()
```

```
'Cornwall / Spokane, WA', 'England / San Francisco, CA',
'Hartford, Huntingdonshire', 'Helsinki, Finland Ashtabula, Ohio',
'London / Fort Byron, NY',
'Bishopstoke, Hants / Fayette Valley, ID', 'Pennsylvania',
'Provo, UT', 'Upper Burma, India Pittsburgh, PA',
'St Ives, Cornwall / Hancock, MI', 'Lyndhurst, England',
'London / Staten Island, NY', 'Portugal / Sau Paulo, Brazil',
'Lucca, Italy / California', 'Guernsey / Elizabeth, NJ',
'New Forest, England', 'Southampton', 'Holley, NY',
'Greenport, NY', 'Barcelona, Spain / Havana, Cuba',
'England / Detroit, MI', 'Goteborg, Sweden / Rockford, IL',
'Oslo, Norway Bayonne, NJ', 'England / Philadelphia, PA',
'Cornwall / Houghton, MI', 'Janjgir, India / Pennsylvania',
'Liverpool / Montreal, PQ', 'Cornwall / Clear Creek, CO',
'Cornwall', 'Cornwall / Camden, NJ', 'West Kensington, London',
'Clevedon, England', 'Auburn, NY', 'Detroit, MI',
'Seattle, WA / Toledo, OH', 'Denmark Hill, Surrey / Chicago',
'Walthamstow, England', 'Ilford, Essex / Winnipeg, MB',
'Somerset / Bernardsville, NJ', 'India / Rapid City, SD',
```

Supernova remnant G46.8–0.3: A n | Problem loading page | Home | Prop_probabilidad | Machine Learning e Inferencia B | CoinFlip_ML_G2 - Hojas de cálc | 03_limpieza_preparacion_datos | raw.githubusercontent.com/IvTole/M
colab.research.google.com/github/IvTole/MachineLearning_InferenciaBayesiana_CUGDL/blob/main/03_probabilidad/03_limpieza_preparacion_datos.ipynb#scrollTo=19bc7ff 150% VPN

le conoce como **data wrangling**, e implica reorganizar, codificar o crear nuevas variables a partir de las existentes. El objetivo e dataset esté en un formato adecuado tanto para su análisis exploratorio como para su uso con algoritmos de machine learning

En esta sección realizaremos tareas como:

- Codificar variables categóricas en formato numérico.
- Crear nuevas variables que combinen o transformen las originales.
- Estandarizar formatos para facilitar comparaciones y visualizaciones.

Estas transformaciones nos ayudarán a representar mejor la información y preparar el terreno para construir modelos más efec

Codificación de variables categóricas

Los algoritmos de machine learning trabajan mejor (o simplemente solo trabajan) con datos numéricos. Por eso, uno de los pas esenciales en la preparación de datos es transformar las variables categóricas en representaciones numéricas. En este caso, v codificar dos columnas clave:

- `sex`: actualmente es una variable de texto (`male`/`female`). La convertiremos en 0 y 1 para representar ambos género
- `embarked`: representa el puerto desde el que embarcó el pasajero (`C`, `Q` o `S`). Usaremos **codificación one-hot**, que columna binaria para cada categoría sin imponer un orden arbitrario.

Además de estas técnicas, existen otras formas de codificación que pueden usarse según el tipo de variable o el modelo a emp

- **Label encoding**: asigna un número entero a cada categoría (por ejemplo, `0`, `1`, `2`), pero puede inducir relaciones ordi

Dest	
USA	1
ENG	2
BRA	3
PERU	4

X_1^{dest}

USA
BRA
PERU
ENG
USA
USA
⋮

One-Hot (Dummies)

Dest_USA	Dest_ENG	Dest_BRA	Dest_PERU
1	0	0	0
0	0	1	0
0	0	0	1
0	1	0	0
1	0	0	0
1	0	0	0

Opcional

Ordinal

Dest
1
3
4
2
1
1
⋮

One-Hot → $\{0,1\}$

Encodes

Ordinal → $\{1,2,3,\ldots\}$

Bajo, Medio, Alto

Supernova remnant G46.8- | Problem loading page | Home | Prop_probabilidad | Machine Learning e Inf | CoinFlip_ML_G2 - Hoja | 03_limpieza_preparaci | raw.githubusercontent.com | Regular expressions - J | data transform log exp

colab.research.google.com/github/IvTole/MachineLearning_InferenciaBayesiana_CUGDL/blob/main/03_probabilidad/03_limpieza_preparacion_datos.ipynb#scrollTo=22367af 150% VPN

03_limpieza_preparacion_datos.ipynb Save in GitHub to keep changes

Share

File Edit View Insert Runtime Tools Help

Commands + Code + Text Run all Copy to Drive RAM Disk

[36]

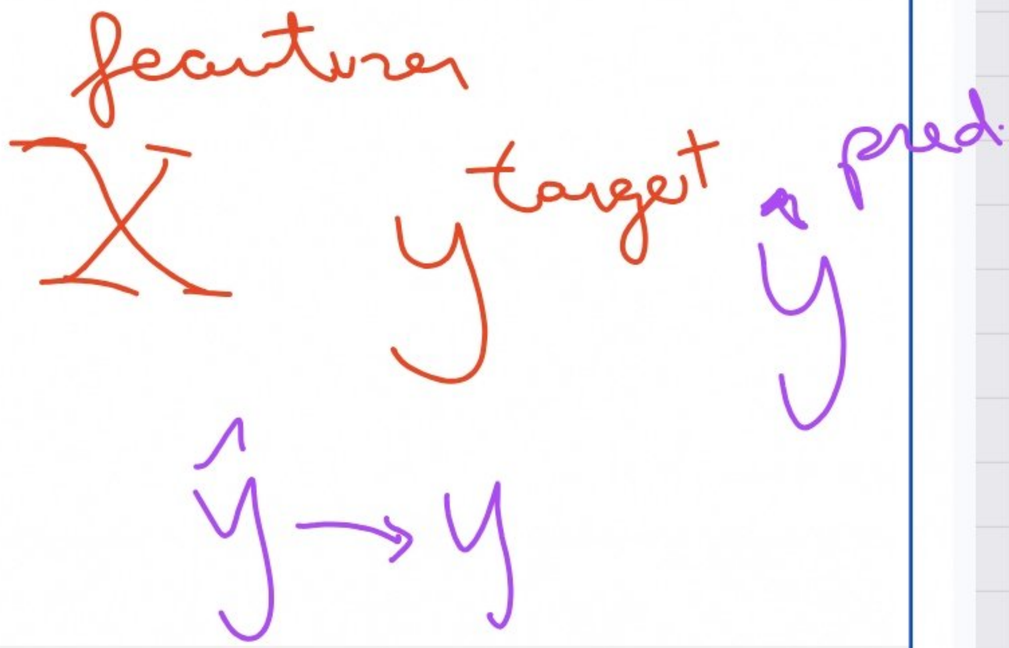
```
# Selección de variables predictoras
# Puedes ajustar esta lista si agregas o quitas columnas relevantes
features = [
    'pclass', 'sex', 'age', 'fare_log',
    'familysize', 'isalone',
    'embarked_Q', 'embarked_S',
    'title_Miss', 'title_Mrs', 'title_Mr', 'title_Rare'
]

X = df_titanic_clean[features] # matrix de características
y = df_titanic_clean['survived'] # vector de variable objetivo

# División en conjunto de entrenamiento y prueba (80/20)
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

# Verificamos las dimensiones
print("Dimensiones del conjunto de entrenamiento:", X_train.shape)
print("Dimensiones del conjunto de prueba:", X_test.shape)
```

```
Dimensiones del conjunto de entrenamiento: (1046, 12)
Dimensiones del conjunto de prueba: (262, 12)
```



Variables Terminal 10:45 AM Python 3