Machine Learning
(Aprendizaje Automático)

- **Supervisado** (TARGET y)
  - **Regresión**
    - $y \in \mathbb{R}$
    - > Regresión Lineal
    - Métricas: R^2, MSE, RMSE, MAE, ...
  - **Clasificación**
    - $y \in \{0,1\}$ $\{1,2,\dots\}$
    - > Regresión Logística
    - Métricas: Auc_score
    - Matriz de confusión
      - Exactitud, Precisión, F1, Sensitividad.
- **No Supervisado** (NO TARGET)
  - **Clustering**

Vista Previa Archivo Edición Visualización Ir Herramientas Ventana Ayuda
Lun 7 de sep 9:26 a.m.
04_regresion_lineal_slides.pdf
Página 2 de 35
Visualización Inspector Zoom Compartir Resaltado Girar Marcado Rellenar formulario Buscar Buscar

Regresión lineal

Ejemplo

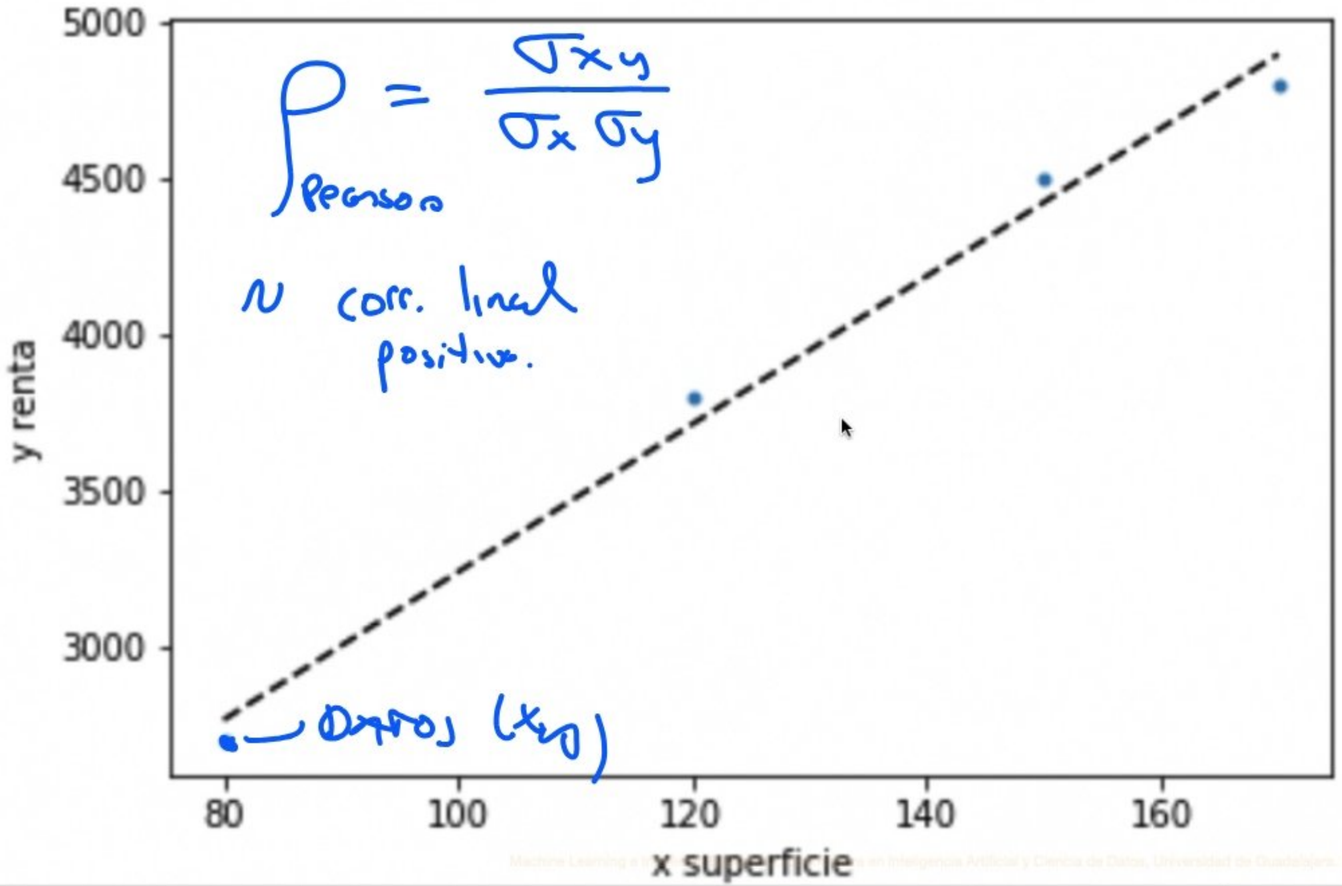
- Queremos modelar el precio de los departamentos en una ciudad según su superficie (en m^2).
- La **variable de entrada** (independiente) nos ayuda a predecir el valor de la variable de salida (superficie del piso).
- La **variable de salida** (dependiente) es la que queremos predecir (el costo mensual)

Superficie [metros cuadrados]	Renta [pesos]
150	4500
120	3800
170	4800
80	2700

Vista Previa Archivo Edición Visualización Ir Herramientas Ventana Ayuda
Lun 7 de sep 9:26 a.m.
04_regresion_lineal_slides.pdf
Página 5 de 35
Visualización Inspector Zoom Compartir Resaltado Girar Marcado Rellenar formulario Buscar

Regresión lineal

Ecuación de una recta



$$\hat{y} = 869.6 + 23.7x$$

$$\text{renta} = 869.6 + 23.7 * \text{superficie}$$

Interpretación de los parámetros:

- β_0 (intercept): también llamado ordenada al origen, representa el punto donde la recta de regresión cruza el eje y.
- β_1: Es el cambio esperado en y por cada unidad de aumento en x, manteniendo todo lo demás constante.

Vista Previa Archivo Edición Visualización Ir Herramientas Ventana Ayuda
Lun 7 de sep 9:28 a.m.
04_regresion_lineal_slides.pdf
Página 3 de 35
Visualización Inspector Zoom Compartir Resaltado Girar Marcado Rellenar formulario Buscar

de x (la superficie) y entonces el modelo lineal se escribe como:

- $\hat{y} = \beta_0 + \beta_1 x$, i.e., Renta = β_0 + β_1 * superficie.
- El objetivo de una regresión lineal es encontrar de forma estadística unos valores que sean significativos para β_0 y β_1, de tal forma que minimizan las diferencias entre los valores reales de y (los que realmente tenemos) y los que prediga nuestro modelo ($\hat{y}$).
- Con estos parámetros tendremos una ecuación que será capaz de predecir los valores de y en función de la variables (o variables) de entrada x.

Regresión lineal

Ecuación de una recta

• Regresión lineal (Simple)

DATOS

$X^{feat.}$, $y^{target} \in \mathbb{R}$

Modelo

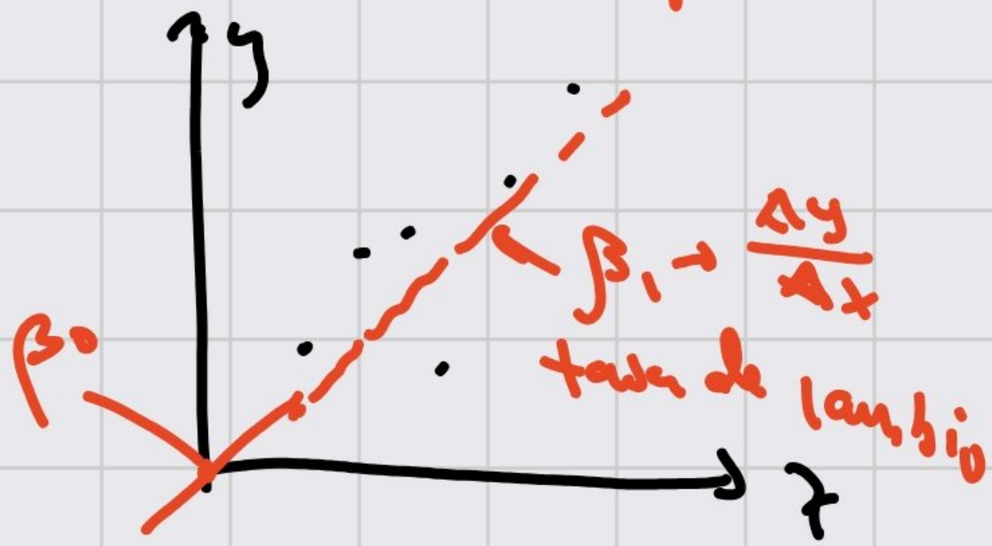
$$\hat{y} = \beta_0 + \beta_1 x$$

$\hat{y}$: predicción

β_0: intercept

β_1: PARÁMETROS

x: feat.



$$\underset{[M\times N]}{\text{Renta}} = \underset{[M\times N]}{\beta_1} \cdot \underset{[m^2]}{\text{Superf}}$$

$+\beta_1$: $\left[\frac{M\times N}{m^2}\right]$

$+1$: $[M\times N]$

Modelo

$\hat{y} = \beta_0 + \beta_1 x$ (feat. DATOS)



Costo

$\hat{y}_i - y_i \sim e_i$ (residuo)

$e_i \sim N(0, \sigma_e)$

$\mathcal{L}$ Pérdida

Función de Pérdida

Loss Function

$\frac{1}{n}\sum_{i=1}^{n}(\hat{y}_i - y_i)$ Mean Bias Error (MBE)

$\frac{1}{n}\sum|\hat{y}_i - y_i|$ Mean Absolute Error (MAE)

$\frac{1}{n}\sum(\hat{y}_i - y_i)^2$ Mean Squared Error (MSE)

$\sqrt{\frac{1}{n}\sum(\hat{y}_i - y_i)^2}$ RMSE

$$\mathcal{L}(\beta) = \mathcal{L}(\beta_0, \beta_1) = \frac{1}{n} \sum (\hat{y}_i - y_i)^2$$

$$= \frac{1}{n} \sum (\beta_0 + \beta_1 x_i - y_i)^2$$

error
pérdida
Loss

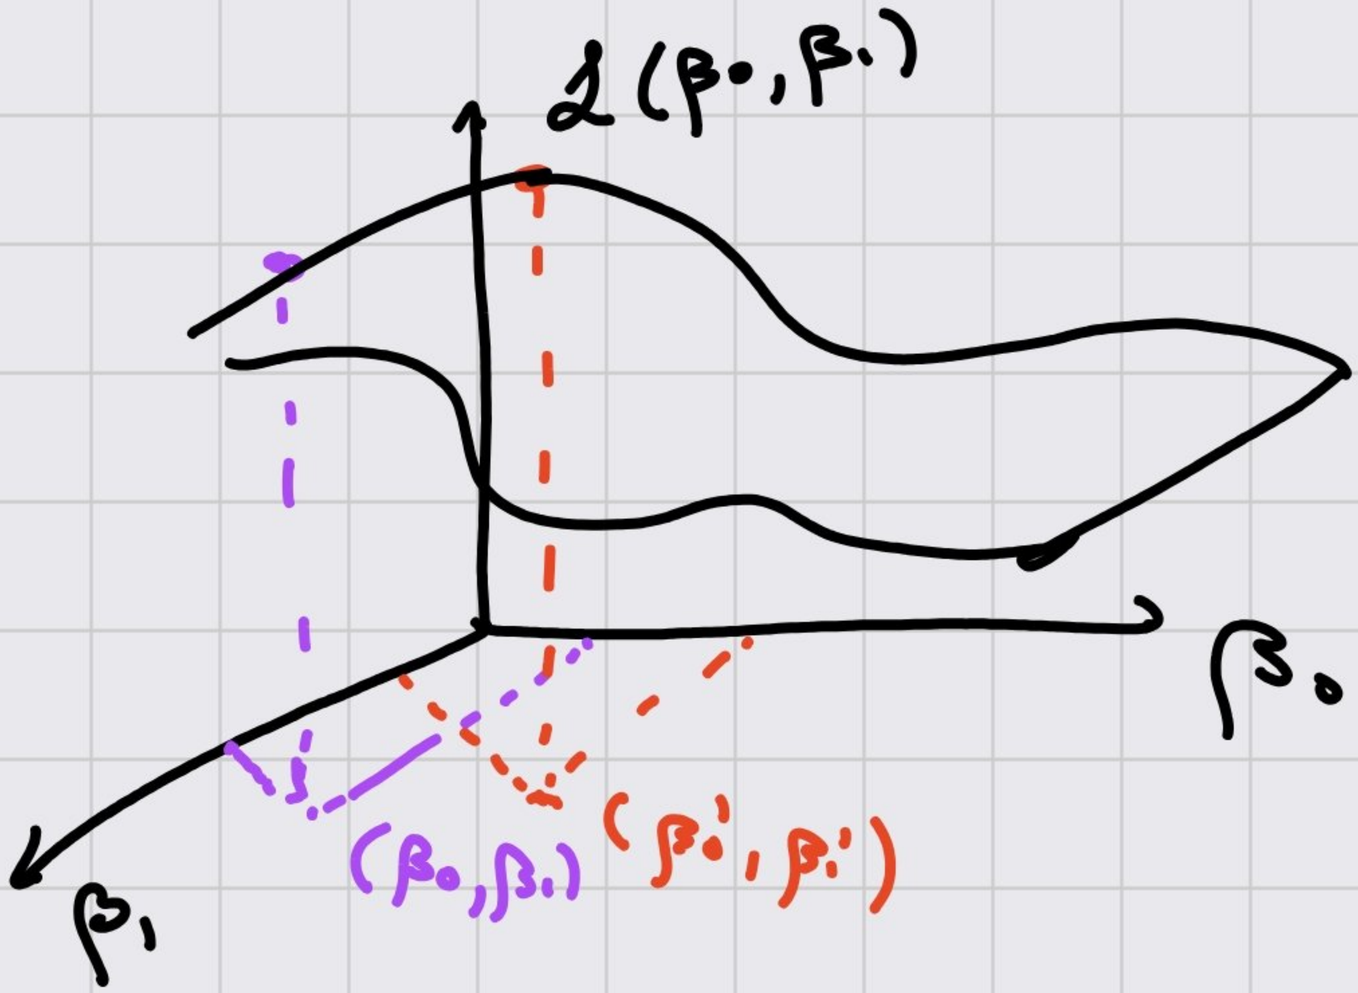
β_0, β_1: PARÁMETROS
"Aprendizaje"

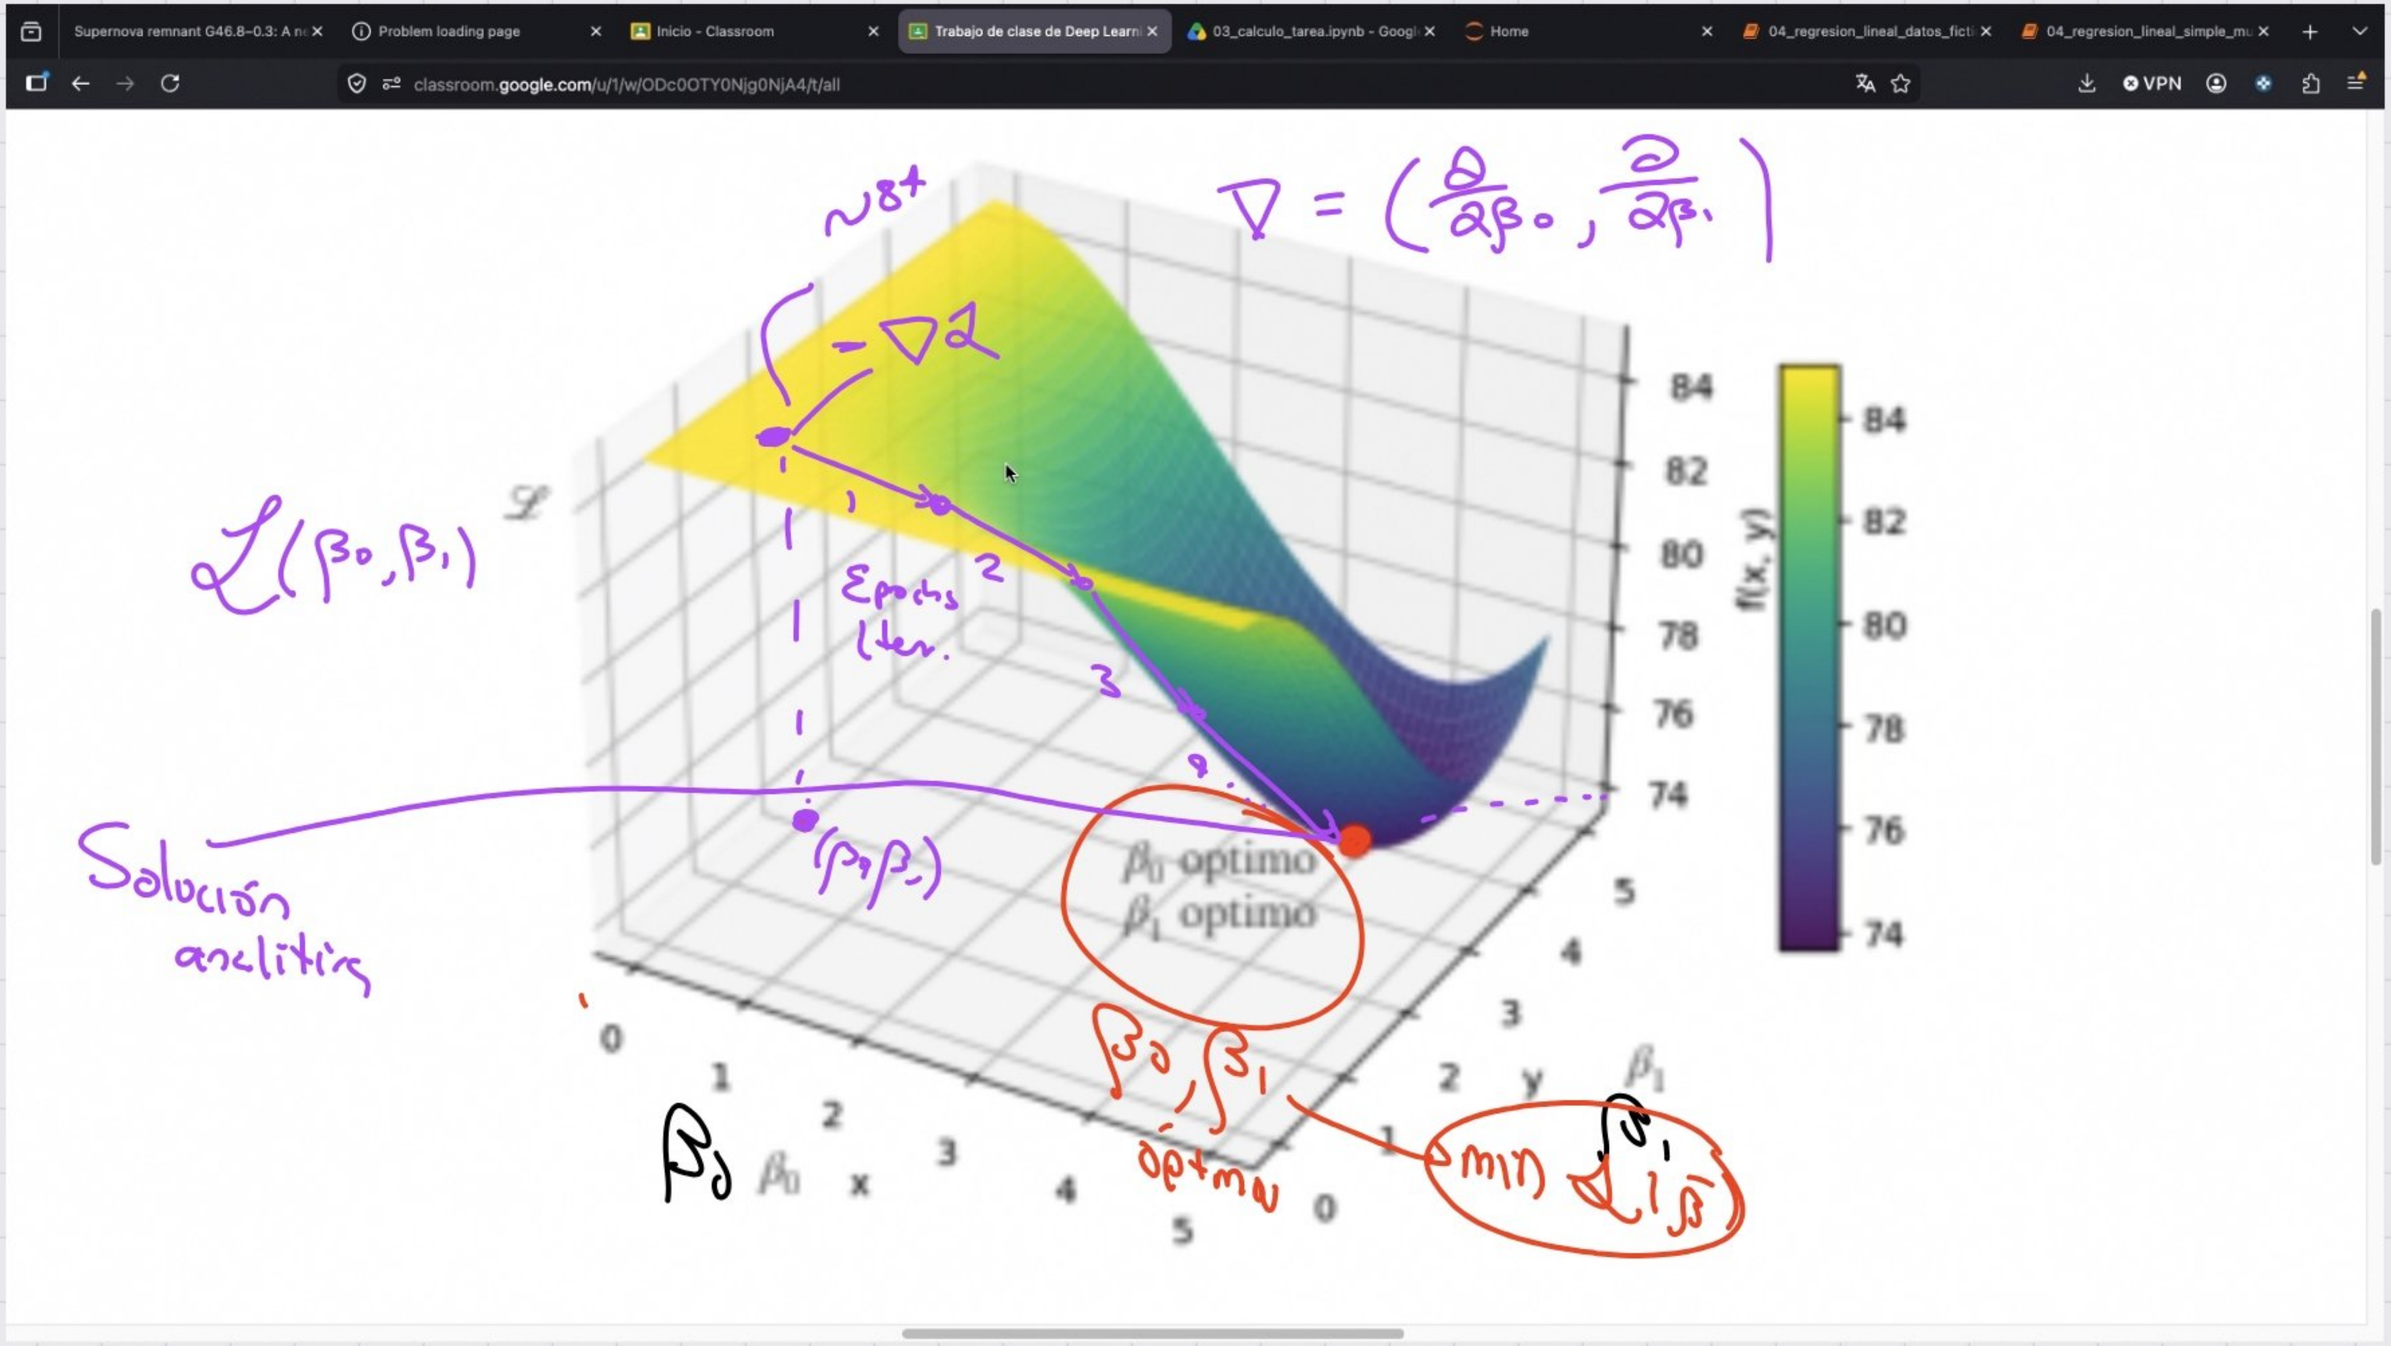
x_i: feat.
y_i: target
DATOS

$$\mathcal{L}$$

Input $\vec{\beta} = (\beta_0, \beta_1) \in \mathbb{R}^2$ ⟶ Output $\in \mathbb{R}$

Error


$\mathcal{L}(\beta_0, \beta_1)$
β_0
β_1
(β_0, β_1)
(β_0', β_1')


$\nabla = \left(\frac{\partial}{\partial \beta_0}, \frac{\partial}{\partial \beta_1}\right)$
$-\nabla \mathcal{L}$
$\mathcal{L}(\beta_0, \beta_1)$
Epochs (iter.
(β_0, β_1)
Solución analítica
β_0 optimo
β_1 optimo
β_0, β_1 optimo
$\min \mathcal{L}(\beta_0, \beta_1)$
β_0
β_1
x
y
f(x, y)

$$\mathcal{L}(\beta_0,\beta_1) = \frac{1}{n}\sum (\beta_0 + \beta_1 x_i - y_i)^2 = \frac{1}{n}\sum u_i^2 \qquad u = \beta_0 + \beta_1 x_i - y_i$$

Objetivo: $\min \mathcal{L}(\beta_0,\beta_1)$

(Optimizar)

→ optimos β_0', β_1'

$$\frac{\partial}{\partial \beta_0}\mathcal{L} = 0$$

$$\frac{\partial}{\partial \beta_1}\mathcal{L} = 0$$

Regla de la cadena $\quad \frac{df}{dx} = \frac{df}{du}\frac{du}{dx}$

$$\frac{\partial}{\partial \beta_0}\mathcal{L} = (1)\cdot 2\frac{1}{n}\sum (\beta_0 + \beta_1 x_i - y_i) = 0$$

$$\frac{\partial}{\partial \beta_1}\mathcal{L} = 2\frac{1}{n}\sum (\beta_0 + \beta_1 x_i - y_i)\, x_i = 0$$

$$\rightarrow \nabla \mathcal{L} = \left(\frac{\partial \mathcal{L}}{\partial \beta_0}, \frac{\partial \mathcal{L}}{\partial \beta_1}\right)$$

$$\frac{\partial}{\partial \beta_0} L = (1) \cdot \frac{1}{n} \sum (\beta_0 + \beta_1 x_i - y_i) = 0 \quad \ldots (1)$$

$$\frac{\partial}{\partial \beta_1} L = \frac{1}{n} \sum (\beta_0 + \beta_1 x_i - y_i) x_i = 0 \quad \ldots (2)$$

$$= \frac{1}{n} \sum (x_i \beta_0 + \beta_1 x_i^2 - y_i x_i)$$

$$\frac{1}{n} \sum y_i = \frac{1}{n} \sum \beta_0 + \frac{1}{n} \sum \beta_1 x_i \quad \ldots (1)$$

$$\frac{1}{n} \sum x_i y_i = \frac{1}{n} \sum x_i \beta_0 + \frac{1}{n} \sum \beta_1 x_i^2 \quad \ldots (2)$$

$$\left.\begin{aligned} A_1 &= B_1 \beta_0 + C_1 \beta_1 \\ A_2 &= B_2 \beta_0 + C_2 \beta_2 \end{aligned}\right\}$$ Sistema de eqs. lineales

$$\beta_1 = \frac{\sigma_{xy}}{\sigma_x^2}$$

$$\beta_0 = \bar{y} + \beta_1 \cdot \bar{x}$$

Solución

óptimo

Vista Previa Archivo Edición Visualización Ir Herramientas Ventana Ayuda
Lun 7 de sep 10:16 a.m.
04_regresion_lineal_slides.pdf
Página 22 de 35
Visualización Inspector Zoom Compartir Resaltado Girar Marcado Rellenar formulario Buscar Buscar

- Los parámetros que minimizan la suma de los residuos al cuadrado son:

$$\beta_1 = \frac{\sigma_{xy}}{\sigma_x^2}$$

covarianza

varianza

$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$

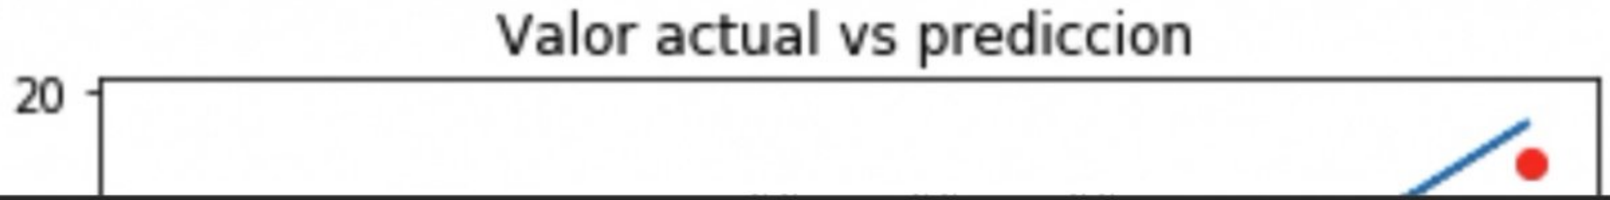
media y

media x

$$A = \frac{(\Sigma y)(\Sigma x^2) - (\Sigma x)(\Sigma xy)}{n(\Sigma x^2) - (\Sigma x)^2}$$

$$B = \frac{n(\Sigma xy) - (\Sigma x)(\Sigma y)}{n(\Sigma x^2) - (\Sigma x)^2}$$

Machine Learning e Inferencia Bayesiana, Licenciatura en Inteligencia Artificial y Ciencia de Datos, Universidad de Guadalajara, M. en C. Iván Tolentino Juárez



Modelo

$\hat{y} = \beta_0 + \beta_1$

→

Loss

$\mathcal{L}(\beta_0, \beta_1)$

MSE

$\hat{y} - y$

→

Optimización

$\nabla \mathcal{L} = 0$

→

parámetros óptimos

	TV	Radio	Newspaper	Sales
0	230.1	37.8	69.2	22.1
1	44.5	39.3	45.1	10.4
2	17.2	45.9	69.3	9.3
3	151.5	41.3	58.5	18.5
4	180.8	10.8	58.4	12.9

x_1 x_2 x_3 y

$y = \beta_0 + \beta_1 x_1$

pred

$Sales = \beta_0 + \beta_1 \cdot TV$

```
Dimensiones de los datos:  (200, 4)
```

[3]:
```
# información del dataframe
df_advertising.info()
```

```
<class 'pandas.core.frame.DataFrame'>
```

```
Varianza Sx^2 =  7370.94989321608 Sy^2 = 27.22185301507538
Desviacion estandar Sx = 85.85423631490808  Sy = 5.21745656
```

[55]:
```
# Calculamos la covarianza (con numpy)

S_xy = np.cov(x,y) ## Corresponde al factor [0][1] de salida
# por default calcula la covarianza de muestra así que no ha
print('Covarianza Sxy =', S_xy)
```

```
Covarianza Sxy = [[7370.94989322  350.39019472]
 [ 350.39019472   27.22185302]]
```

[17]:
```
# Calculamos el coeficiente de Correlación de Pearson

r = (S_xy)/(S_x*S_y)
```

Matriz de Covarianza.

X, Y

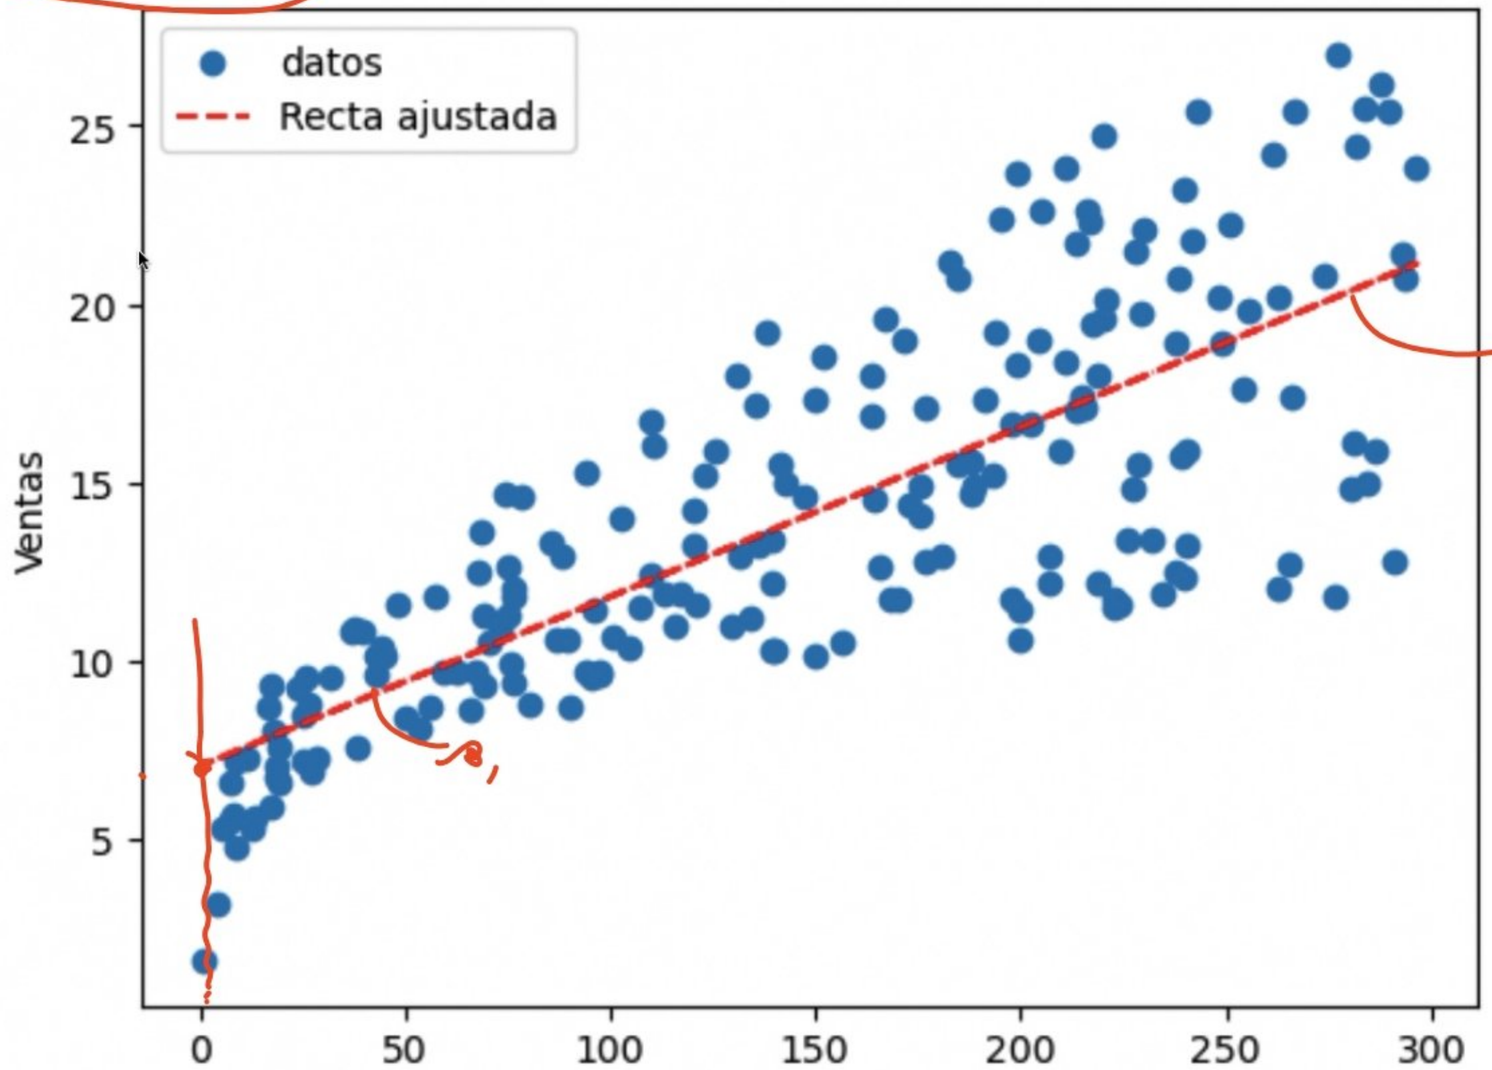
$$\begin{pmatrix} \mathrm{Cov}(x,x) & \mathrm{cov}(x,y) \\ \mathrm{cov}(y,x & \mathrm{cov}(y,y) \end{pmatrix} = \begin{pmatrix} \mathrm{Var}(x) & \mathrm{Cov}(x,y) \\ \mathrm{Cov}(y,x) & \mathrm{Var}(y) \end{pmatrix}$$

Supernova remnant G46.8–0.3 | Problem loading page | Inicio - Classroom | Trabajo de clase de Deep L | 03_calculo_tarea.ipynb - G | Home | 04_regresion_lineal_datos | 04_regresion_lineal_simple | MachineLearning_Inferenc

http://localhost:8888/notebooks/04_regresion_lineal_simple_multiple.ipynb

90% VPN

```
Beta0:  7.033
Beta1:  0.048
```



$\min \mathcal{L}(\beta_1, \beta_0)$

Mínimo error

Supernova remnant G46.8–0.3 | Problem loading page | Inicio - Classroom | Trabajo de clase de Deep L | 03_calculo_tarea.ipynb - G | Home | 04_regresion_lineal_datos | 04_regresion_lineal_simple | MachineLearning_Inferenc
http://localhost:8888/notebooks/04_regresion_lineal_simple_multiple.ipynb 90% VPN

Covariance Type: nonrobust

$\hat{y} = \beta_0 + \beta_1 X$

Pruebas de Hipótesis
$H_0: \beta = 0$
$H_1: \beta \neq 0$

	coef	std err	t	P>|t|	[0.025	0.975]
	(β_0)	(β_0)	test statistic	p-valor	intervalo de confianza 95%	
Intercept	7.0326 ±	0.458	15.360	0.000	[6.130 ,	7.935]
(β_1) **TV**	0.0475 ±	0.003	17.668	0.000	[0.042 ,	0.053]

Omnibus:	0.531	**Durbin-Watson:**	1.935
Prob(Omnibus):	0.767	**Jarque-Bera (JB):**	0.669

```python
# 2. entrenar el modelo
model_lm.fit(X,y)

display(model_lm)



# 3. hacer predicciones
y_pred = model_lm.predict(X)

# 4. evaluacion con metricas
r2 = r2_score(y, y_pred) # para r2 si importa el orden de los argumentos
mse = mean_squared_error(y, y_pred)
rmse = np.sqrt(mse)

print('R2: ', r2)
print('MSE: ', mse)
print('RMSE: ', rmse)
```



