[PDF] Online LaTeX Editor | The cosmic accelerator | Frontiers | The high energy | The high energy X-ray probe | Joint-instrument analyses | astrometry-inference-tutor | Home | 06_regresion_logistica_im | Machine Learning e Inferen

http://localhost:8888/notebooks/06_regresion_logistica_implementacion_dataset.ipynb 90% VPN

[82]:
```
df_bank['y'].value_counts()
```

[82]:
```
y
no     3668
yes     451
Name: count, dtype: int64
```

Clase 0 ~ 90%.

Clase 1 ~ 10%.

$$P = \frac{1}{1+e^{-XB}}$$

→ Clase 1

Observaciones iniciales

1-P Clase 0

- El dataset contiene aproximadamente 4119 filas y 21 c
- La variable objetivo `y` es binaria: `yes` o `no`, indica

[PDF] Online LaTeX Editor | The cosmic accelerator | Frontiers | The high energy | The high energy X-ray probe | Joint-instrument analyses | astrometry-inference-tutor | Home | 06_regresion_logistica_im | Machine Learning e Inferen

http://localhost:8888/notebooks/06_regresion_logistica_implementacion_dataset.ipynb 90% VPN

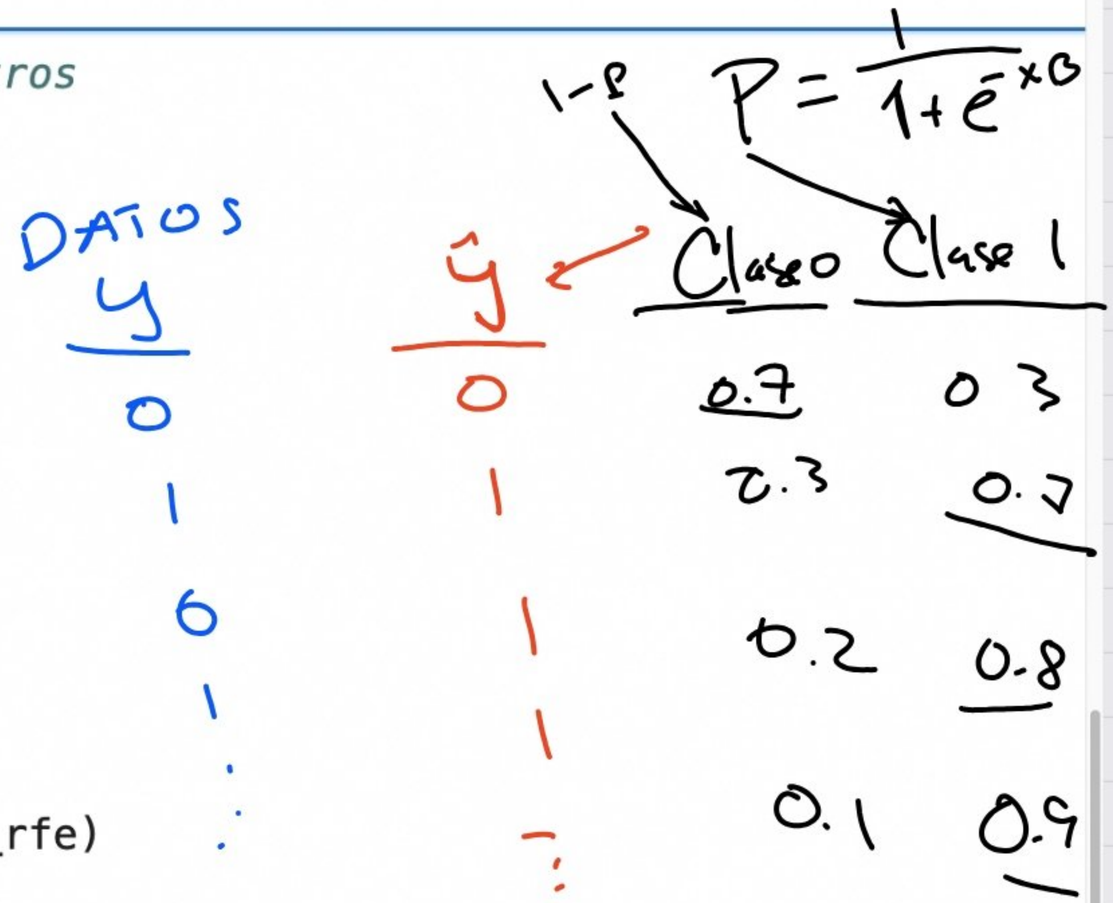
15]:
```
# 1. Instanciamos modelos, y sus hiperparámetros
lr = LogisticRegression(max_iter=20000)
lr_rfe = LogisticRegression(max_iter=20000)

# 2. Entrenamos modelos
lr.fit(X_train,y_train)
lr_rfe.fit(X_rfe_train, y_train)

# 3. Predicciones y evaluación básica
y_pred = lr.predict(X_test)
y_pred_rfe = lr_rfe.predict(X_rfe_test)

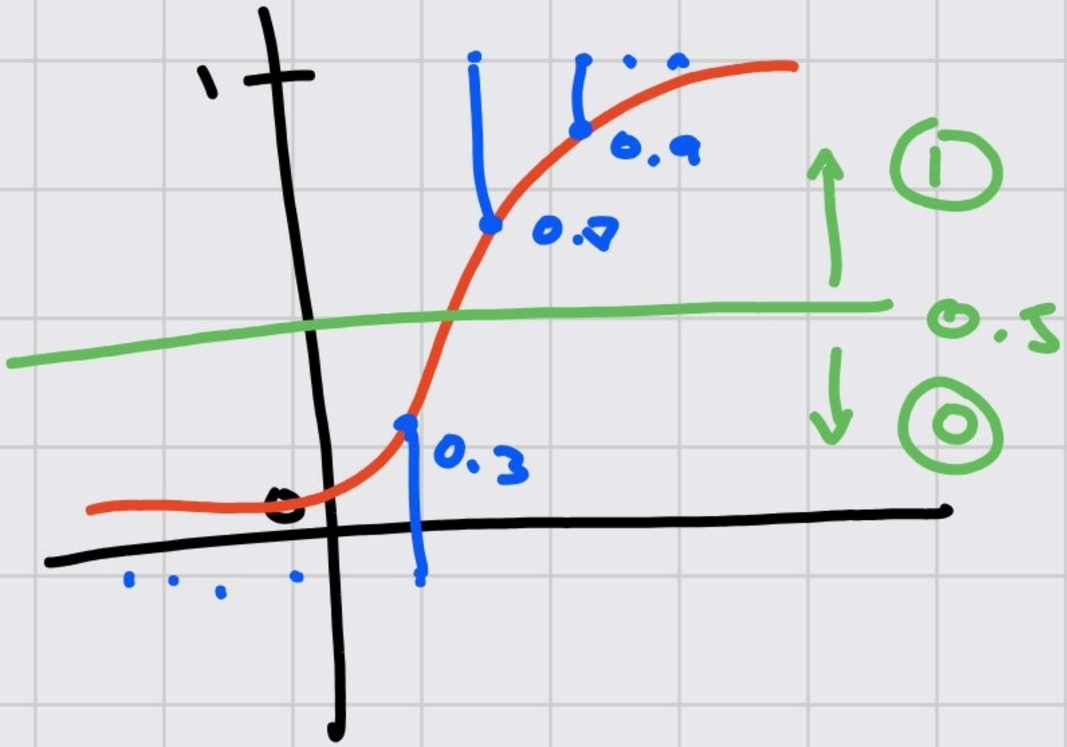
accuracy = accuracy_score(y_test, y_pred)
accuracy_rfe = accuracy_score(y_test, y_pred_rfe)

print(f"Exactitud en test con todas las variables: {accuracy:.4f}")
print(f"Exactitud en test con 12 variables seleccionadas: {accuracy_rfe:.4f}")
```




```
Exactitud en test con todas las variables: 0.9126
Exactitud en test con 12 variables seleccionadas: 0.8997
```

$$P = \frac{1}{1+e^{-x\theta}}$$



```python
# 3. Predicciones y evaluación básica
y_pred = lr.predict(X_test)
y_pred_rfe = lr_rfe.predict(X_rfe_test)

accuracy = accuracy_score(y_test, y_pred)
accuracy_rfe = accuracy_score(y_test, y_pred_rfe)

print(f"Exactitud en test con todas las variables: {accuracy:.4f}")
print(f"Exactitud en test con 12 variables seleccionadas: {accuracy_rfe:.4f}")
```

```
Exactitud en test con todas las variables: 0.9045
Exactitud en test con 12 variables seleccionadas: 0.8989
```

umbral 0.5

2]:

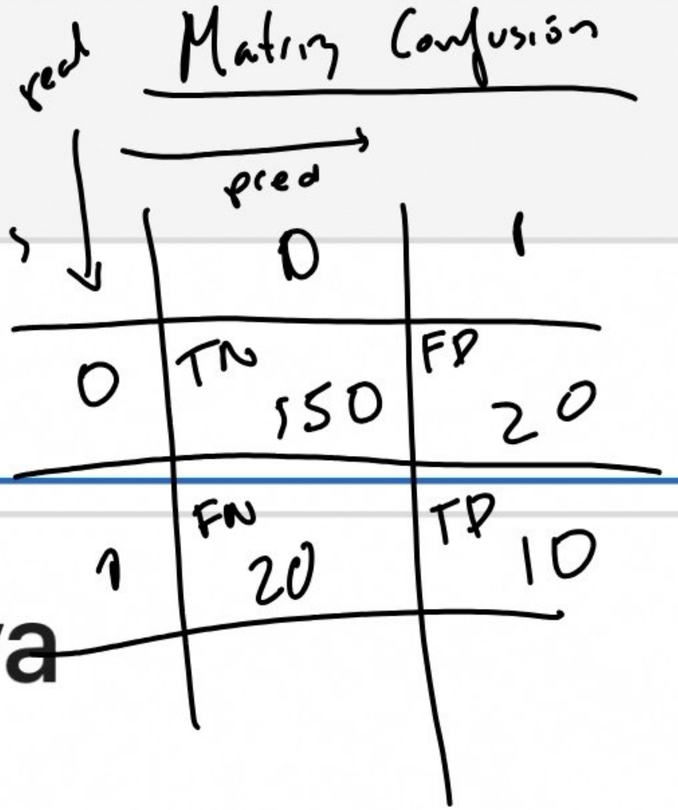
```python
print(y_pred_rfe)
print(y_test)
```

```
[0 0 0 ... 0 0 0]
2799    0
3197    0
1708    0
2436    0
3884    0
```

[139]:
```
print(y_pred_rfe)
print(y_test.to_numpy())
```

```
[0 0 0 ... 0 0 1]
[0 0 0 ... 1 0 1]
```

TN FN FP TP



Conclusión comparativa

Al comparar ambos modelos, observamos que:

- El modelo entrenado con **todas las variables** alcanza

Matriz de Confusión

real \ pred	0	1
0	TN	FP
1	FN	TP

90% 0
10% 1 → acc ~ 0.9

$$\text{Accuracy (Exactitud)} = \frac{TP+TN}{TP+TN+FP+FN}$$

$$\text{Precision} = \frac{TP}{TP+FP}$$

Detectar FP

De los casos predichos como positivo, en la prop de verdaderos positivos,

$$\text{Recall (Sensibilidad)} = \frac{TP}{TP+FN}$$

TPR

De los casos reales positivos, en la prop que fue detectada correctamente.

Detectar FN

$$\text{Specificity} = \frac{TN}{TN+FP}$$

$$1 - \text{Specificity} = \frac{FP}{TN+FP}$$

FPR

$$F1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

[140]:
```
#predict probabilidades del conjunto de test
probs = lr.predict_proba(X_test)
probs_rfe = lr_rfe.predict_proba(X_rfe_test)
```

[141]:
```
probs

#primera columna, probabilidad de la clase 0 (no)
#segunda columna, probabilidad de la clase 1 (si)
```

$1-P$ Clase 0 P Clase 1 $P = \frac{1}{1+e^{-XB}}$

[141]:
```
array([[8.48290133e-01, 1.51709867e-01],   0
       [9.99136649e-01, 8.63351474e-04],   0
       [9.86633901e-01, 1.33660991e-02],   0
       ...,
       [8.35468008e-01, 1.64531992e-01],
       [9.90032574e-01, 9.96742649e-03],
       [9.92148540e-01, 7.85146014e-03]])
```

[45]:
```
# Comparacion
pd.DataFrame({
    'probs_0': probs[:,0],
    'probs_1': probs[:,1],
    'preds': y_pred,
```

```
Matriz de confusión (todas las variables), threshold: 0.5
Accuracy: 0.9045307443365695
```

actual	0	1
prediction		
0	1060	77
1	41	58

```
Matriz de confusión (12 variables rfe), threshold: 0.5
Accuracy (rfe): 0.8988673139158576
```

actual	0	1
prediction		
0	1081	105
1	20	30

Para crear la curva de ROC, tenemos que calcular la sensitividad y 1-especificidad para varios valores del umbral d

[58]:
```
# lo hacemos de forma iterada para varios threshold
```

[PDF] Online LaTeX Editor | The cosmic accelerator | N | Frontiers | The high energy | The high energy X-ray probe (H | Joint-instrument analyses | astrometry-inference-tutor | Home | 06_regresion_logistica_im | Machine Learning e Inferen
http://localhost:8888/notebooks/06_regresion_logistica_implementacion_dataset.ipynb 90% VPN

```
Exactitud en test con todas las variables: 0.9045
Exactitud en test con 12 variables seleccionadas: 0.8989
=== Reporte modelo completo ===
              precision    recall  f1-score   support

           0       0.93      0.96      0.95      1101
           1       0.59      0.43      0.50       135

    accuracy                           0.90      1236
   macro avg       0.76      0.70      0.72      1236
weighted avg       0.89      0.90      0.90      1236

=== Reporte modelo con RFE ===
              precision    recall  f1-score   support

           0       0.91      0.98      0.95      1101
           1       0.60      0.22      0.32       135

    accuracy                           0.90      1236
   macro avg       0.76      0.60      0.63      1236
weighted avg       0.88      0.90      0.88      1236

AUC con todas las variables: 0.9207
AUC con RFE (12 variables): 0.7940
```

Umbral 0.5

[66]:
```
# Visualización de las matrices de confusión (para threshold 0.5)
fig, ax = plt.subplots(1, 2, figsize=(12, 5))
```

1	168	114

```
Matriz de confusión (12 variables rfe), threshold: 0.1
Accuracy (rfe): 0.7694174757281553
```

actual	**0**	**1**
prediction		
0	857	41
1	244	94

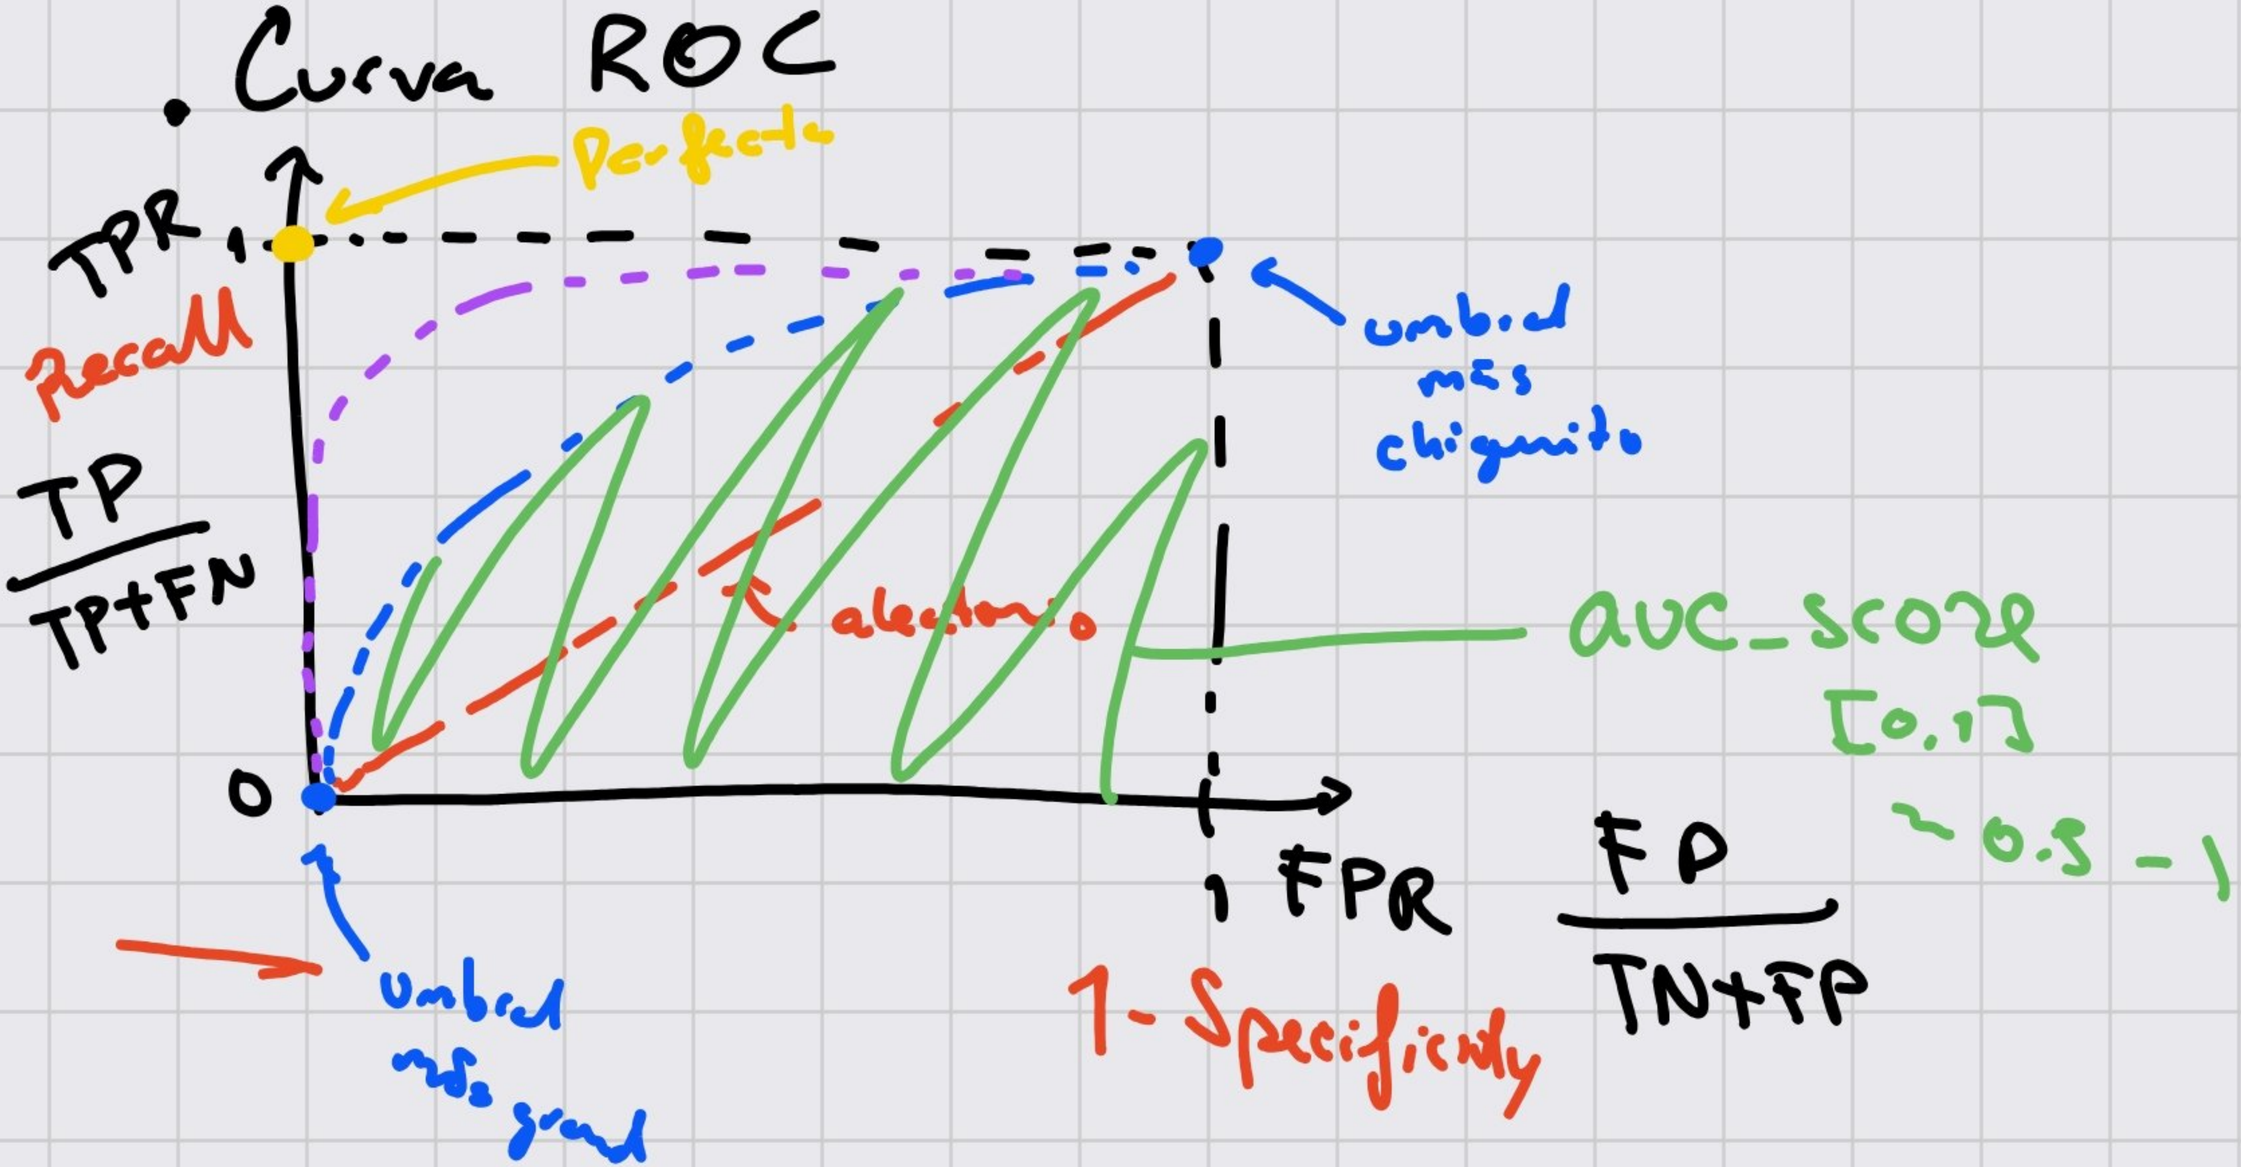
Para crear la curva de ROC, tenemos que calcular la sensitividad y 1-especificidad para varios valores del umbral de decisión.

[58]:
```
# lo hacemos de forma iterada para varios threshold

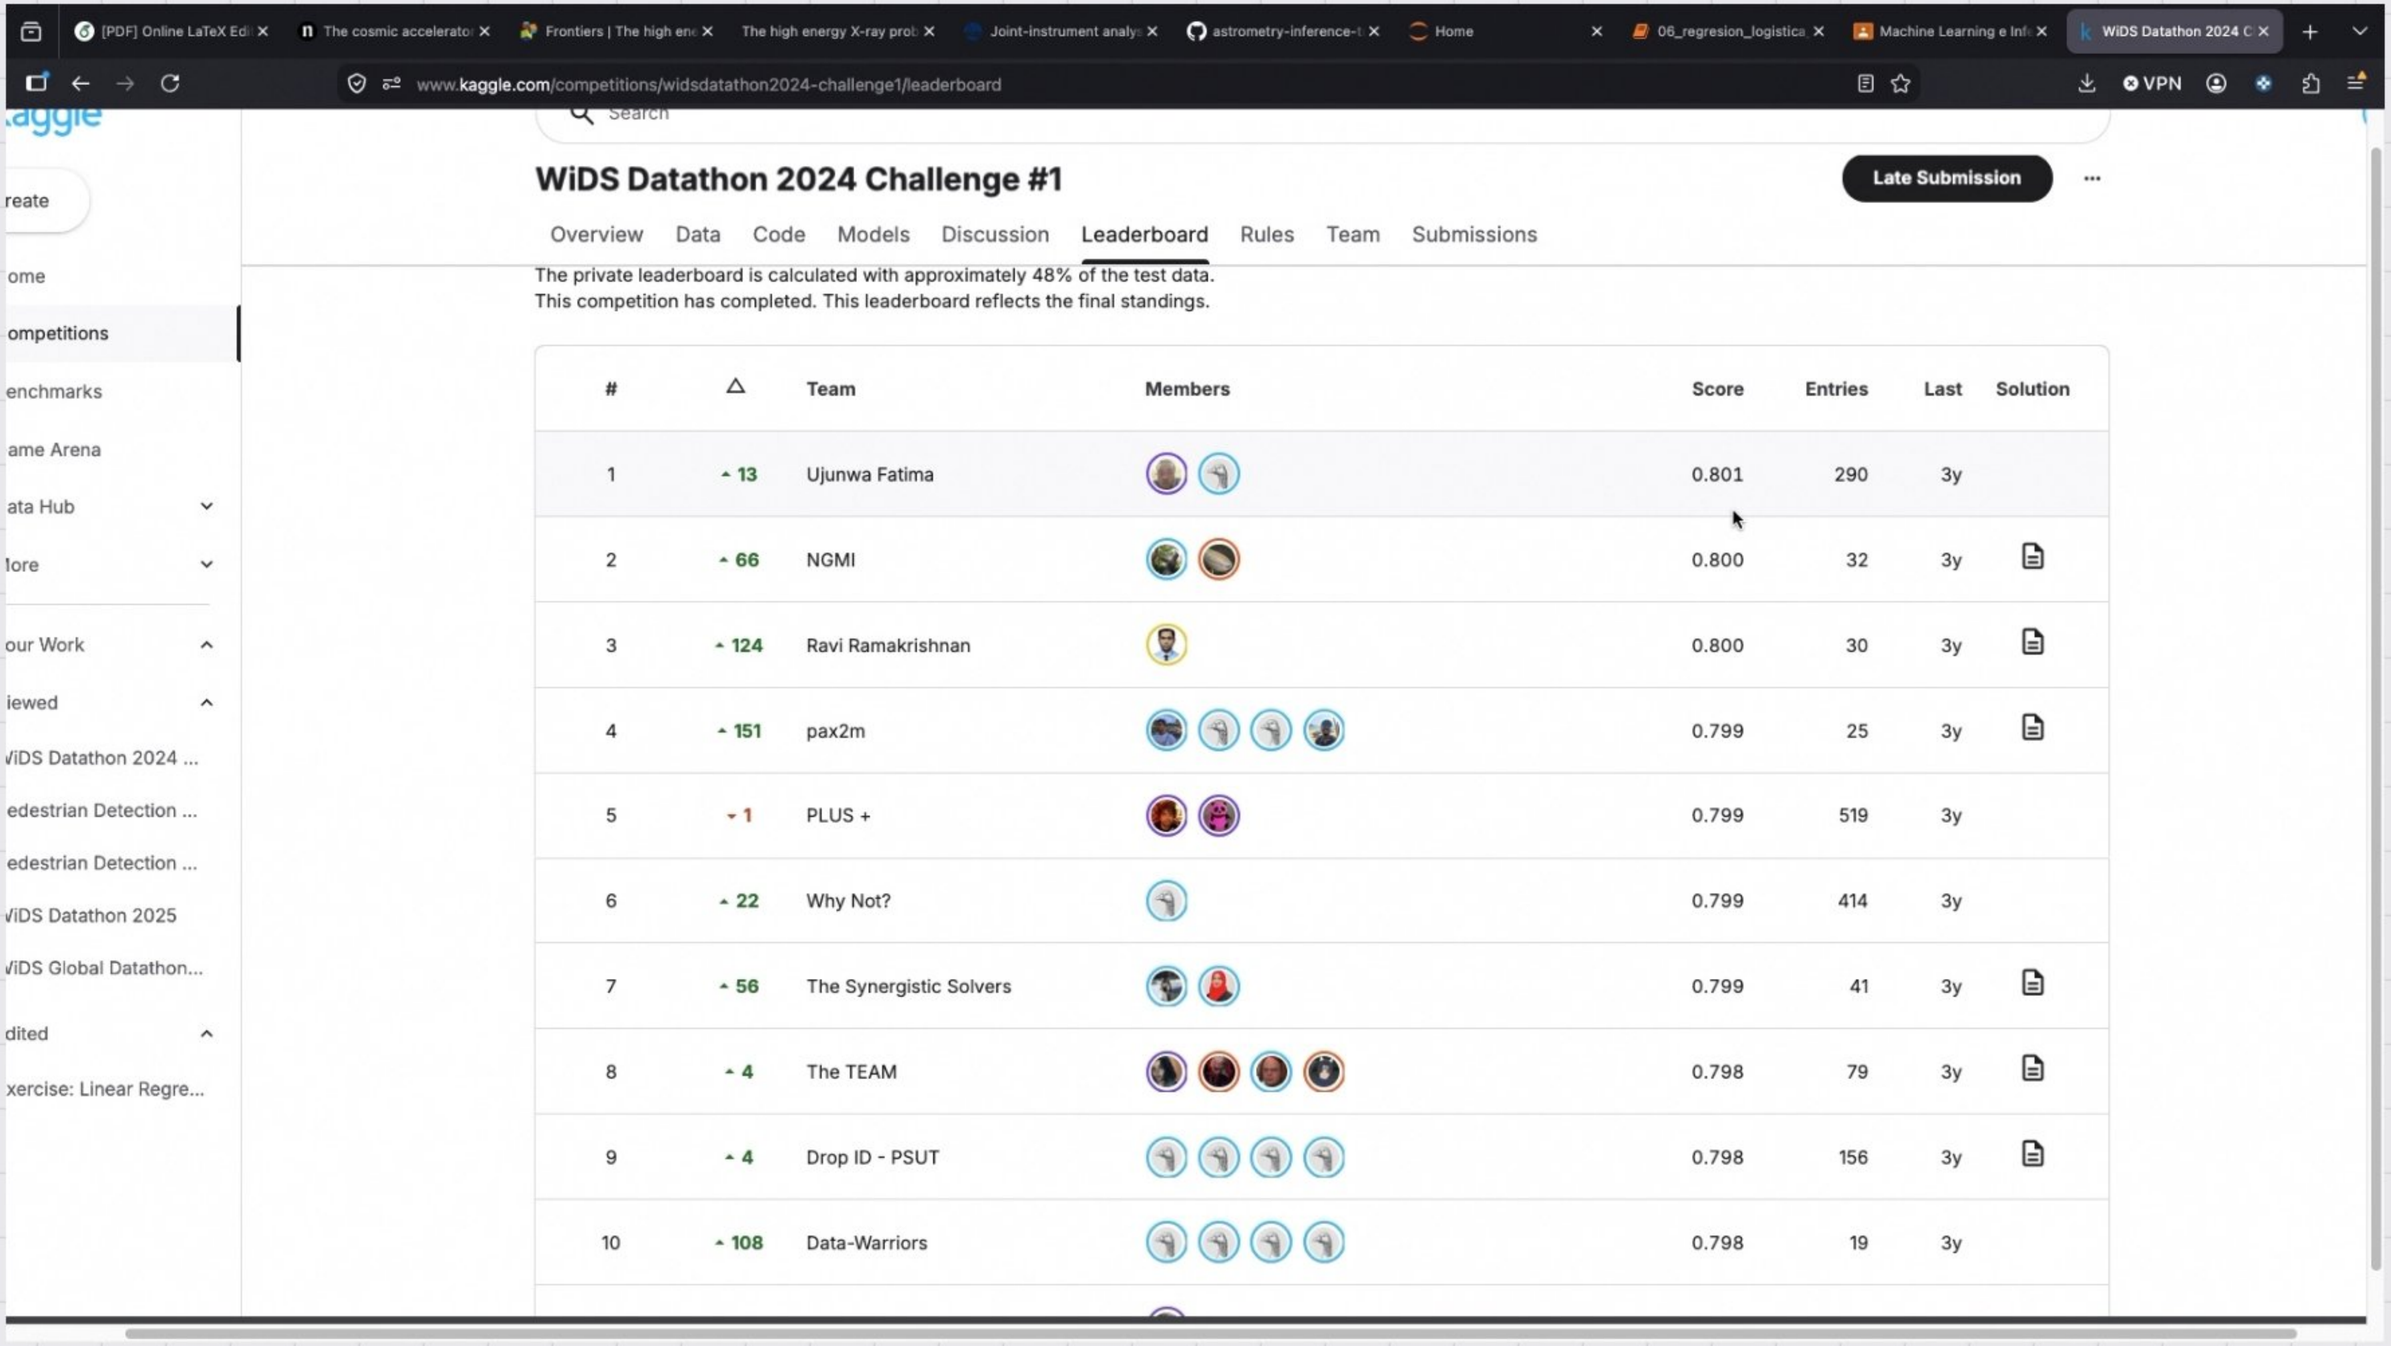
thresholds = [0.04, 0.05, 0.07, 0.10, 0.12, 0.15, 0.18, 0.20, 0.25, 0.3, 0.4, 0.5]

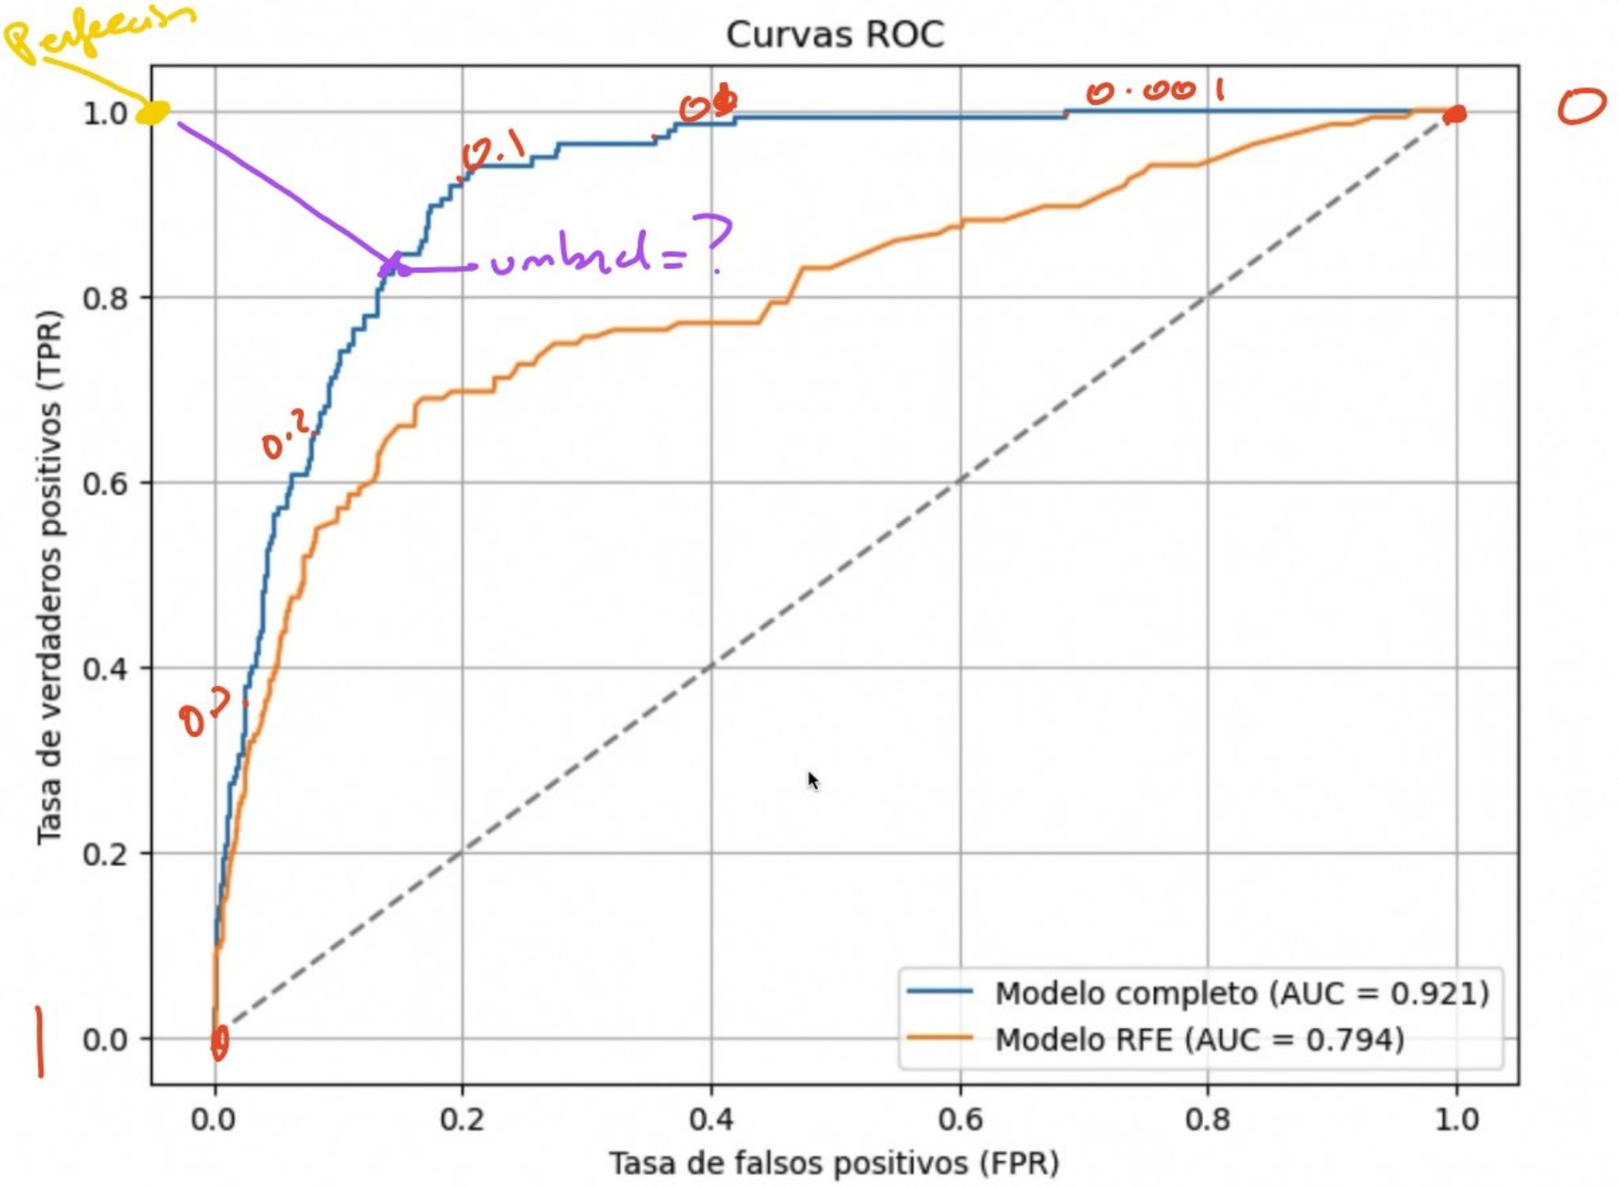
sensitivities = [1] # ya incluimos el 1, para completar el gráfico
especifities_c = [1] # 1 - especificidad

for t in thresholds:
    prob_df['prediction'] = np.where(prob_df[0] >= t, 1, 0)
    prob_df['actual'] = list(y_test) ## para que coincidadn los index
    prob_df.head()
```


Curva ROC
Perfetto
TPR
1
Recall
TP / TP+FN
umbral mas chiquito
aleatorio
AUC_score
[0,1]
~ 0.5 - 1
0
FPR
1
FP / TN+FP
1 - Specificity
umbral mas grande


0.9
0.8
0.4
0.3


www.kaggle.com/competitions/widsdatathon2024-challenge1/leaderboard
WiDS Datathon 2024 Challenge #1
Late Submission
Overview
Data
Code
Models
Discussion
Leaderboard
Rules
Team
Submissions
The private leaderboard is calculated with approximately 48% of the test data.
This competition has completed. This leaderboard reflects the final standings.
| △ | Team | Members | Score | Entries | Last | Solution
1 | 13 | Ujunwa Fatima | 0.801 | 290 | 3y
2 | 66 | NGMI | 0.800 | 32 | 3y
3 | 124 | Ravi Ramakrishnan | 0.800 | 30 | 3y
4 | 151 | pax2m | 0.799 | 25 | 3y
5 | 1 | PLUS + | 0.799 | 519 | 3y
6 | 22 | Why Not? | 0.799 | 414 | 3y
7 | 56 | The Synergistic Solvers | 0.799 | 41 | 3y
8 | 4 | The TEAM | 0.798 | 79 | 3y
9 | 4 | Drop ID - PSUT | 0.798 | 156 | 3y
10 | 108 | Data-Warriors | 0.798 | 19 | 3y


Curvas ROC
Tasa de verdaderos positivos (TPR)
Tasa de falsos positivos (FPR)
0.0
0.2
0.4
0.6
0.8
1.0
Modelo completo (AUC = 0.921)
Modelo RFE (AUC = 0.794)

Preguntas | Respuestas 68 | Configuración | Puntos totales: 40

Analiza el rendimiento del modelo basándote en el reporte y la matriz de confusión mostradas. A pesar de tener una exactitud (accuracy) del 86%, el banco está recibiendo miles de quejas de clientes molestos porque sus tarjetas son bloqueadas injustamente, pero la dirección está contenta porque se detecta casi todo el fraude.

1. Explica la relación entre la **Precisión** y **Sensibilidad (Recall)** para la clase Fraude (1) en este modelo. ¿Qué significa ese 0.25 de precisión en el mundo real?

2. Si el banco decide que la prioridad ahora es **reducir la insatisfacción del cliente** (evitar bloqueos falsos), ¿qué métrica debería intentar subir y qué impacto tendría este en la detección de fraudes reales?. Justifica tu respuesta usando los conceptos de Falsos Positivos y Falsos Negativos

Hay muchos FP Marcó fraude y no lo era

$$Prec = \frac{TP}{TP+FP}$$

$$Recall = \frac{TP}{TP+FN}$$

Clase	Precision	Recall	F1-Score
0 (Legítima)	0.99	0.85	0.91
1 (Fraude)	0.25	0.95	0.40
Accuracy			0.86

Real\Predicción	0	1
0	8075	1425
1	25	475

TN FP FN TP

Texto de respuesta larga