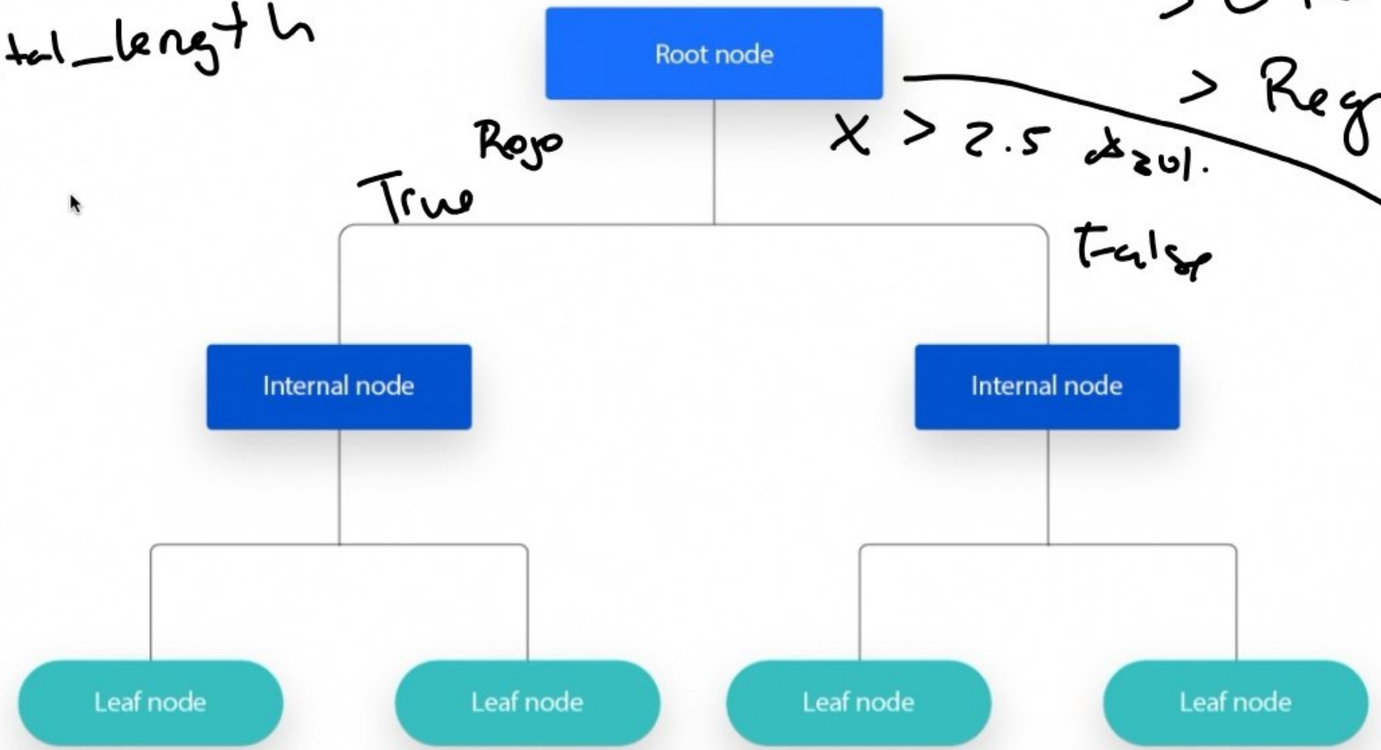
Vista Previa Archivo Edición Visualización Ir Herramientas Ventana Ayuda
Mié 14 de oct 9:23a.m.
07_arboles_ensamble_slides.pdf
Página 2 de 22
Visualización Inspector Zoom Compartir Resaltado Girar Marcado Rellenar formulario Buscar

características
petal_length

> Clasificación
> Regresión

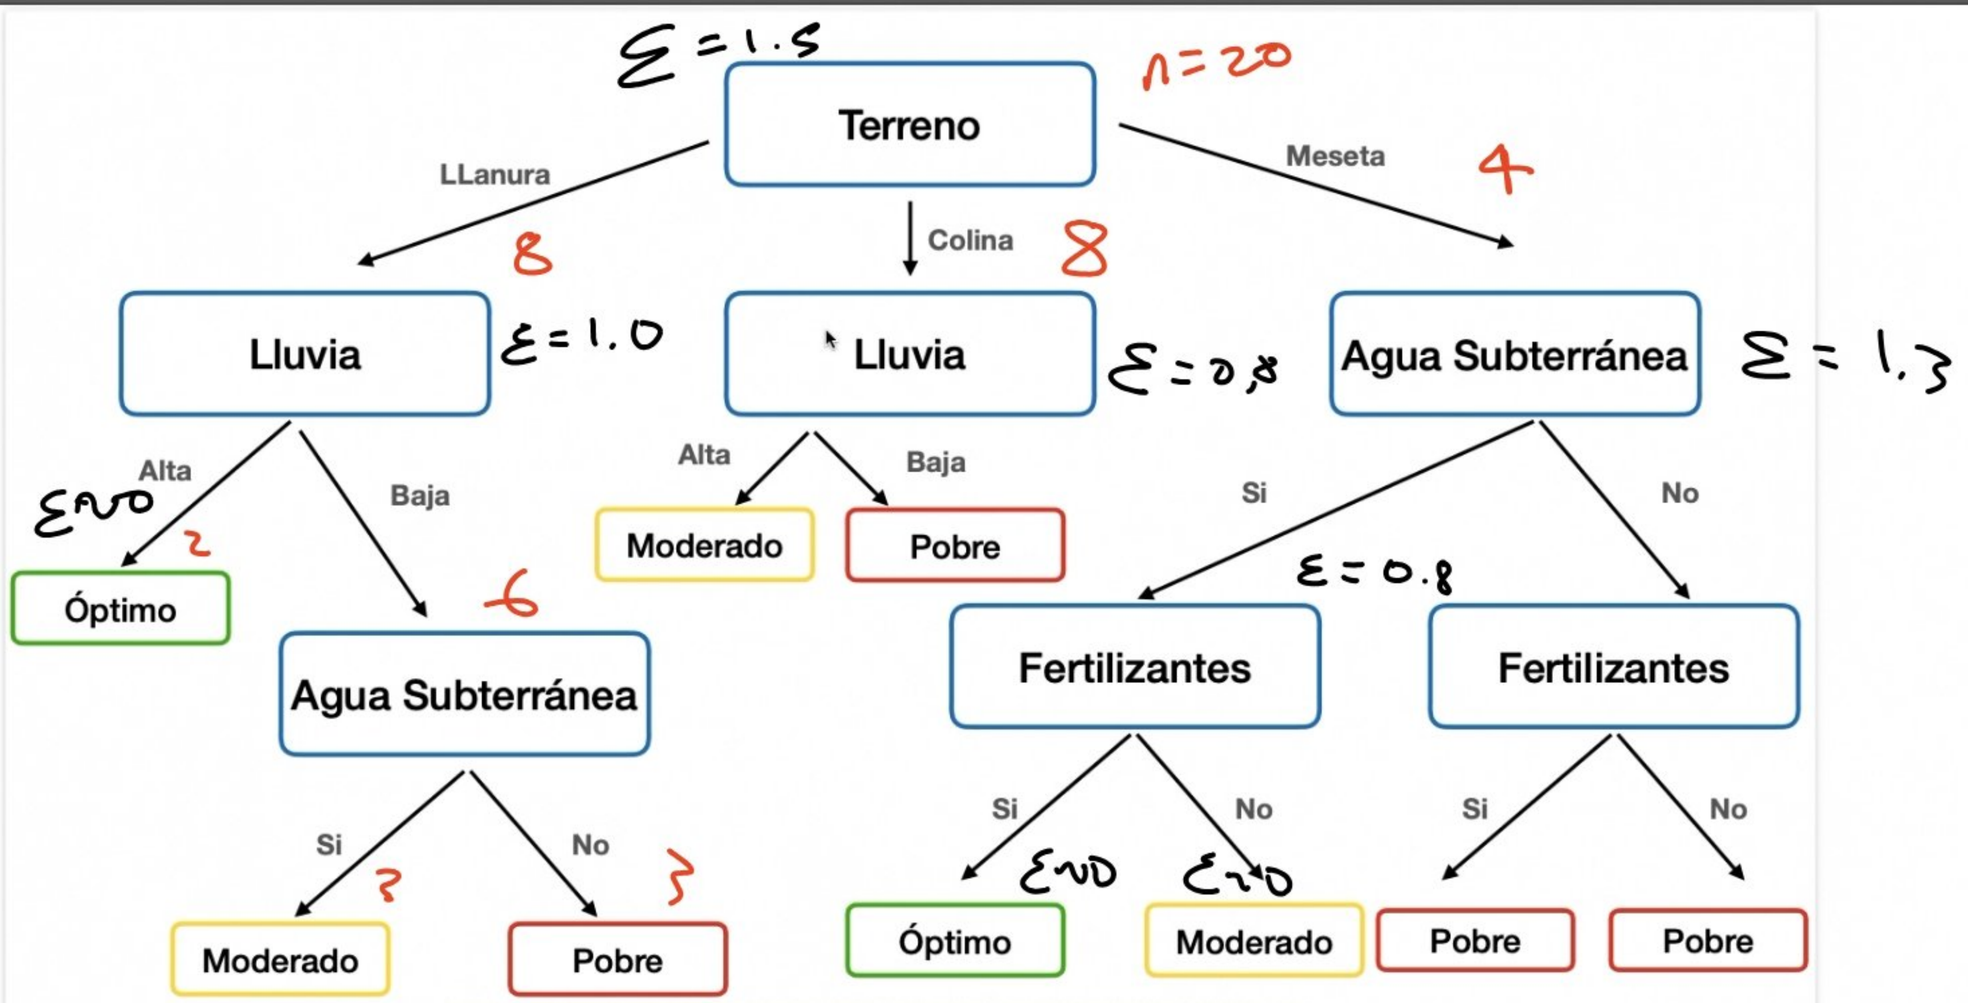


Predicción

Bayesiana, Licenciatura en Inteligencia Artificial y Ciencia de Datos, Universidad de Guadalajara. M. en C. Iván Toledano Juárez

	Lugar	Lluvia	Terreno	Fertilizantes	Agua_subterranea	Cosecha
0	P1	Altas	Llanura	Si	Si	Optima

Macintosh HD › Usuarios › vanotole › Documento › Doctorado › MachineLe › Github › MachineLe › 07_arboles_ensamble › 07_arboles_ensamble_slides.pdf



Homogeneidad

Vista Previa Archivo Edición Visualización Ir Herramientas Ventana Ayuda
Mié 14 de oct 9:30 a.m.
07_arboles_ensamble_slides.pdf
Página 5 de 22
Visualización Inspector Zoom Compartir Resaltado Girar Marcado Rellenar formulario Buscar

Cosecha Lluvia	Moderada	Optima	Pobre
Altas	4	3	0
Bajas	2	0	5
Medias	3	1	2

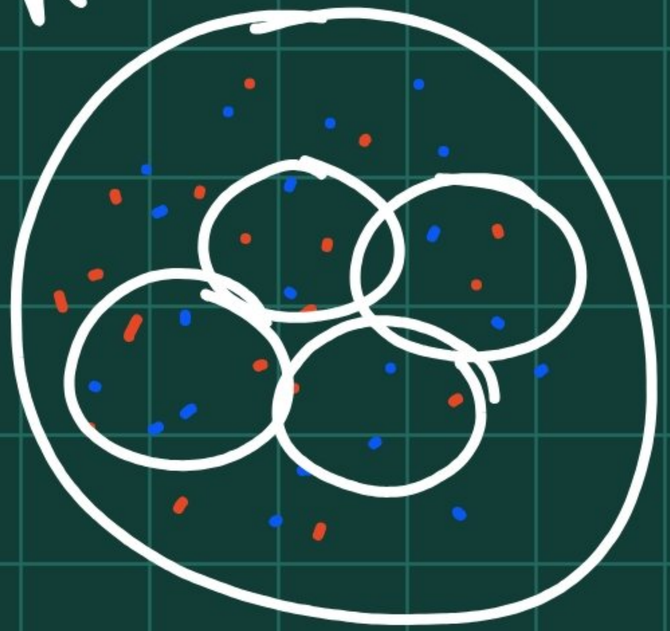
Cosecha Terreno	Moderada	Optima	Pobre
Colinas	3	0	3
Llanura	3	2	1
Meseta	3	2	3

Cosecha Fertilizantes	Moderada	Optima	Pobre
No	3	0	6
Si	6	4	1

Cosecha Agua_subterranea	Moderada	Optima	Pobre
No	3	2	6
Si	6	2	1

Macintosh HD › Usuarios › vanotole › Documento › Doctorado › MachineLe › Github › MachineLe › 07_arboles_ensamble › 07_arboles_ensamble_slides.pdf

homogéneo



0 → 50%

1 → 50%

heterogéneo



Vista Previa Archivo Edición Visualización Ir Herramientas Ventana Ayuda
Mié 14 de oct 9:36 a.m.
07_arboles_ensamble_slides.pdf
Página 6 de 22
Visualización Inspector Zoom Compartir Resaltado Girar Marcado Rellenar formulario Buscar

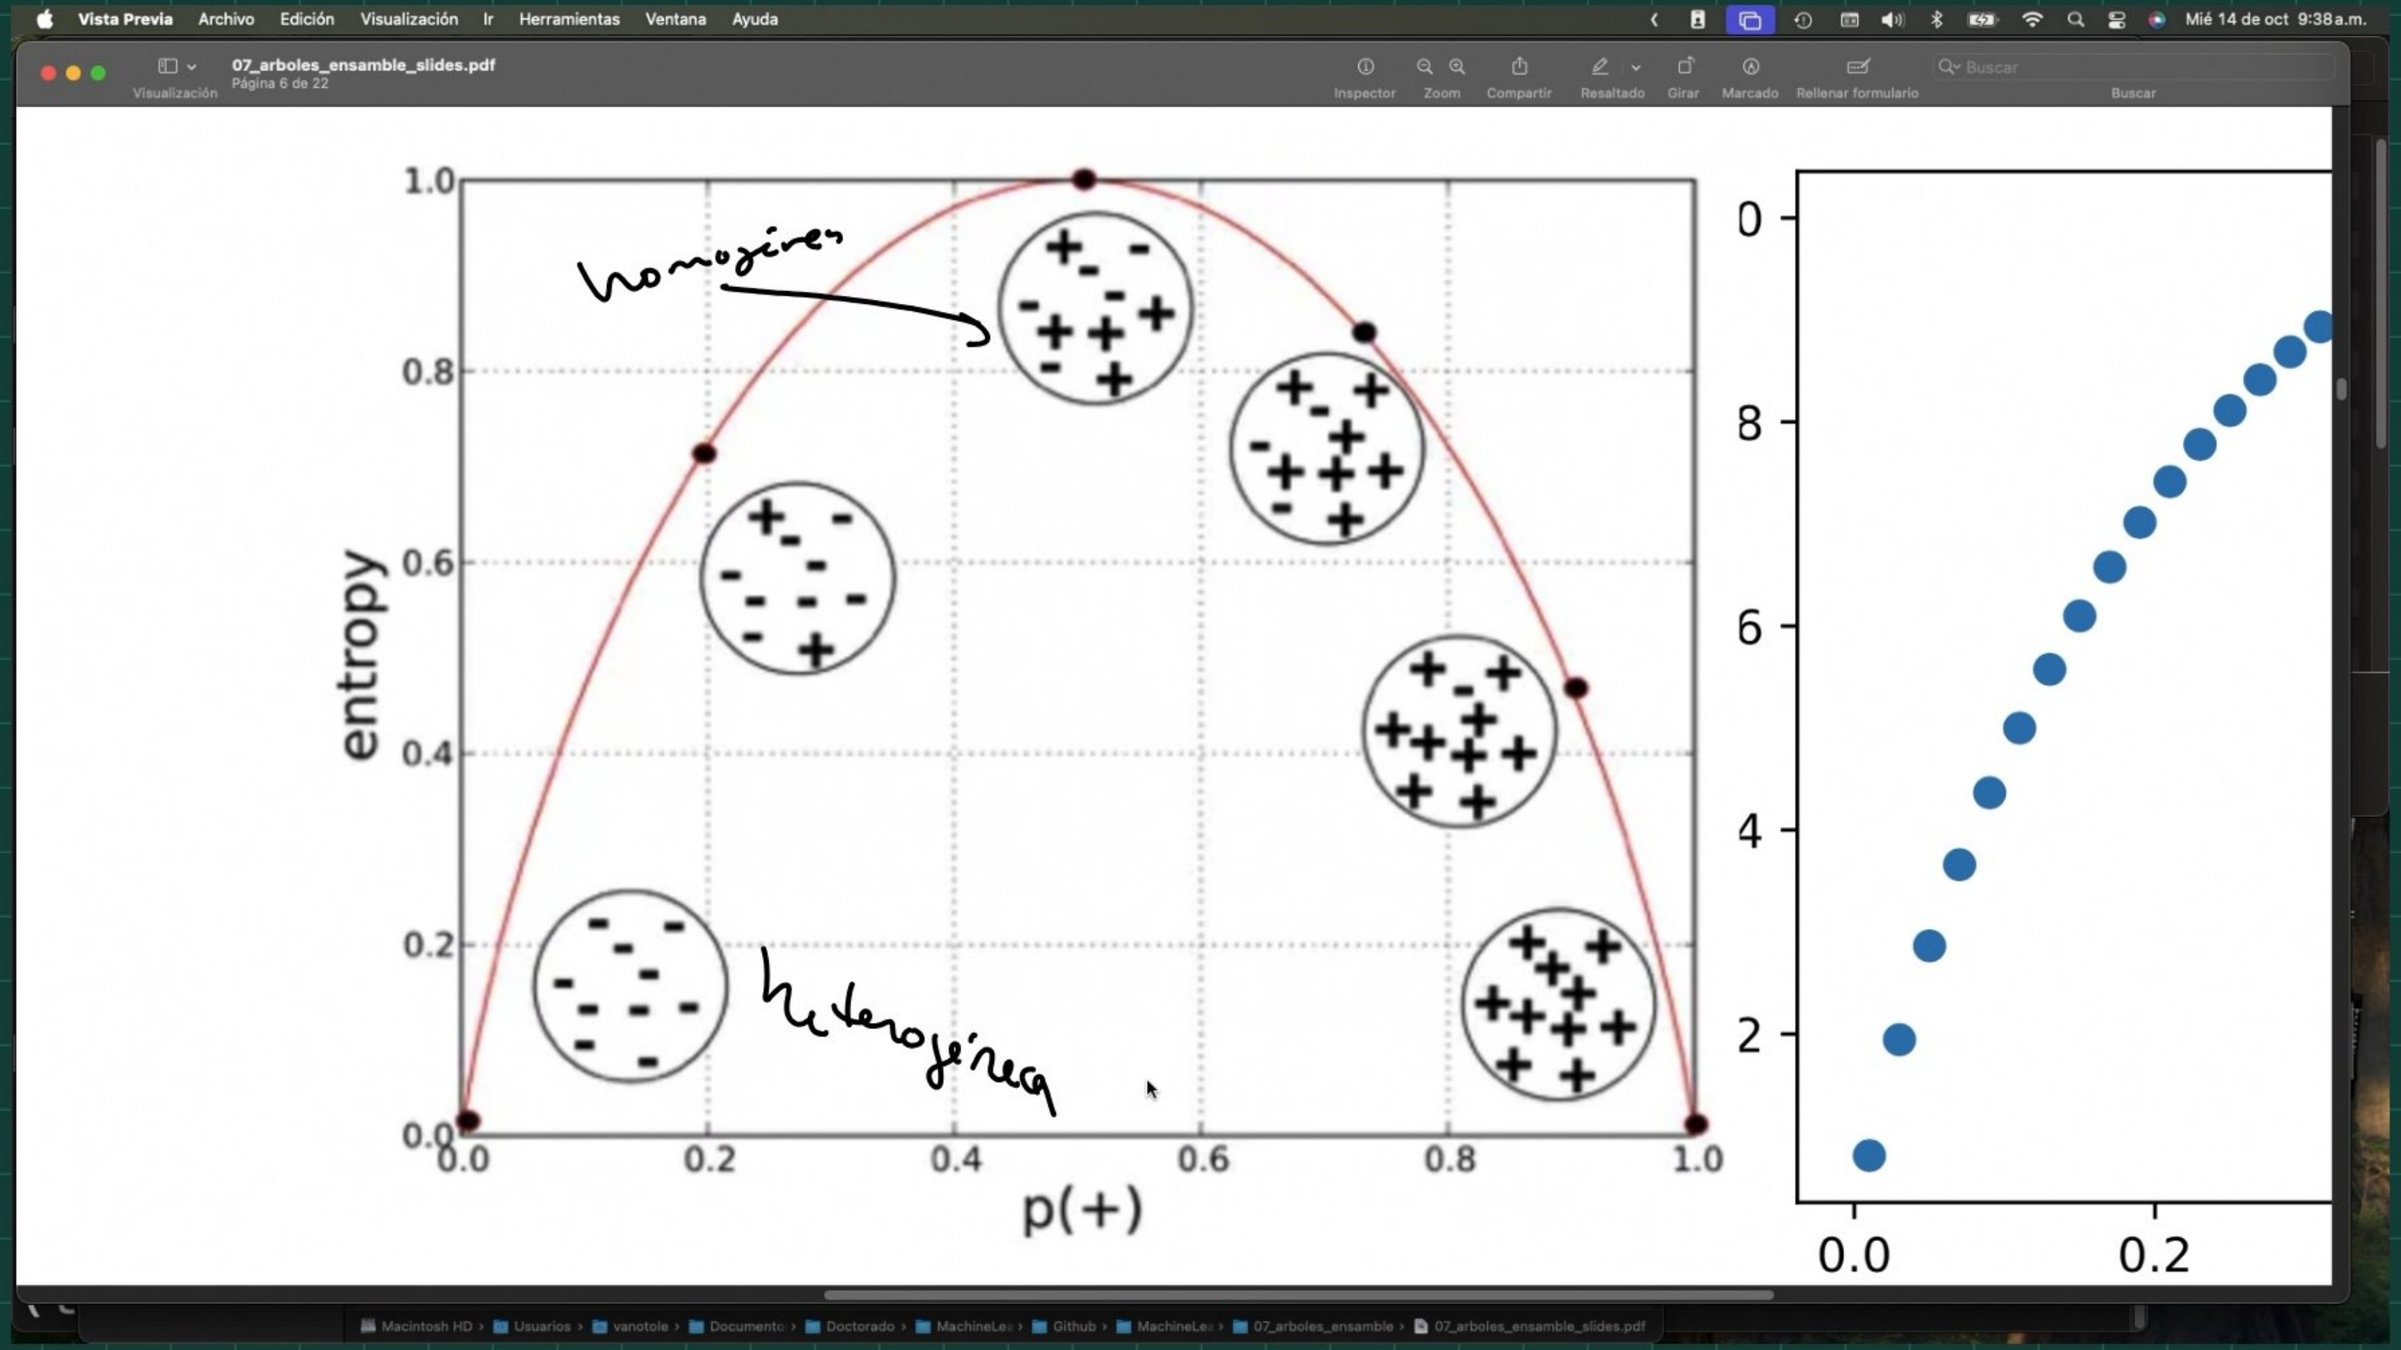


$$H(S) = \sum_{i=1}^{n} - p_i \log_2(p_i)$$

clases

- Donde n son las categorías

Macintosh HD › Usuarios › vanotole › Documento › Doctorado › MachineLe › Github › MachineLe › 07_arboles_ensamble › 07_arboles_ensamble_slides.pdf


Vista Previa Archivo Edición Visualización Ir Herramientas Ventana Ayuda
Mié 14 de oct 9:38 a.m.
07_arboles_ensamble_slides.pdf
Página 6 de 22
Visualización
Inspector
Zoom
Compartir
Resaltado
Girar
Marcado
Rellenar formulario
Buscar
homogénea
heterogénea
entropy
p(+)
0.0
0.2
0.4
0.6
0.8
1.0
0
2
4
6
8
Macintosh HD › Usuarios › vanotole › Documento › Doctorado › MachineLe › Github › MachineLe › 07_arboles_ensamble › 07_arboles_ensamble_slides.pdf

Entropía del sistema

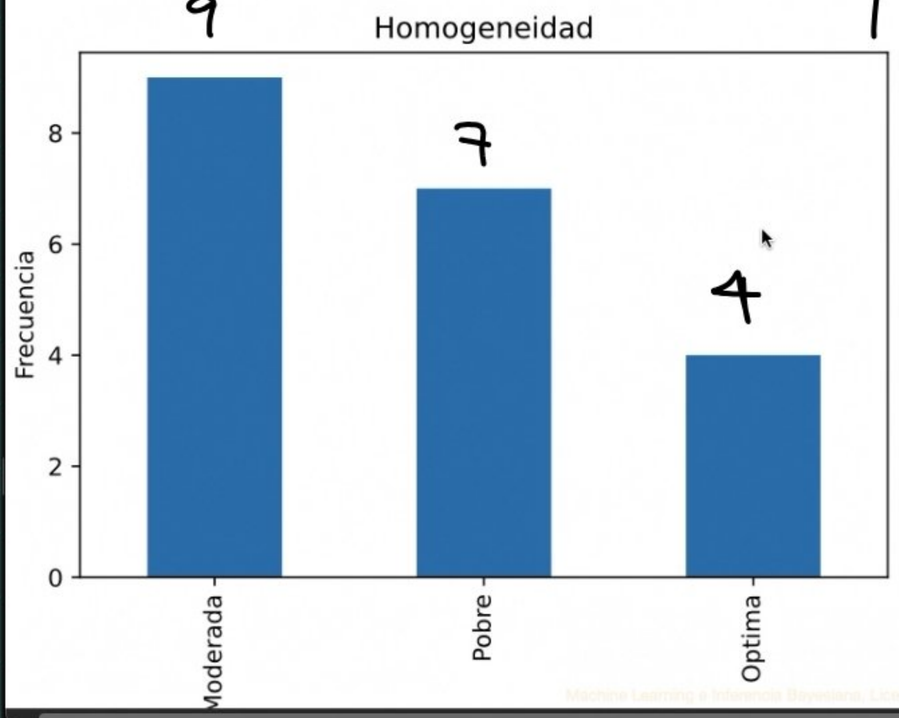
Variable target

$$H(S) = -\frac{4}{20} \cdot \log_2\left(\frac{4}{20}\right) - \frac{9}{20} \cdot \log_2\left(\frac{9}{20}\right) - \frac{7}{20} \cdot \log_2\left(\frac{7}{20}\right) = 1.5$$

mid

pobre

opt -



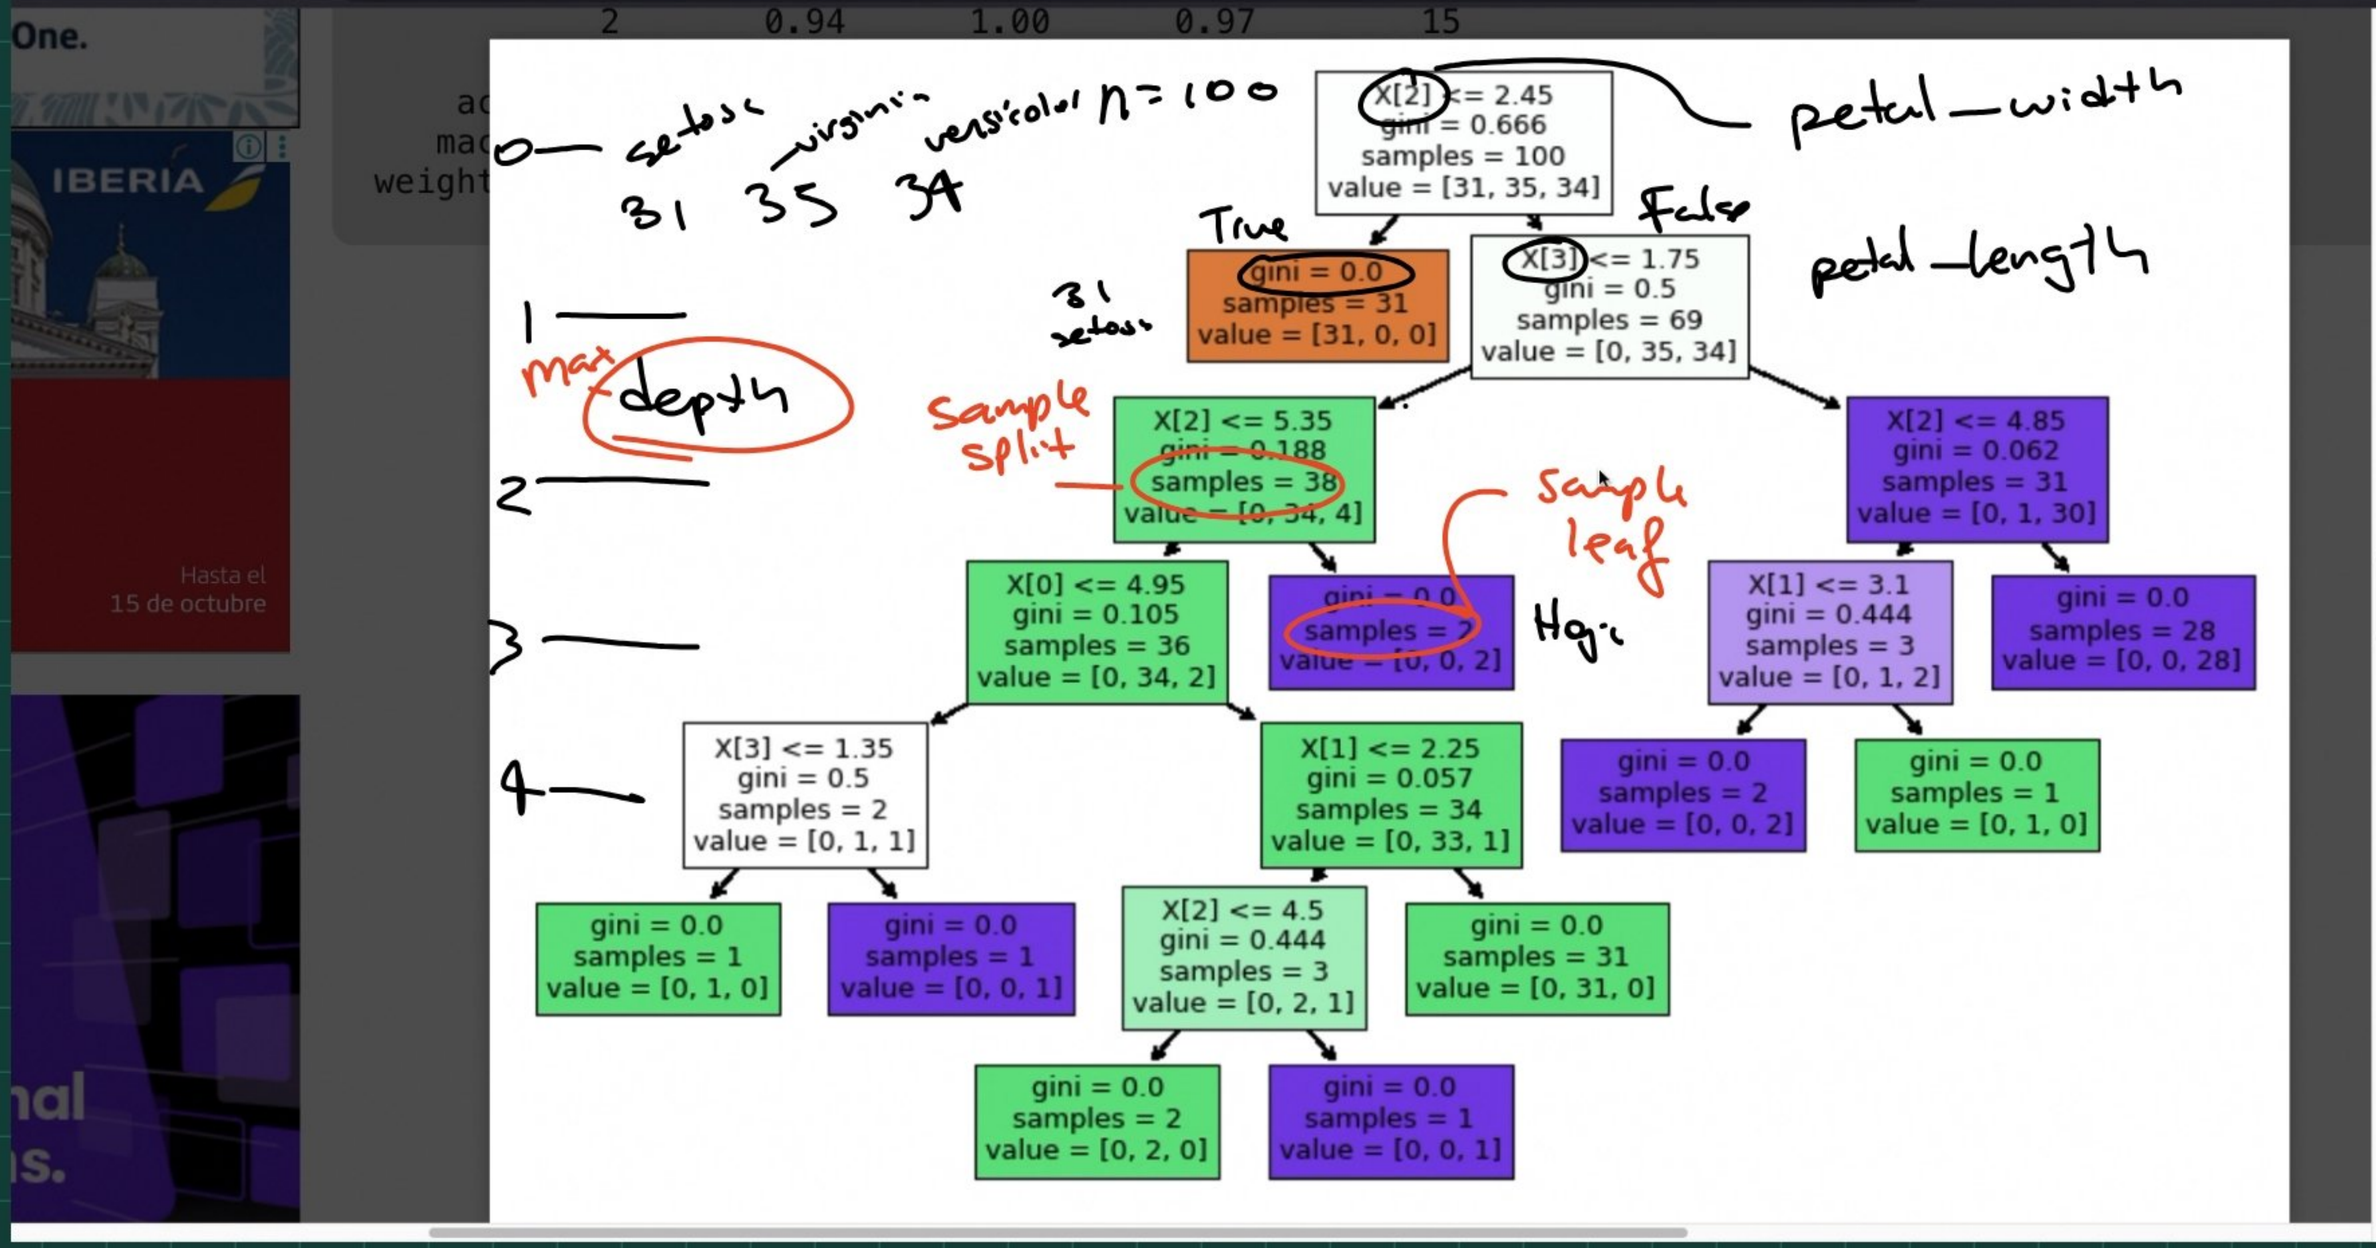
$$H(S) = -\sum_{i=1}^{3} p_i \log_2(p_i)$$

Entropía Total / Target.

$$p_{\text{optimo}} = \frac{4}{20}$$

$$p_{\text{moderado}} = \frac{9}{20}$$

$$p_{\text{pobre}} = \frac{7}{20}$$


X[2] <= 2.45
gini = 0.666
samples = 100
value = [31, 35, 34]
True
False
gini = 0.0
samples = 31
value = [31, 0, 0]
X[3] <= 1.75
gini = 0.5
samples = 69
value = [0, 35, 34]
X[2] <= 5.35
gini = 0.188
samples = 38
value = [0, 34, 4]
X[2] <= 4.85
gini = 0.062
samples = 31
value = [0, 1, 30]
X[0] <= 4.95
gini = 0.105
samples = 36
value = [0, 34, 2]
gini = 0.0
samples = 2
value = [0, 0, 2]
X[1] <= 3.1
gini = 0.444
samples = 3
value = [0, 1, 2]
gini = 0.0
samples = 28
value = [0, 0, 28]
X[3] <= 1.35
gini = 0.5
samples = 2
value = [0, 1, 1]
X[1] <= 2.25
gini = 0.057
samples = 34
value = [0, 33, 1]
gini = 0.0
samples = 2
value = [0, 0, 2]
gini = 0.0
samples = 1
value = [0, 1, 0]
gini = 0.0
samples = 1
value = [0, 1, 0]
gini = 0.0
samples = 1
value = [0, 0, 1]
X[2] <= 4.5
gini = 0.444
samples = 3
value = [0, 2, 1]
gini = 0.0
samples = 31
value = [0, 31, 0]
gini = 0.0
samples = 2
value = [0, 2, 0]
gini = 0.0
samples = 1
value = [0, 0, 1]
petal_width
petal_length
sample split
sample leaf
max depth
n = 100
setosa
virginica
versicolor
31 35 34
31 setosa

Ganancia de información

Variable target

$$\Delta H(S, V) = H(S) - \sum_{c \in V} \frac{|V = c|}{V} H(V = c)$$

X_1

$$\text{Terreno} = \{\text{llanura}, \text{meseta}, \text{colina}\}$$

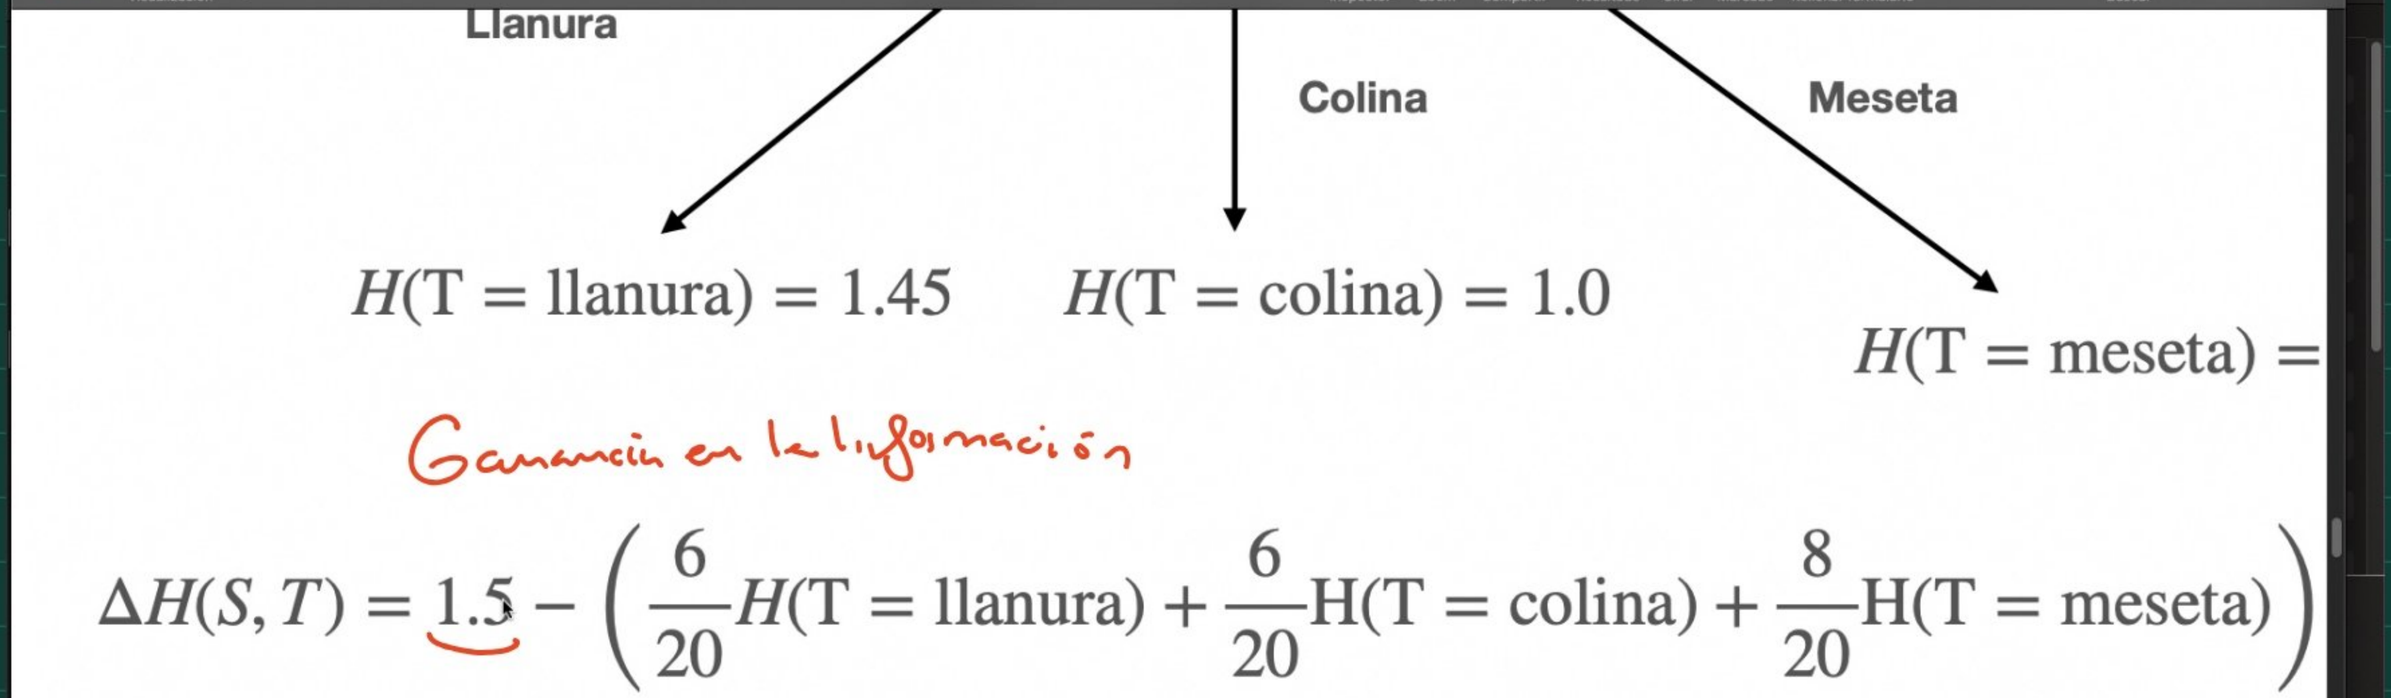
Cosecha / Terreno	Moderada	Optima	Pobre
Colinas	3	0	3
Llanura	3	2	1
Meseta	3	2	3

$$H(\text{T} = \text{colina}) = -\left(\frac{0}{6} \cdot \log_2\left(\frac{0}{6}\right) + \frac{3}{6} \cdot \log_2\left(\frac{3}{6}\right) + \frac{3}{6} \log_2\left(\frac{3}{6}\right)\right) = 1.0$$

$$H(\text{T} = \text{llanura}) = -\left(\frac{2}{6} \cdot \log_2\left(\frac{2}{6}\right) + \frac{1}{6} \cdot \log_2\left(\frac{1}{6}\right) + \frac{3}{6} \cdot \log_2\left(\frac{3}{6}\right)\right) = 1.45$$

$$H(\text{T} = \text{meseta}) = -\left(\frac{2}{8} \cdot \log_2\left(\frac{2}{8}\right) + \frac{3}{8} \cdot \log_2\left(\frac{3}{8}\right) + \frac{3}{8} \cdot \log_2\left(\frac{3}{8}\right)\right) = 1.56$$

Vista Previa Archivo Edición Visualización Ir Herramientas Ventana Ayuda
Mié 14 de oct 9:50 a.m.
07_arboles_ensamble_slides.pdf
Página 10 de 22
Visualización Inspector Zoom Compartir Resaltado Girar Marcado Rellenar formulario Buscar



Ganancia en la información

$$\Delta H(S,T) = 1.5 - \left(\frac{6}{20} H(\text{T} = \text{llanura}) + \frac{6}{20} \text{H}(\text{T} = \text{colina}) + \frac{8}{20} \text{H}(\text{T} = \text{meseta}) \right)$$

Machine Learning e Inferencia Bayesiana, Licenciatura en Inteligencia Artificial y Ciencia de Datos, Universidad de Guadalajara. M. en C. Iván Toledano Juárez.

Ganancia de información

Variable target

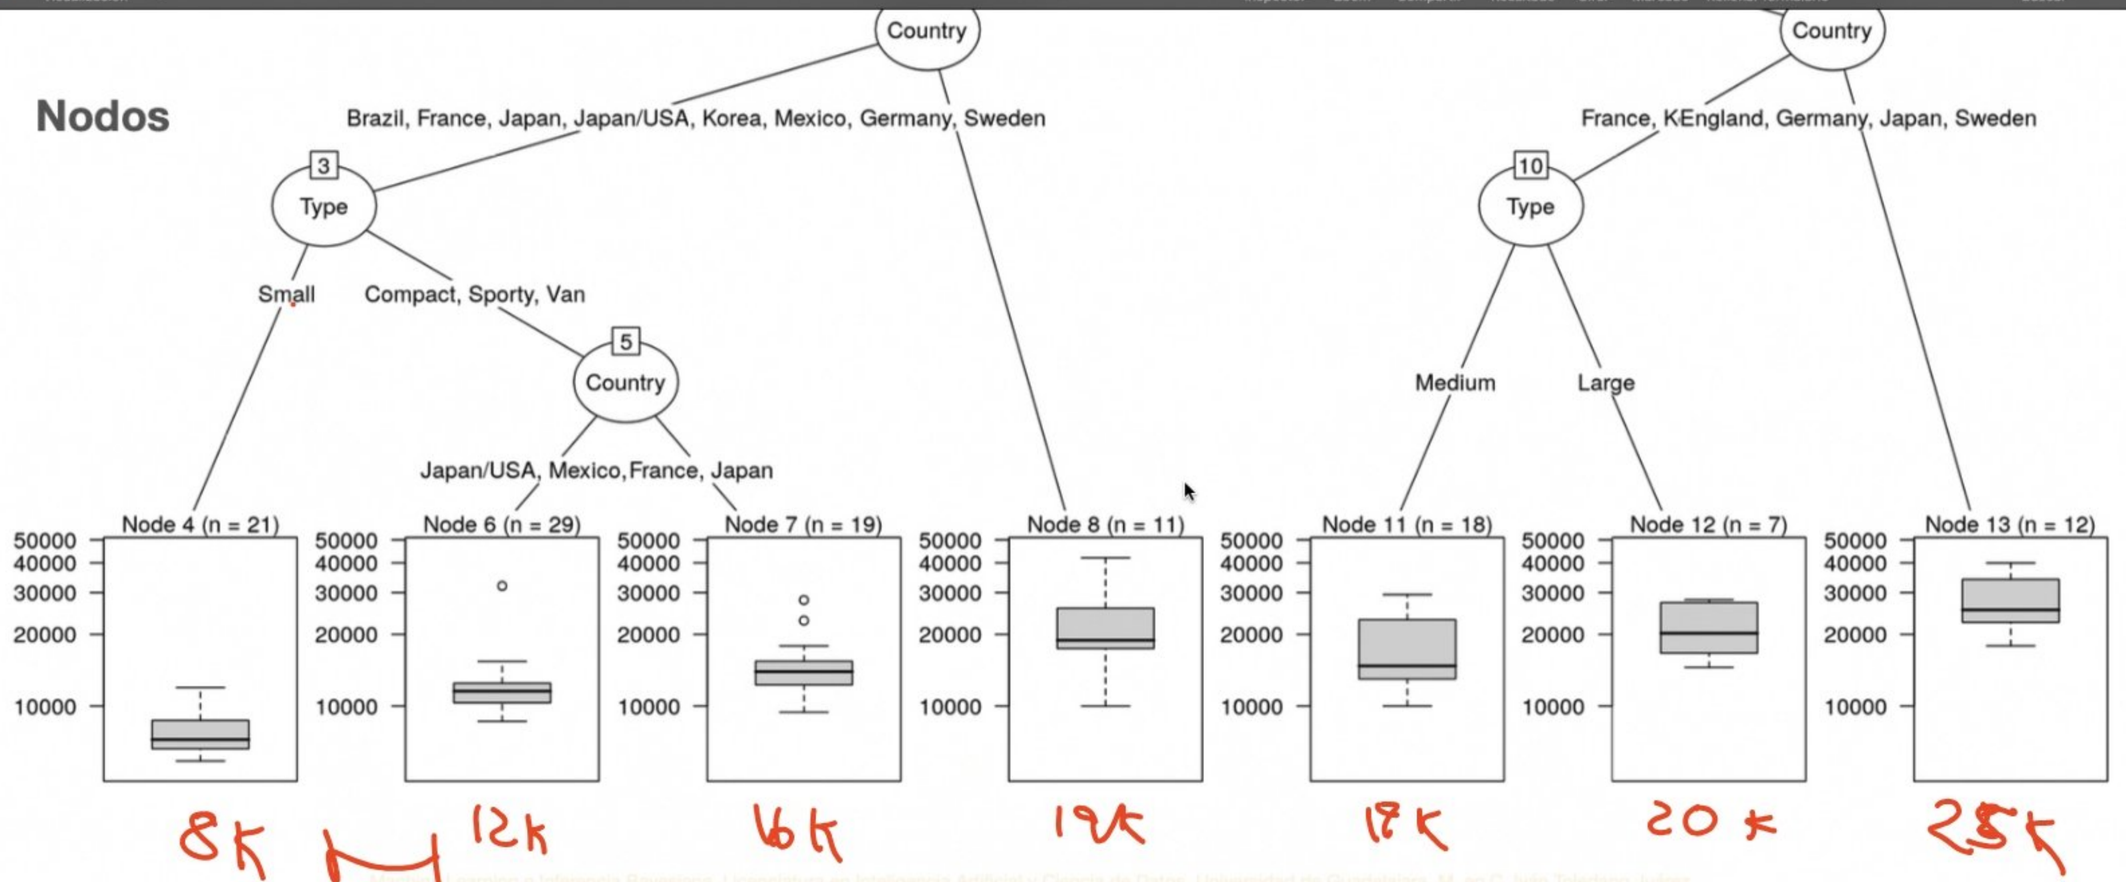
Macintosh HD › Usuarios › vanotole › Documento › Doctorado › MachineLe › Github › MachineLe › 07_arboles_ensamble › 07_arboles_ensamble_slides.pdf

R_2)

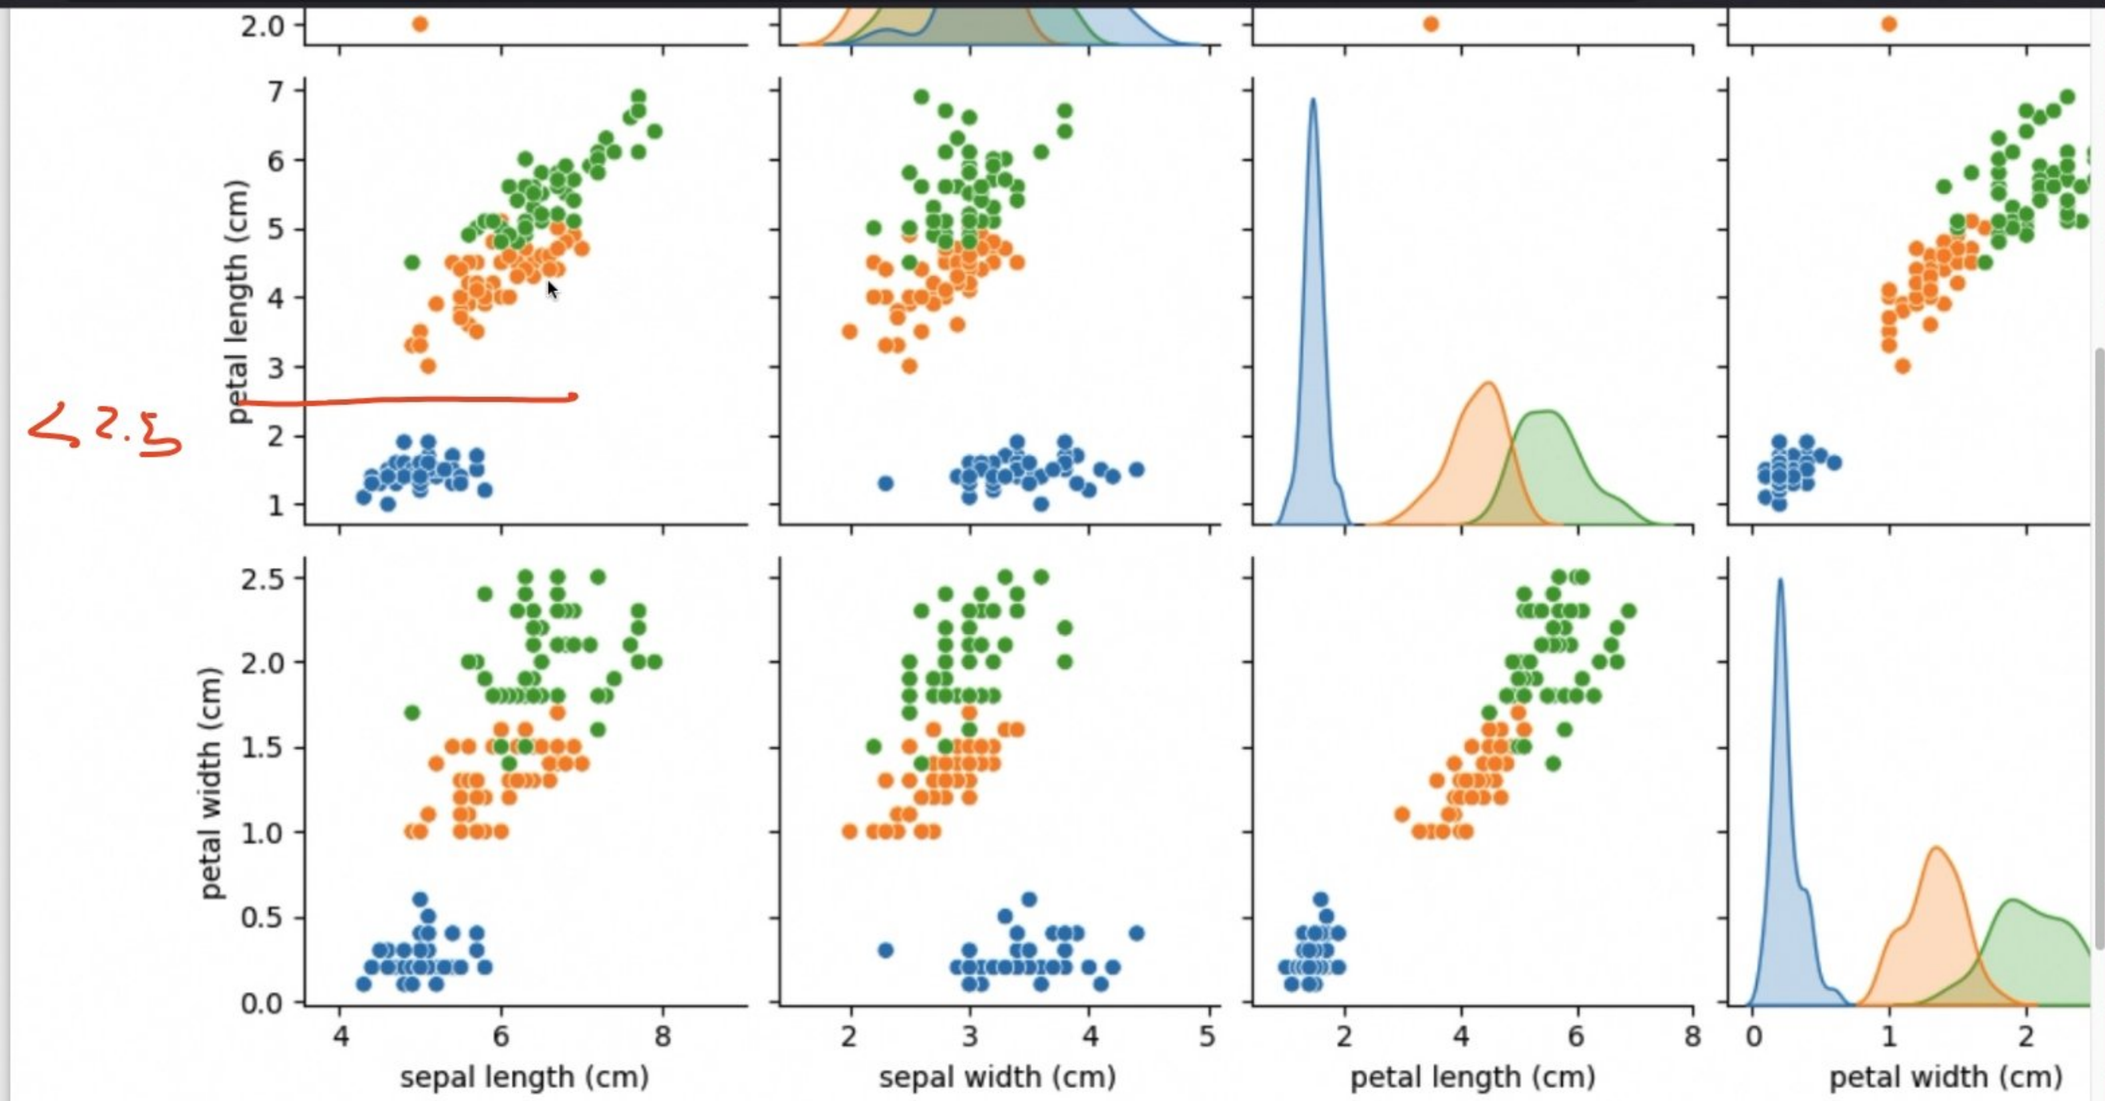
R_3)

R_n)

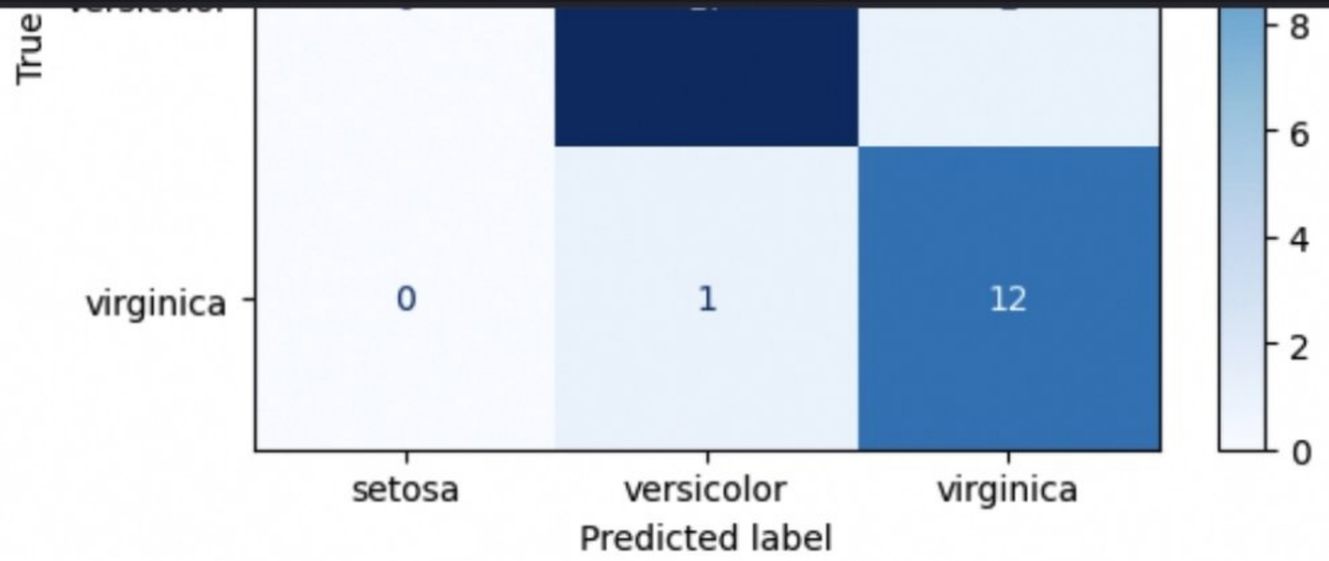
Nodos



rboles de regresión




```
[9]: # La lista de targets ya está precargada en los dataset de ejemplo de scikitlearn
     iris.target_names
```

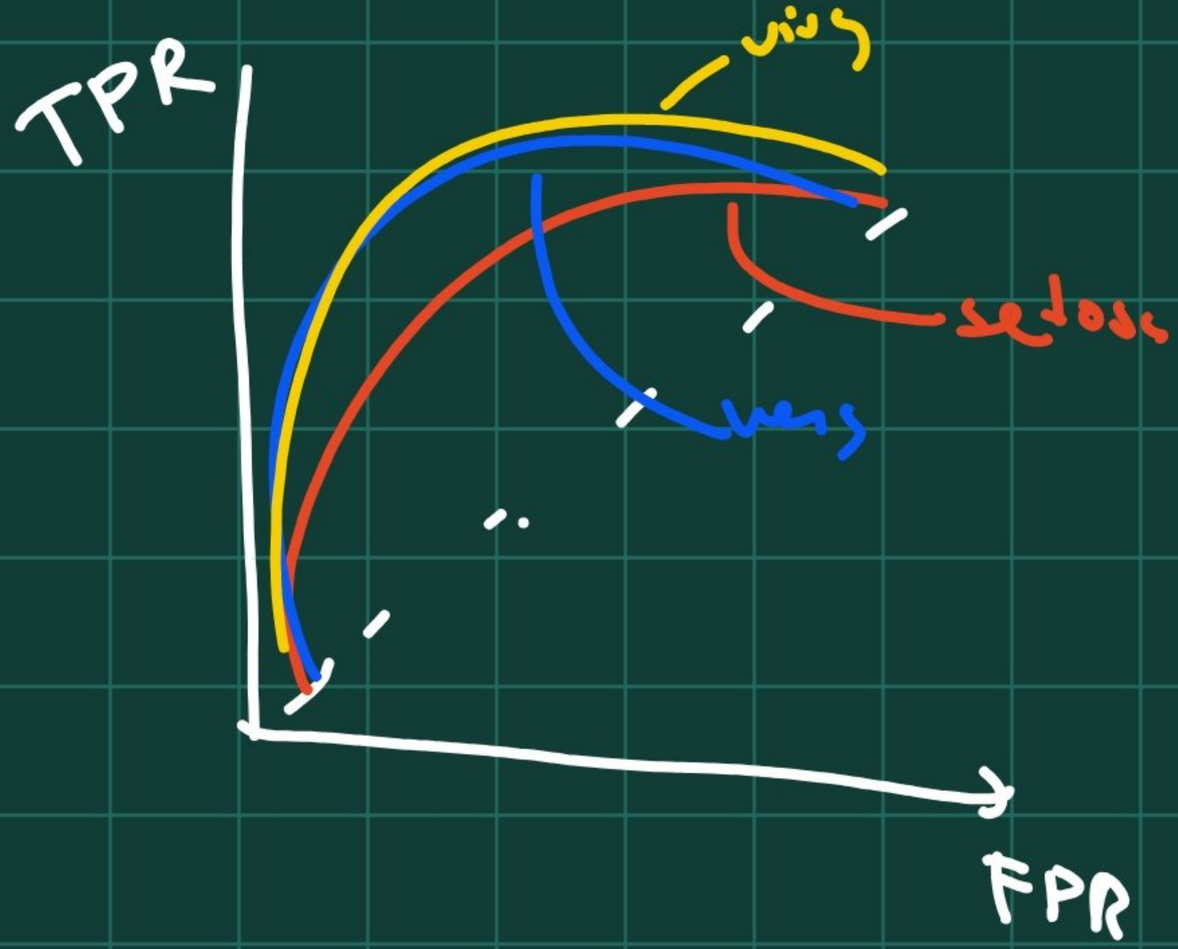


¿Por qué usamos la curva ROC en clasificación multiclase? ¶

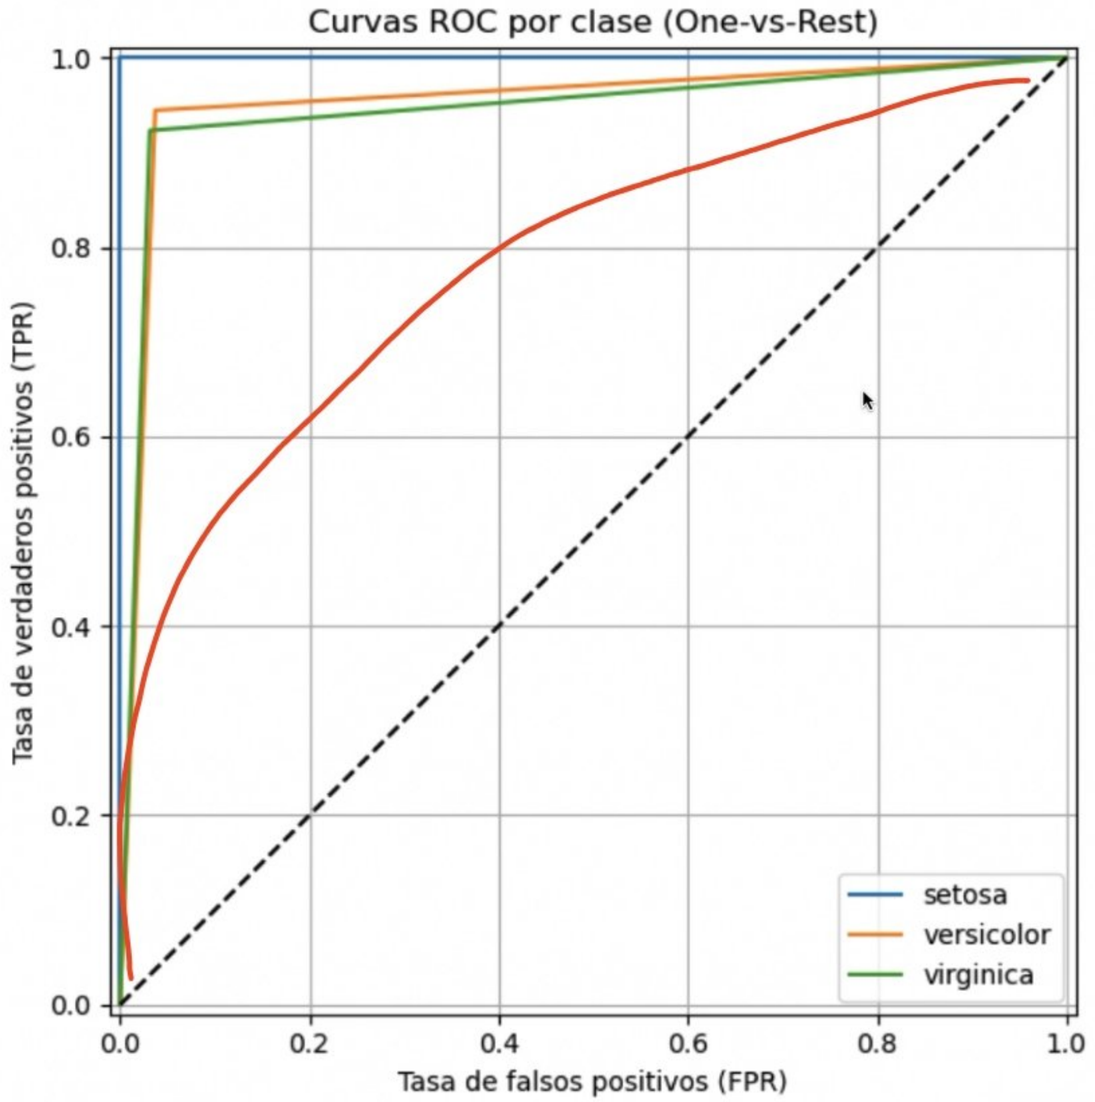
La curva ROC (Receiver Operating Characteristic) es una herramienta clásica para evaluar modelos de clasificación **binaria** entre la **tasa de verdaderos positivos** (TPR) y la **tasa de falsos positivos** (FPR) para diferentes umbrales de decisión.

Sin embargo, en el caso de problemas de **clasificación multiclase**, como el dataset *Iris* que contiene tres especies diferer curva ROC directamente. Para resolver esto, aplicamos una estrategia conocida como **One-vs-Rest (OvR)**, donde conside "clase positiva" y agrupamos las demás como "clase negativa". De este modo, generamos una curva ROC para cada clase cómo se comporta el modelo al distinguir cada una de ellas contra las demás.

En `scikit-learn`, esta estrategia está incorporada y facilita la evaluación multiclase mediante curvas ROC por clase. Pu oficial en la documentación de `scikit-learn`:



Setosa.
Versicolor.
Virg.


Curvas ROC por clase (One-vs-Rest)
Tasa de verdaderos positivos (TPR)
Tasa de falsos positivos (FPR)
0.0
0.2
0.4
0.6
0.8
1.0
setosa
versicolor
virginica