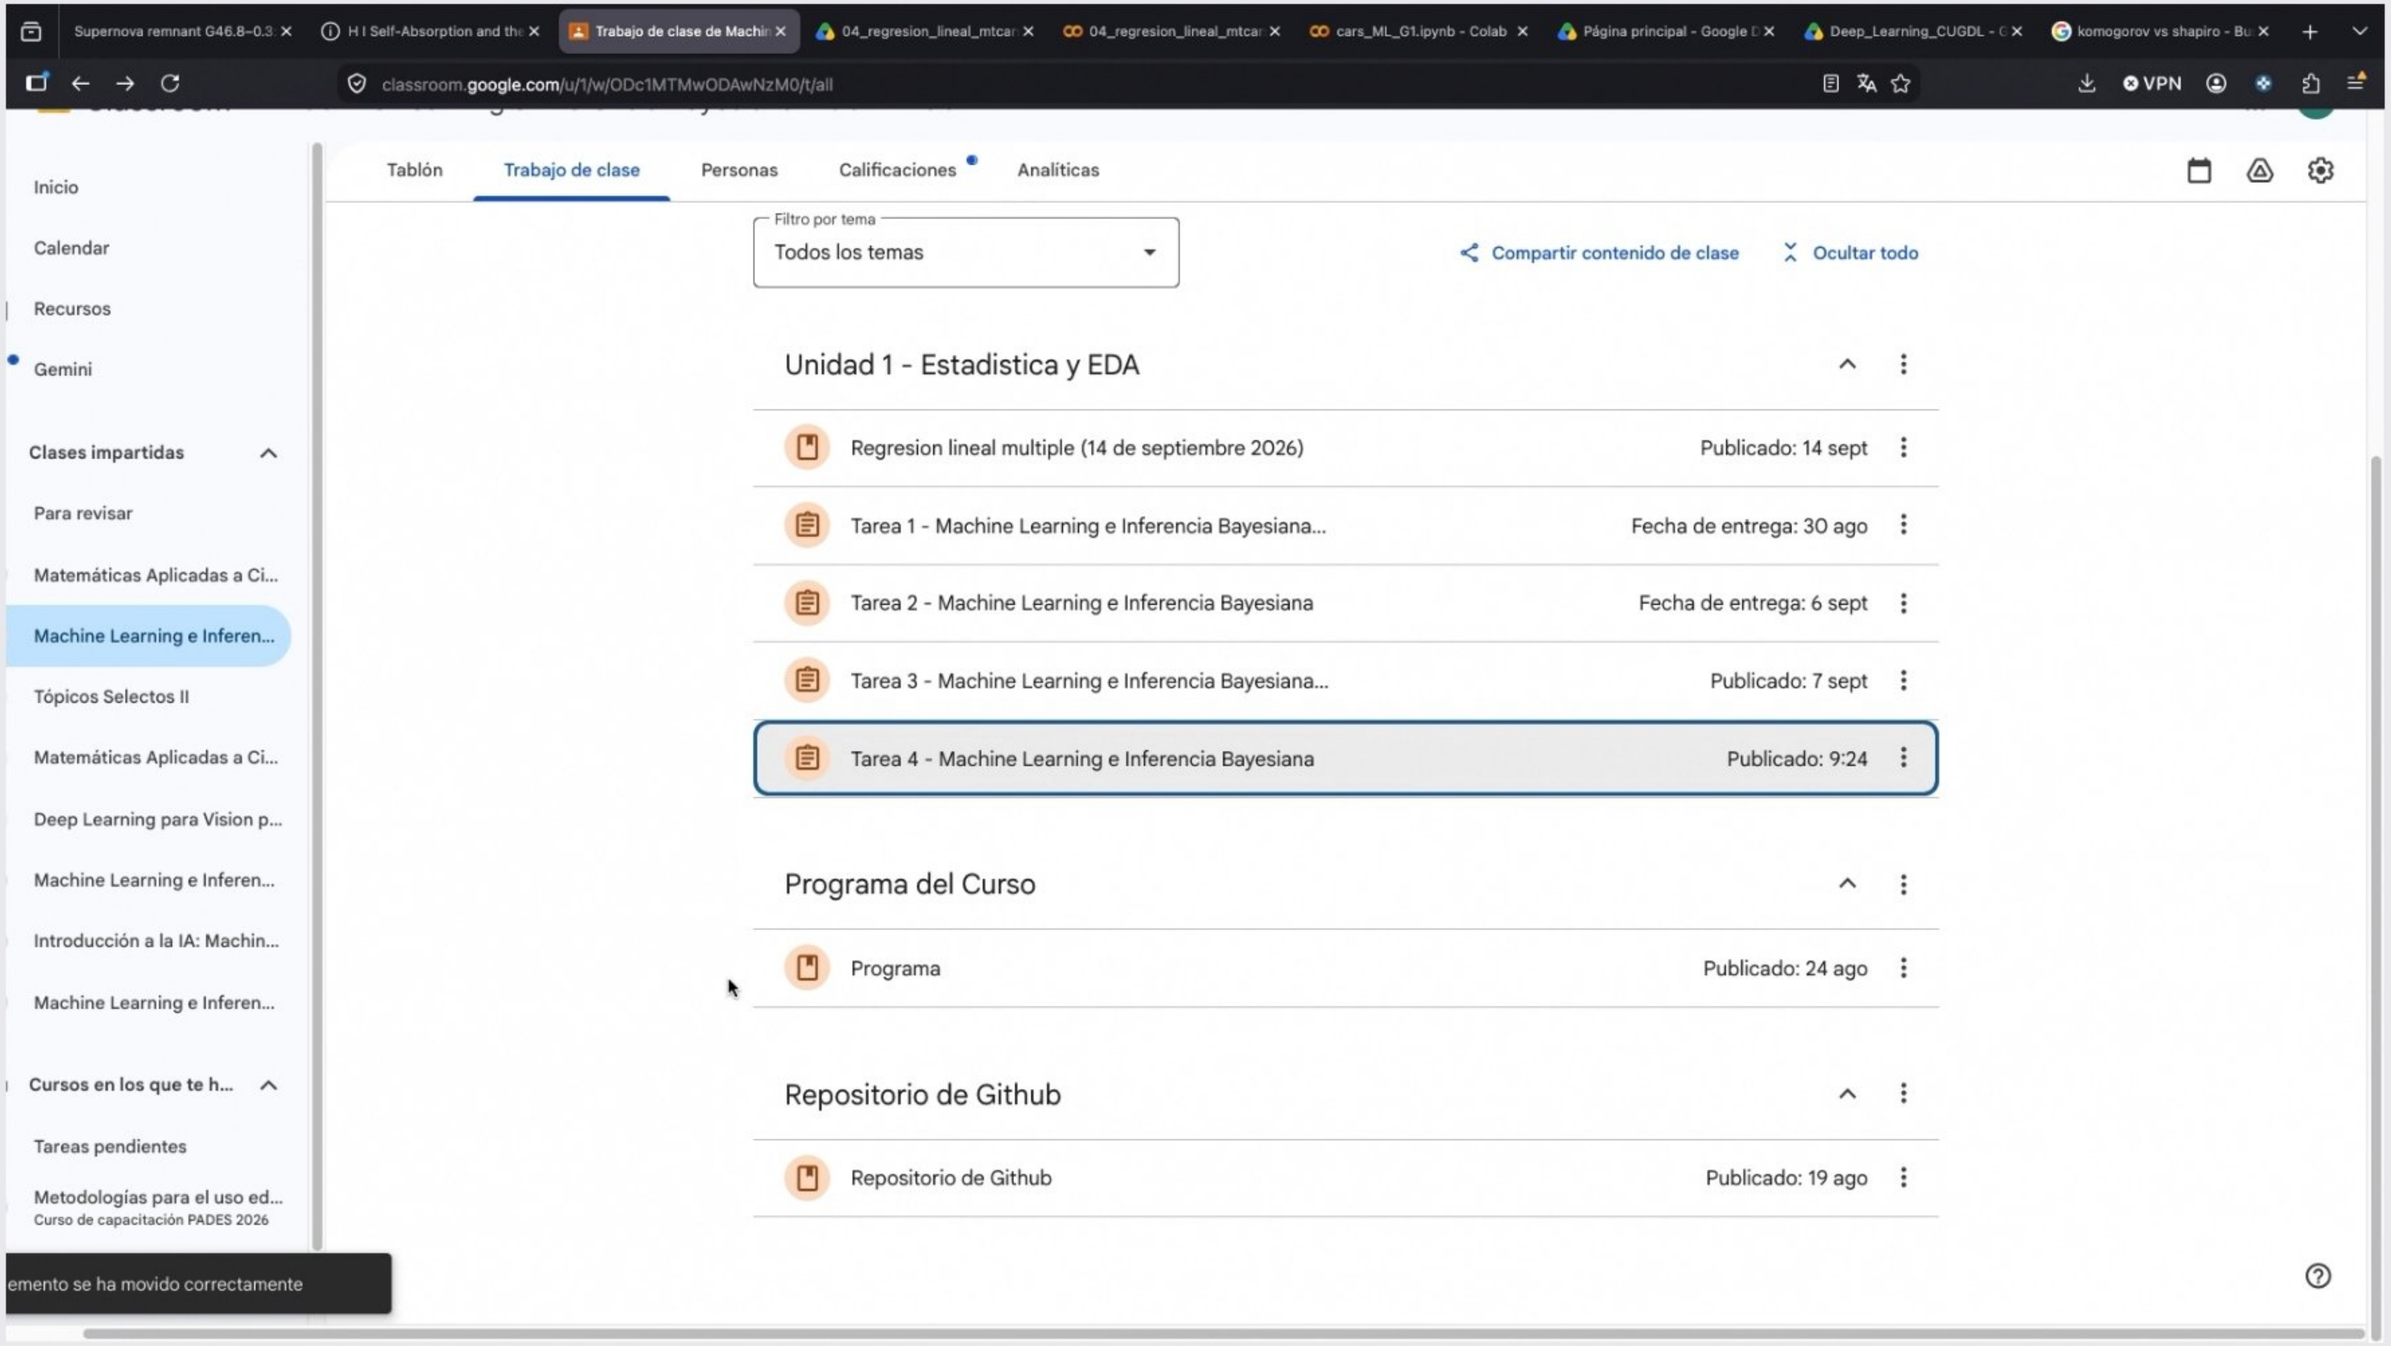

Supernova remnant G46.8–0.3
H I Self-Absorption and the
Trabajo de clase de Machin
04_regresion_lineal_mtcar
04_regresion_lineal_mtcar
cars_ML_G1.ipynb - Colab
Página principal - Google D
Deep_Learning_CUGDL - G
komogorov vs shapiro - Bu
classroom.google.com/u/1/w/ODc1MTMwODAwNzM0/t/all
VPN
Inicio
Calendar
Recursos
Gemini
Clases impartidas
Para revisar
Matemáticas Aplicadas a Ci...
Machine Learning e Inferen...
Tópicos Selectos II
Matemáticas Aplicadas a Ci...
Deep Learning para Vision p...
Machine Learning e Inferen...
Introducción a la IA: Machin...
Machine Learning e Inferen...
Cursos en los que te h...
Tareas pendientes
Metodologías para el uso ed...
Curso de capacitación PADES 2026
emento se ha movido correctamente
Tablón
Trabajo de clase
Personas
Calificaciones
Analíticas
Filtro por tema
Todos los temas
Compartir contenido de clase
Ocultar todo
Unidad 1 - Estadistica y EDA
Regresion lineal multiple (14 de septiembre 2026)
Publicado: 14 sept
Tarea 1 - Machine Learning e Inferencia Bayesiana...
Fecha de entrega: 30 ago
Tarea 2 - Machine Learning e Inferencia Bayesiana
Fecha de entrega: 6 sept
Tarea 3 - Machine Learning e Inferencia Bayesiana...
Publicado: 7 sept
Tarea 4 - Machine Learning e Inferencia Bayesiana
Publicado: 9:24
Programa del Curso
Programa
Publicado: 24 ago
Repositorio de Github
Repositorio de Github
Publicado: 19 ago

• Regresión Lineal

Modelo

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_m x_m$$

Función de Costo / Error

$$\mathcal{L} = \frac{1}{n} \sum_{i=1}^{n} (\hat{y}_i - y_i)^2$$

optimización

Evaluación

↳ R^2, MSE, RMSE, MAE, ...

Caso particular, simple

$$\hat{y} = \beta_0 + \beta_1 x$$

$$\beta_1 = \frac{\sigma_{xy}}{\sigma_x^2}, \quad \beta_0 = \bar{y} - \beta_1 \bar{x}$$

Solución Analítica (MCO)

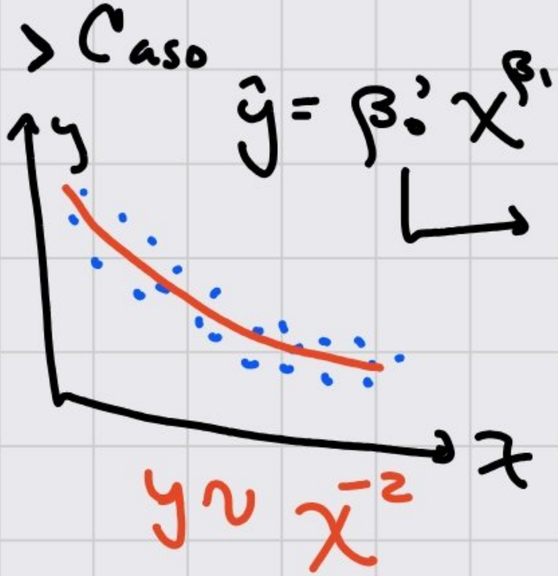
$$\beta = (X^T X)^{-1} X^T Y$$

Parámetros óptimos

- Transformaciones.

$\hat{y} = \beta_0 + \beta_1 x$ Lineal – Lineal

> Caso $\hat{y} = \beta_0' x^{\beta_1}$



$y \sim x^{-2}$

Log-Log

$$\ln(\hat{y}) = \ln(\beta_0' x^{\beta_1})$$

$$Y = \ln(\beta_0') + \ln(x^{\beta_1})$$

$$= \ln(\beta_0') + \beta_1 \ln(x)$$

β_0 x

$$Y = \beta_0 + \beta_1 x$$ Lineal

Propiedades

$\log(ab) = \log(a) + \log(b)$

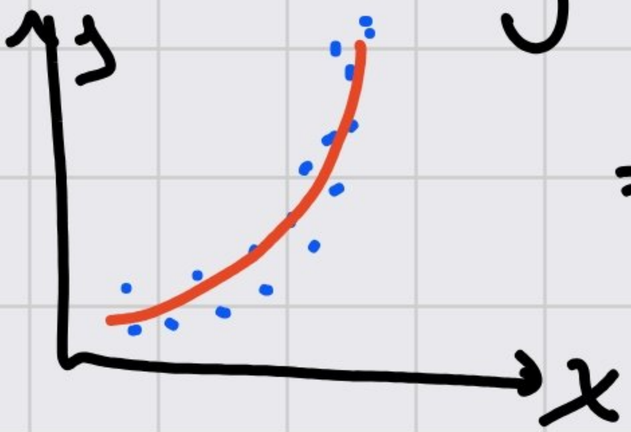
$\log(a^b) = b \cdot \log(a)$

$\beta_0 = \ln(\beta_0')$

Amplitud

$\beta_1 \longrightarrow$ potencia

> Caso



$$\hat{y} = \beta_0 \cdot e^{\beta_1 x}$$

Log - Lineal

$$\Rightarrow \ln(\hat{y}) = \ln(\beta_0 \cdot e^{\beta_1 x})$$

$$= \ln(\beta_0) + \ln(e^{\beta_1 x})$$

$$\underbrace{\ln(\hat{y})}_{Y} = \underbrace{\ln(\beta_0)}_{\beta_0} + \beta_1 x$$

$$Y = \beta_0 + \beta_1 x$$

$\beta_0 \rightarrow$ Amp.

$\beta_1 \rightarrow$ exponente

> Caso $\hat{y} = \ln(\beta_0 \cdot x^{\beta_1})$ Lineal-Log

$= \ln(\beta_0) + \beta_1 \ln(x)$

$$\boxed{Y = \beta_0 + \beta_1 X}$$ no cts.

Supernova remnant G46.8–0.3 | H I Self-Absorption and the | Trabajo de clase de Machin | 04_regresion_lineal_mtcar | 04_regresion_lineal_mtcar | cars_ML_G1.ipynb - Colab | Página principal - Google D | Deep_Learning_CUGDL - G | komogorov vs shapiro - Bu
classroom.google.com/u/1/w/ODc1MTMwODAwNzM0/t/all
VPN

características de 32 modelos de automóviles de diferentes marcas y tipos, principalmente de los años 1973-1974. Las variables registradas son las siguientes:

TARGET y

- **mpg**: Indica la eficiencia del consumo de combustible del vehículo en millas por galón.
- **cyl**: Número de cilindros del motor (4,6 u 8 cilindros).

X_1

- **disp**: La cilindrada o desplazamiento del motor en pulgadas cúbicas.

X_2

- **hp**: Potencia del motor en caballos de fuerza.

X_3

- **drat**: Relación entre el eje trasero (rear axle ratio).

X_4

- **wt**: Peso del automóvil en miles de libras (1=1000 libras).

X_5

- **qsec**: Tiempo en segundos que toma recorrer un cuarto de milla.
- **vs**: Tipo de motor (0=tipo V, 1=recto/línea).
- **am**: Tipo de transmisión (0 = automática, 1 = manual).
- **gear**: Número de marchas o velocidades en la transmisión (3,4, ó 5).
- **carb**: Número de carburadores.

En la siguiente actividad utilizaremos este dataset para crear varios modelos de regresión lineal

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots$$

$y \in \mathbb{R}$

x_1 → Numéricas

x_2 → Categóricas (Codificadas)

$$E_j[mpg] = \beta_0 + \beta_1 \cdot cyl \begin{cases} 4 \\ 6 \\ 8 \end{cases}$$

cyl	→	cyl_4	cyl_6	cyl_8
4		1	0	0
6		0	1	0
8		0	0	1
8		0	0	1
4		1	0	0
⋮		⋮	⋮	⋮

$$mpg = \beta_0 + \beta_1 cyl_4 + \beta_2 cyl_6 + \beta_3 cyl_8$$

Corolla $mpg = 8 + 10$

Mustang V8 $mpg = 8 + 6$

Supernova remnant G46.8- | H I Self-Absorption and | Trabajo de clase de Ma | 04_regresion_lineal_m | 04_regresion_lineal_m | 04_regresion_lineal_m | cars_ML_G1.ipynb - Co | Página principal - Goog | Deep_Learning_CUGDL | komogorov vs shapiro
classroom.google.com/u/1/w/ODc1MTMwODAwNzM0/t/all
VPN

- Si el p-valor es mayor o igual a α, no se rechaza la hipótesis nula, lo que sugiere que no hay evidencia estadística suficiente para afirmar que β_i es diferente de cero.

Esta prueba de hipótesis ayuda a interpretar la relevancia de cada predictor en el modelo. Denominaremos como un **modelo válido** aquel en el cual **todas** sus variables predictoras son significativamente diferentes de cero.

Ejercicio 1:
Encontrar el mejor modelo válido para explicar el rendimiento (mpg) de un auto, haciendo uso de 3 de las variables continuas originales del conjunto de datos: *disp, hp, drat, wt, qsec.* Para este ejercicio se consideran como válidos coeficientes β_i cuyo p-valor asociado de la prueba de hipótesis se mayor a 0.1, es decir, se considera un nivel de significancia de 10 %.

Ejercicio 2:
Escribir la ecuación de la recta del mejor modelo encontrado, escribiendo explícitamente sus variables y coeficientes. Interpretar con sus palabras el efecto de cada variable independiente sobre la variable dependiente.

vars = ["disp", "hp", "drat", "wt", "qsec"]

Modelos de 3 vars. → Combinaciones $${}_nC_k = \frac{n!}{k!(n-k)!}$$

$$\Rightarrow {}_5C_3 = \frac{5!}{3!(5-3)!} = \frac{5 \cdot 4 \cdot (3 \cdot 2 \cdot 1)}{(3 \cdot 2 \cdot 1)(2 \cdot 1)}$$

$$= \frac{5 \cdot 4}{2} = 10$$

disp, hp, wt

disp, hp, qsec

⋮

⋮

Supernova remnant G46.8- | H I Self-Absorption and | Trabajo de clase de Ma | 04_regresion_lineal_m | 04_regresion_lineal_m | 04_regresion_lineal_m | cars_ML_G1.ipynb - Co | Página principal - Goog | Deep_Learning_CUGDL | komogorov vs shapiro
colab.research.google.com/drive/1TcaO1eqhbjzdEko_fBWBM9GOFbv38wyz?authuser=1#scrollTo=b5024bda 120% VPN

Dep. Variable:	mpg	R-squared:	0.837
Model:	OLS	Adj. R-squared:	0.820
Method:	Least Squares	F-statistic:	47.93
Date:	Mon, 21 Sep 2026	Prob (F-statistic):	3.72e-11
Time:	16:02:40	Log-Likelihood:	-73.352
No. Observations:	32	AIC:	154.7
Df Residuals:	28	BIC:	160.6
Df Model:	3		
Covariance Type:	nonrobust		

$H_0: \beta = 0$

$H_1: \beta \neq 0$

$\alpha = 0.05$

pvalor $> \alpha$ No rechazo H_0

pvalor $< \alpha$ Rechazo H_0

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	11.3945 (β_0)	8.069	1.412	0.169	-5.134	27.923
drat	1.6561 (β_1)	1.227	1.350	0.188	-0.857	4.169
wt	-4.3978 (β_2)	0.678	-6.485	0.000	-5.787	-3.009
qsec	0.9462 (β_3)	0.262	3.616	0.001	0.410	1.482

Vars x

C.I 95%

Omnibus:	2.969	Durbin-Watson:	1.859
Prob(Omnibus):	0.227	Jarque-Bera (JB):	2.466
Skew:	0.673	Prob(JB):	0.291
Kurtosis:	2.806	Cond. No.	334.

Supernova remnant G4 | H I Self-Absorption | Trabajo de clase de | 04_regresion_lineal | 04_regresion_lineal | 04_regresion_lineal | cars_ML_G1.ipynb | Página principal - G | Deep_Learning_CU | komogorov vs shapi | 02 perceptron limite
colab.research.google.com/drive/1TcaO1eqhbjzdEko_fBWBM9GOFbv38wyz?authuser=1#scrollTo=b5024bda 120% VPN

Intercept	19.3443	6.371	3.036	0.005	6.294	32.394
disp	-0.0192	0.009	-2.052	0.050	-0.038	-3.58e-05
hp	-0.0312	0.013	-2.340	0.027	-0.059	-0.004
drat	2.7150	1.487	1.825	0.079	-0.332	5.762

$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3$

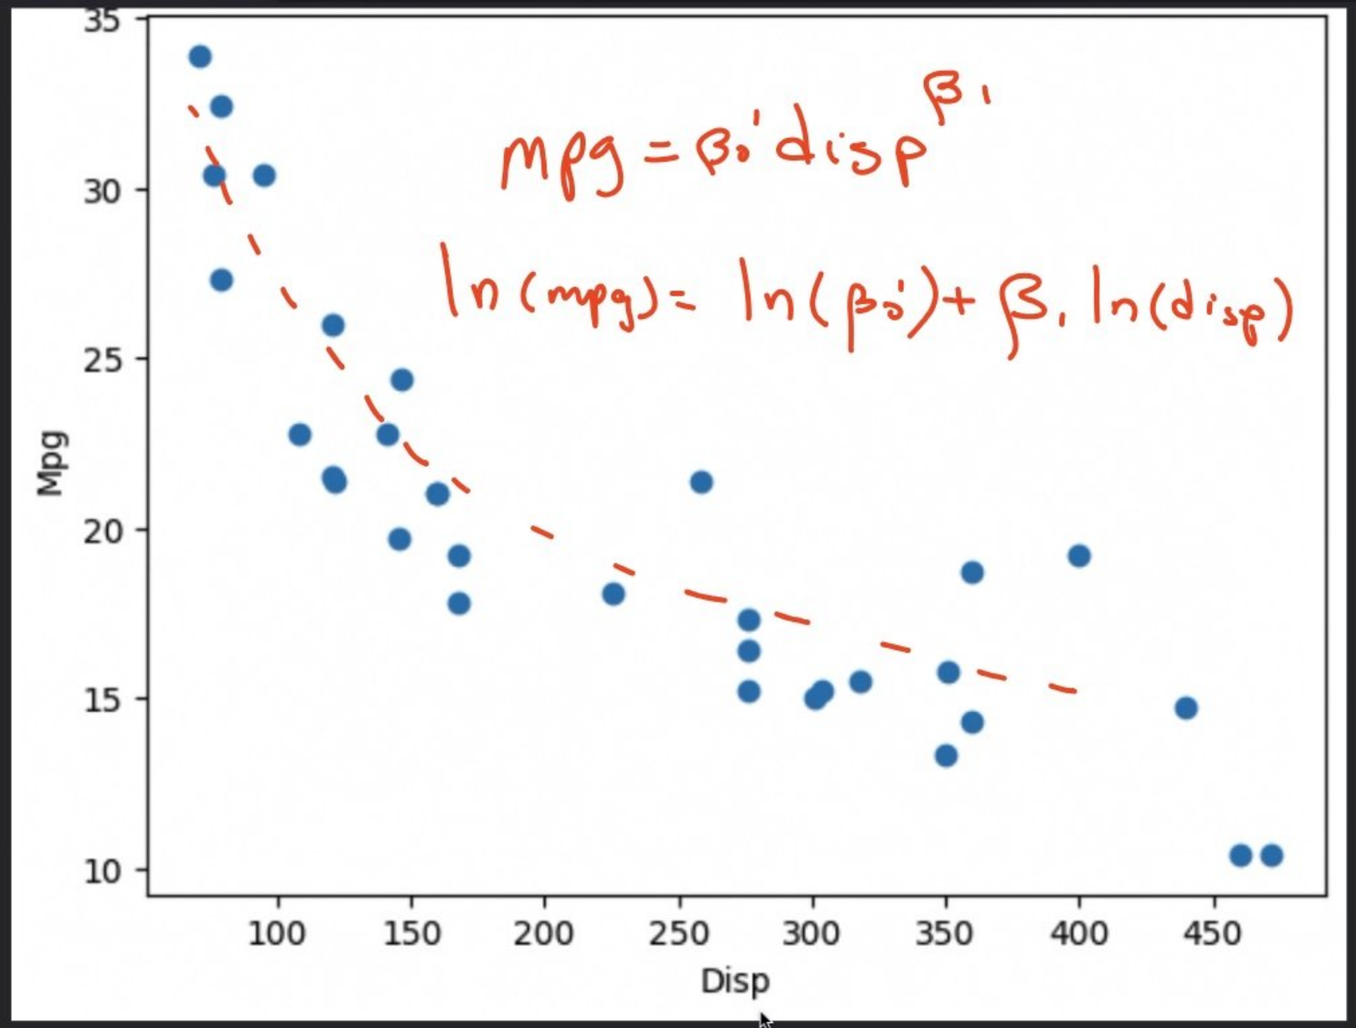
Omnibus:	3.840	Durbin-Watson:	1.708
Prob(Omnibus):	0.147	Jarque-Bera (JB):	3.032
Skew:	0.754	Prob(JB):	0.220
Kurtosis:	3.005	Cond. No.	3.74e+03

$mpg = 19.3 + (-0.019) \cdot disp + (-0.03) \cdot hp + (2.71) \cdot drat$

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specif
[2] The condition number is large, 3.74e+03. This might indicate that there are strong multicollinearity or other numerical problems.

OLS Regression Results

Dep. Variable:	mpg	R-squared:	0.827
Model:	OLS	Adj. R-squared:	0.808
Method:	Least Squares	F-statistic:	44.57
Date:	Mon, 21 Sep 2026	Prob (F-statistic):	8.65e-11




```
# Gráfica de los datos antes de la transformaciónç

plt.scatter(y=df_cars['mpg'],
```

[52] ✓ 0s

```
lm.summary()
```

OLS Regression Results

Dep. Variable:	ln_mpg	**R-squared:**	0.821
Model:	OLS	**Adj. R-squared:**	0.815
Method:	Least Squares	**F-statistic:**	137.3
Date:	Mon, 21 Sep 2026	**Prob (F-statistic):**	1.01e-12
Time:	16:23:37	**Log-Likelihood:**	21.369
No. Observations:	32	**AIC:**	-38.74
Df Residuals:	30	**BIC:**	-35.81
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	5.3810	0.208	25.866	0.000	4.956	5.806
ln_disp	-0.4586	0.039	-11.719	0.000	-0.538	-0.379

Omnibus:	2.424	**Durbin-Watson:**	1.769
Prob(Omnibus):	0.298	**Jarque-Bera (JB):**	1.534
Skew:	0.528	**Prob(JB):**	0.464
Kurtosis:	3.182	**Cond. No.**	50.5

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

$\ln(mpg) = \ln(\beta_0') + \beta_1 \ln(disp)$

$5.38 \quad -0.46$

$mpg = e^{5.38} \, disp^{-0.46}$

Graficamos la recta que sale de esta regresión.

Variables Terminal

```
print('Probablemente no es gaussiano')
```

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                    mpg   R-squared:                       0.775
Model:                            OLS   Adj. R-squared:                  0.751
Method:                 Least Squares   F-statistic:                     32.15
Date:                Mon, 21 Sep 2026   Prob (F-statistic):           3.28e-09
Time:                        16:27:24   Log-Likelihood:                -78.510
No. Observations:                  32   AIC:                             165.0
Df Residuals:                      28   BIC:                             170.9
Df Model:                           3
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
Intercept     19.3443      6.371      3.036      0.005       6.294      32.394
disp          -0.0192      0.009     -2.052      0.050      -0.038   -3.58e-05
hp            -0.0312      0.013     -2.340      0.027      -0.059      -0.004
drat           2.7150      1.487      1.825      0.079      -0.332       5.762
==============================================================================
Omnibus:                        3.840   Durbin-Watson:                   1.708
Prob(Omnibus):                  0.147   Jarque-Bera (JB):                3.032
Skew:                           0.754   Prob(JB):                        0.220
Kurtosis:                       3.005   Cond. No.                     3.74e+03
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
[2] The condition number is large, 3.74e+03. This might indicate that there are
strong multicollinearity or other numerical problems.

Error estándar residual (rmse) =  3.008
```

Distribución (normalizada) de los residuos del modelo

Modelo 3 vars. (disp, hp, drat)

$mpg = \beta_0 + \beta_1 \cdot disp + \beta_2 \cdot hp + \beta_3 \cdot drat$

$R^2_{adj.} = 0.75$ RMSE = 3.008 mpg

Modelo 1 var.

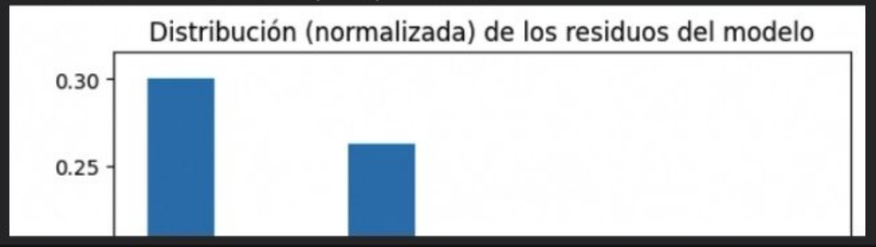
$mpg = \beta_0 + \beta_1 \cdot disp^{-0.96}$

$R^2_{adj} = 0.846$ RMSE = 2.37

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                    mpg   R-squared:                       0.851
Model:                            OLS   Adj. R-squared:                  0.846
Method:                 Least Squares   F-statistic:                     171.0
Date:                Mon, 21 Sep 2026   Prob (F-statistic):           6.31e-14
Time:                        16:29:13   Log-Likelihood:                -71.940
No. Observations:                  32   AIC:                             147.9
Df Residuals:                      30   BIC:                             150.8
Df Model:                           1
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
Intercept     -0.1547      1.604     -0.096      0.924      -3.430       3.120
disp_pow_m0_45   220.5102     16.861     13.078      0.000     186.076     254.944
==============================================================================
Omnibus:                        2.252   Durbin-Watson:                   1.925
Prob(Omnibus):                  0.324   Jarque-Bera (JB):                2.019
Skew:                           0.531   Prob(JB):                        0.364
Kurtosis:                       2.377   Cond. No.                         40.6
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Error estándar residual (rmse) =  2.367
```



Supernova remnant G4 | H I Self-Absorption | Trabajo de clase de | 04_regresion_lineal | 04_regresion_lineal | 04_regresion_lineal | cars_ML_G1.ipynb | Página principal - G | Deep_Learning_CU | komogorov vs shapi | 02 perceptron limite
classroom.google.com/u/1/w/ODc1MTMwODAwNzM0/t/all
VPN

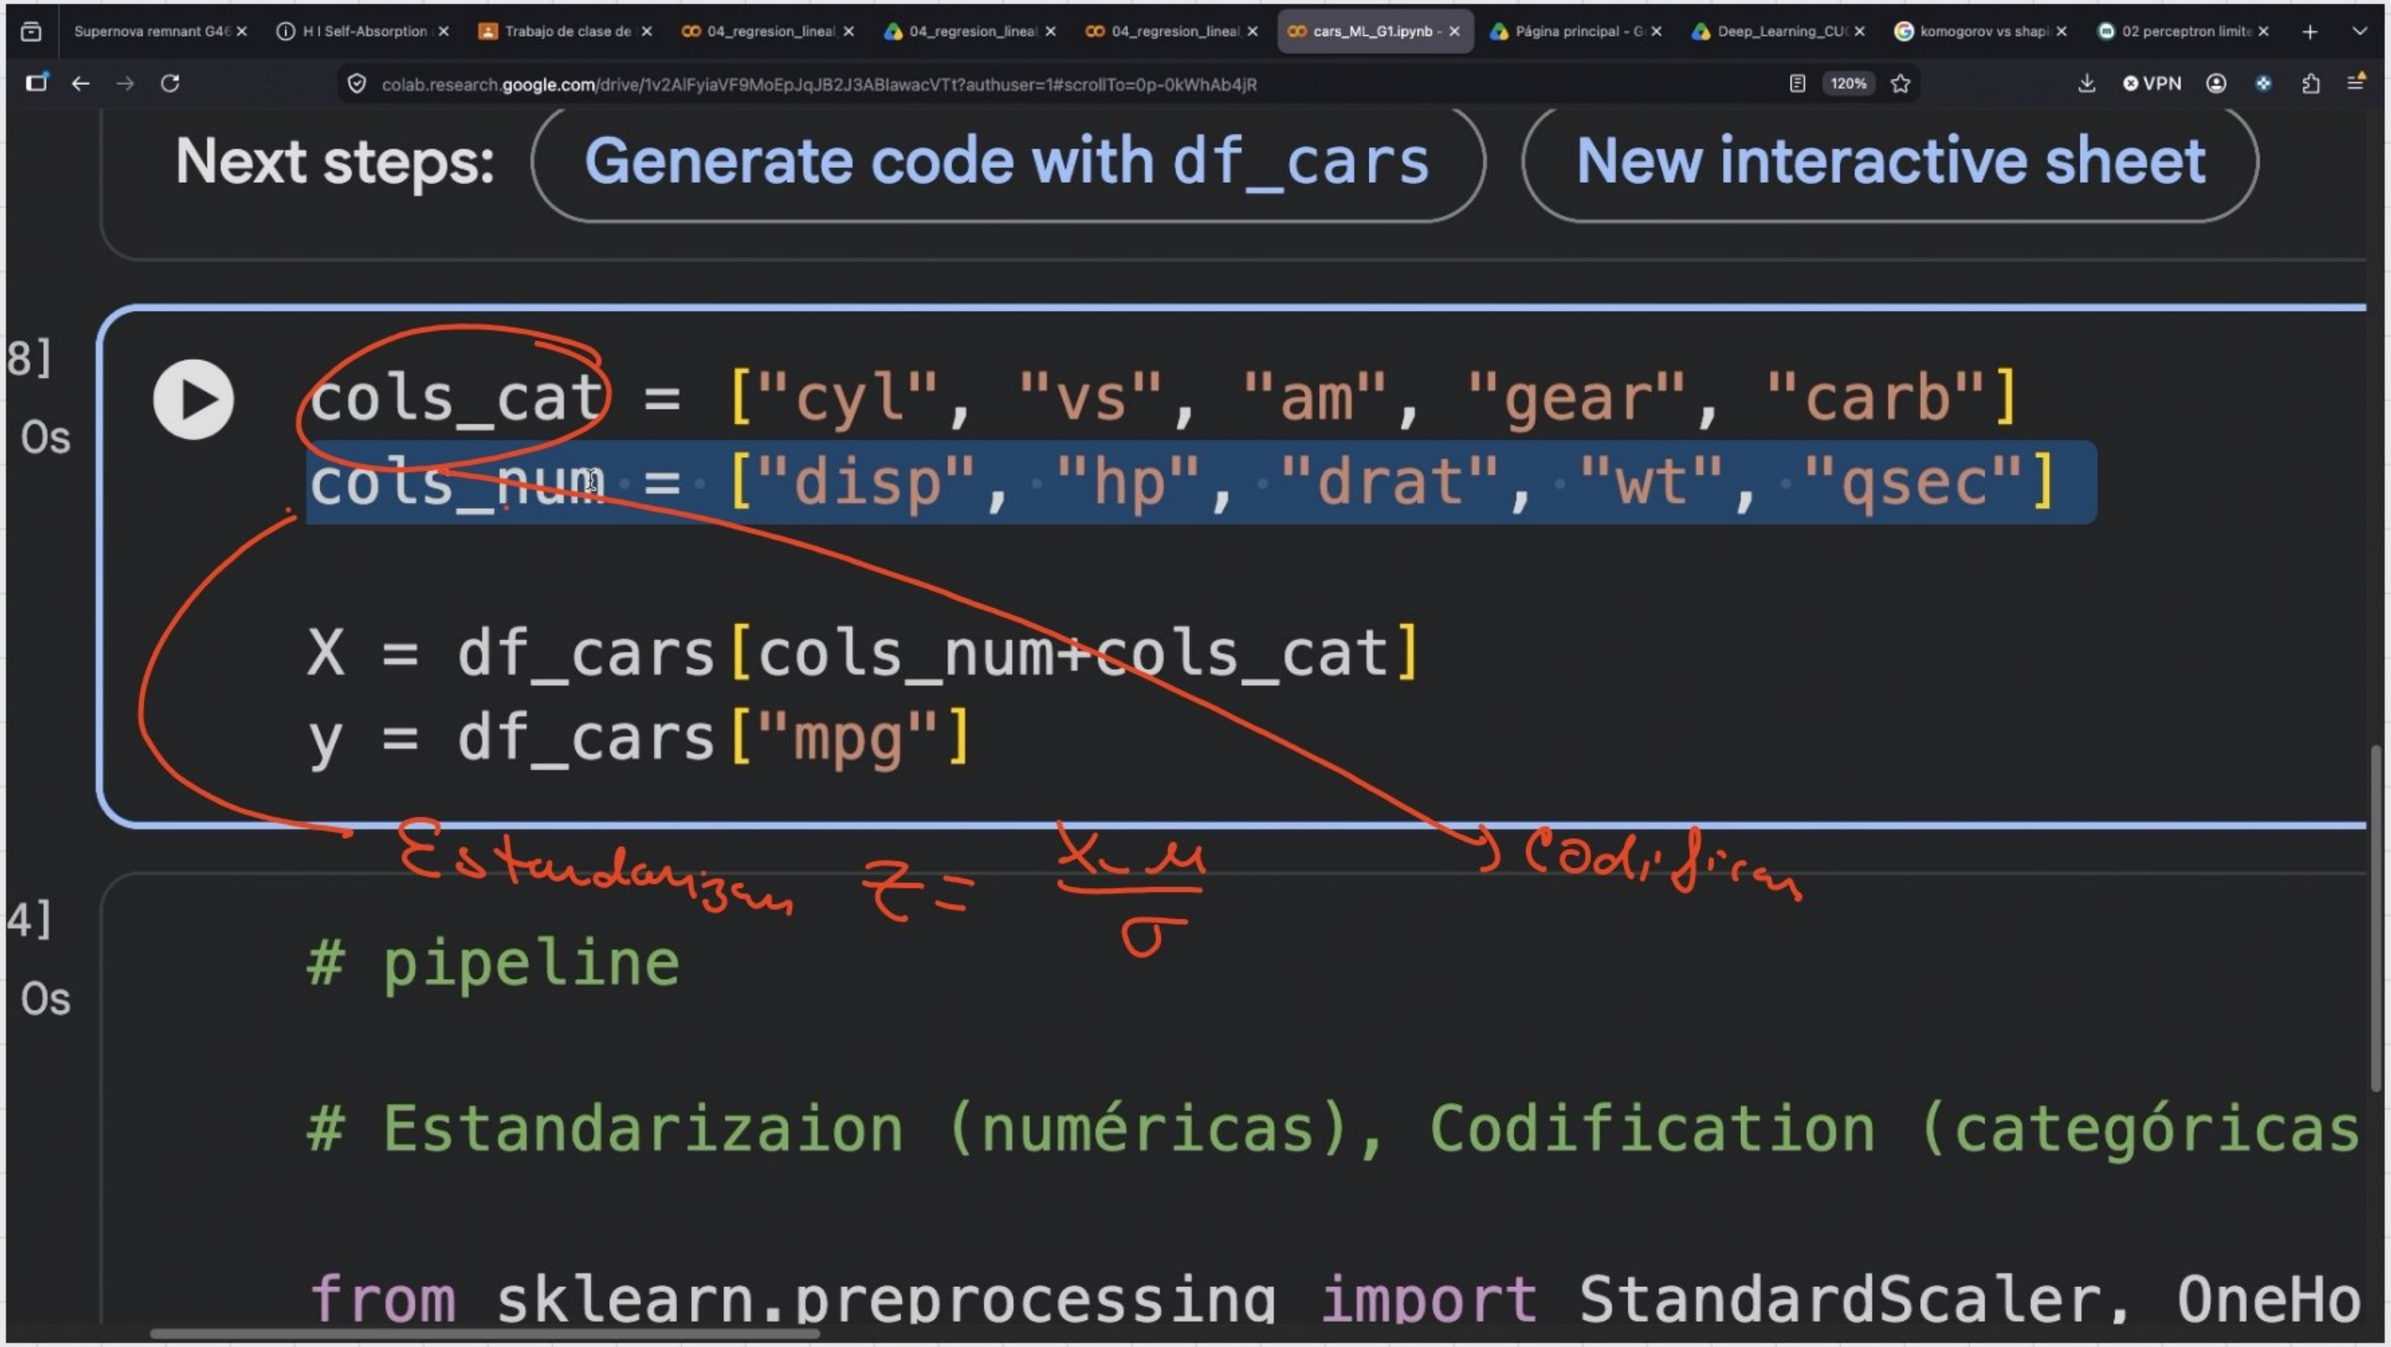
sola variable $(\text{disp})^{-0,46}$ también siguen una distribución normal, y verifica si los residuos son normales sin aplicar esta transformación. Finalmente, si cambiamos el nivel de significancia a 0.1 ¿Se mantienen las mismas conclusiones?

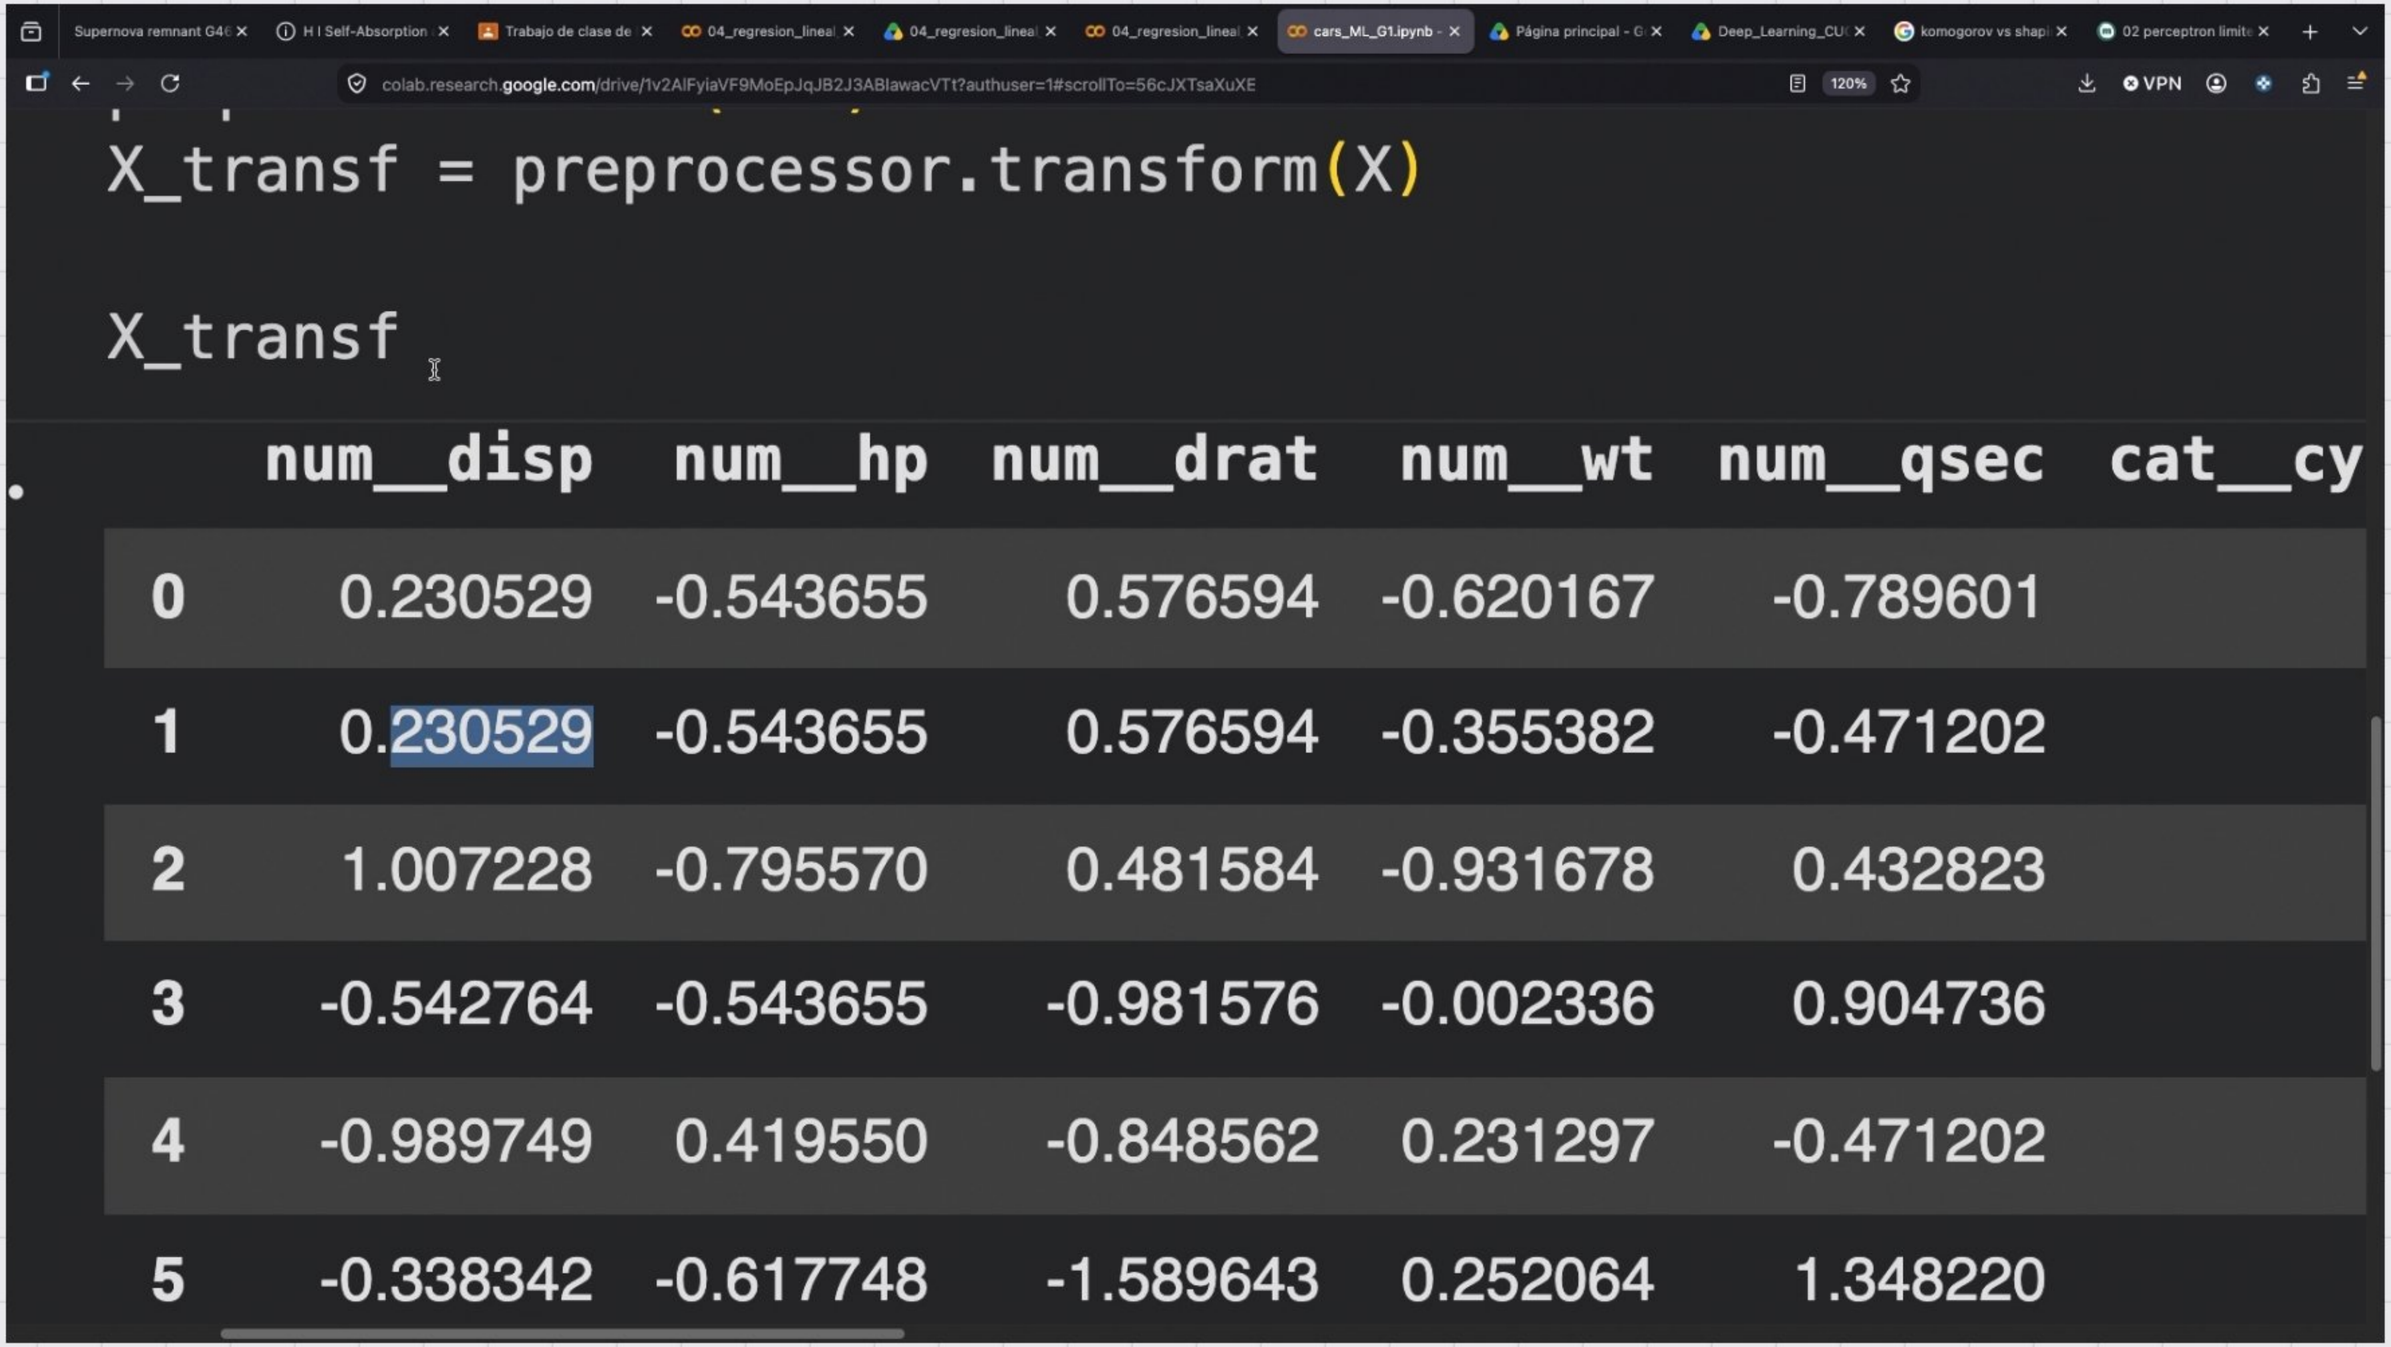
Ejercicio 5:

Concluye si el modelo de tres variables obtenido es adecuado para explicar la variable de rendimiento del auto (mpg). ¿Qué ajustes propondrías para mejorar el modelo en términos de precisión y reducción de varianza? Utiliza toda la información obtenida en los ejercicios anteriores, resumiéndola en tus propias palabras. **OPCIONAL:** Experimenta con todas las variables disponibles en el conjunto de datos para intentar encontrar un modelo mejor. Puedes emplear pruebas adicionales a las mencionadas para respaldar tus conclusiones.

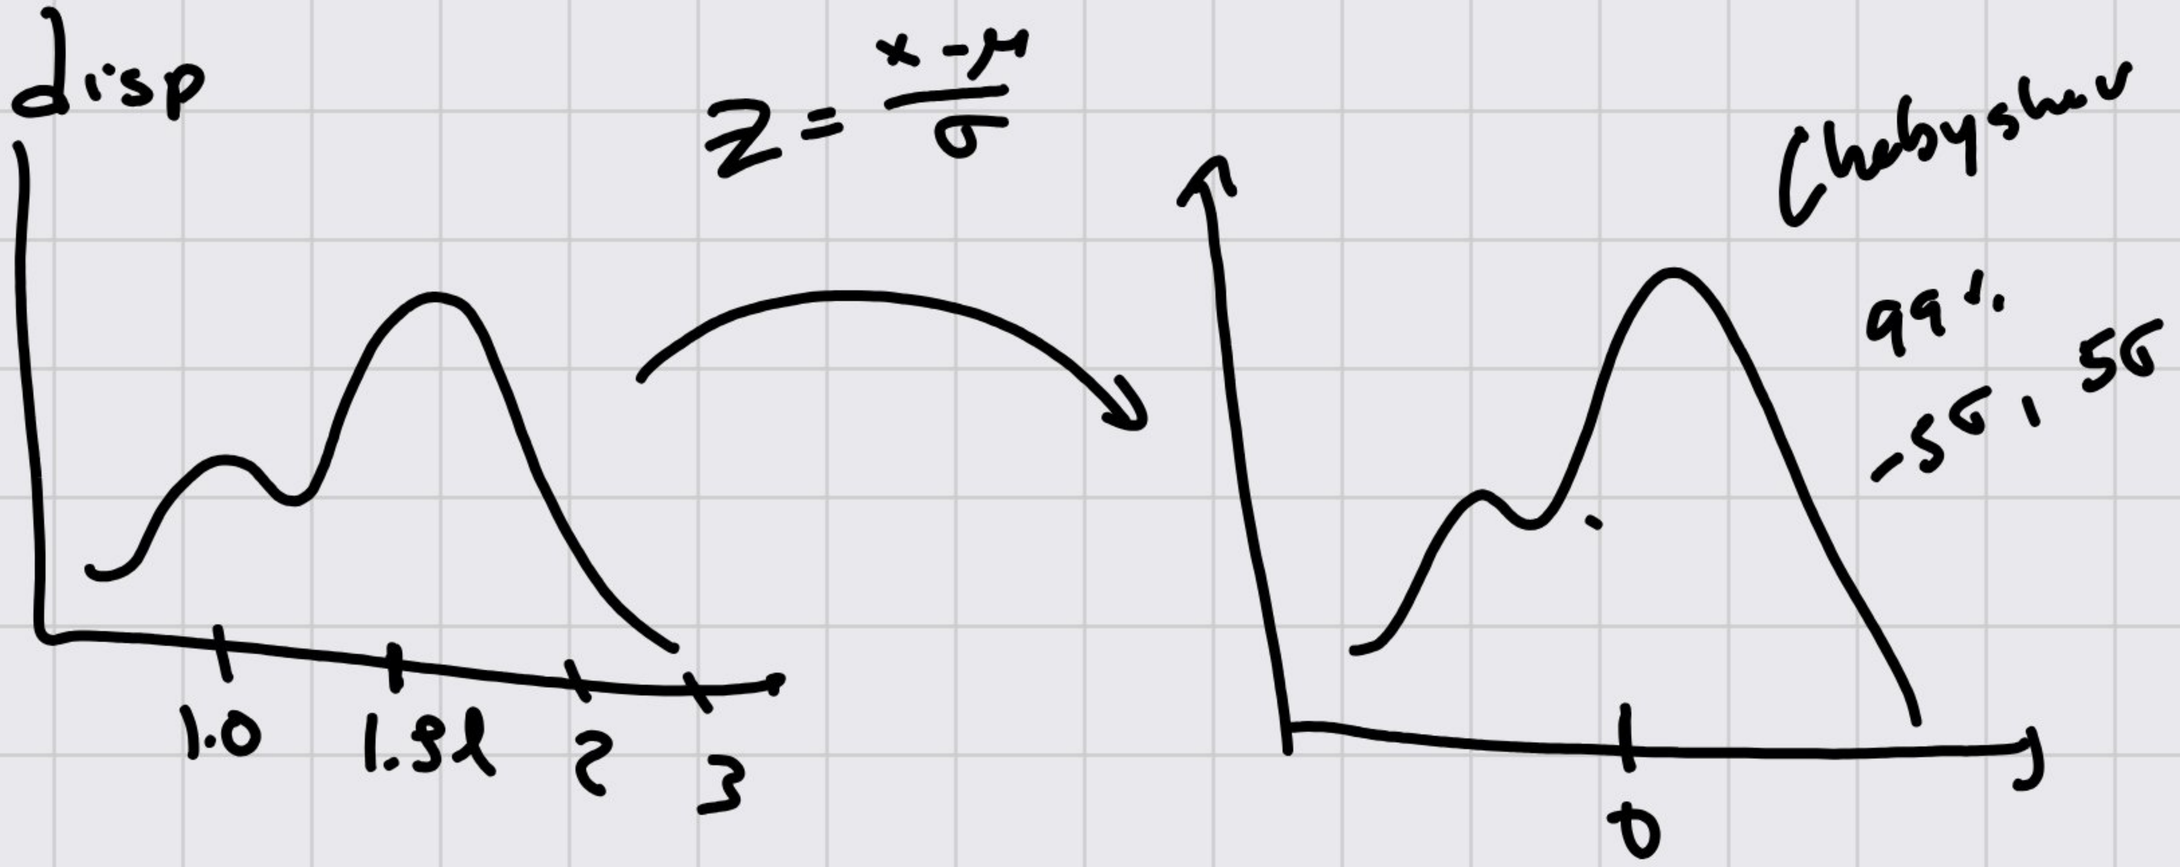
$$mpg = \beta_1 disp^{-0.46} + \beta_2 hp^{-0.5} + \beta_3 e^{wt}$$

hp^2 hp^{-1} $\sqrt{hp}$ $\sin(hp)$


Supernova remnant G4
H I Self-Absorption
Trabajo de clase de
04_regresion_lineal
04_regresion_lineal
04_regresion_lineal
cars_ML_G1.ipynb -
Página principal - G
Deep_Learning_CU
komogorov vs shapi
02 perceptron limite
colab.research.google.com/drive/1v2AlFyiaVF9MoEpJqJB2J3ABlawacVTt?authuser=1#scrollTo=0p-0kWhAb4jR
120%
VPN
Next steps:
Generate code with df_cars
New interactive sheet
8]
0s
cols_cat = ["cyl", "vs", "am", "gear", "carb"]
cols_num = ["disp", "hp", "drat", "wt", "qsec"]
X = df_cars[cols_num+cols_cat]
y = df_cars["mpg"]
Estandarizar $z = \frac{x-\mu}{\sigma}$
Codificar
4]
0s
pipeline
Estandarizaion (numéricas), Codification (categóricas
from sklearn.preprocessing import StandardScaler, OneHo



	num__disp	num__hp	num__drat	num__wt	num__qsec	cat__cy
0	0.230529	-0.543655	0.576594	-0.620167	-0.789601	
1	0.230529	-0.543655	0.576594	-0.355382	-0.471202	
2	1.007228	-0.795570	0.481584	-0.931678	0.432823	
3	-0.542764	-0.543655	-0.981576	-0.002336	0.904736	
4	-0.989749	0.419550	-0.848562	0.231297	-0.471202	
5	-0.338342	-0.617748	-1.589643	0.252064	1.348220	


disp
1.0
1.5
2
3
$z = \frac{x - \mu}{\sigma}$
Chebyshev
99%
-5σ, 5σ
0