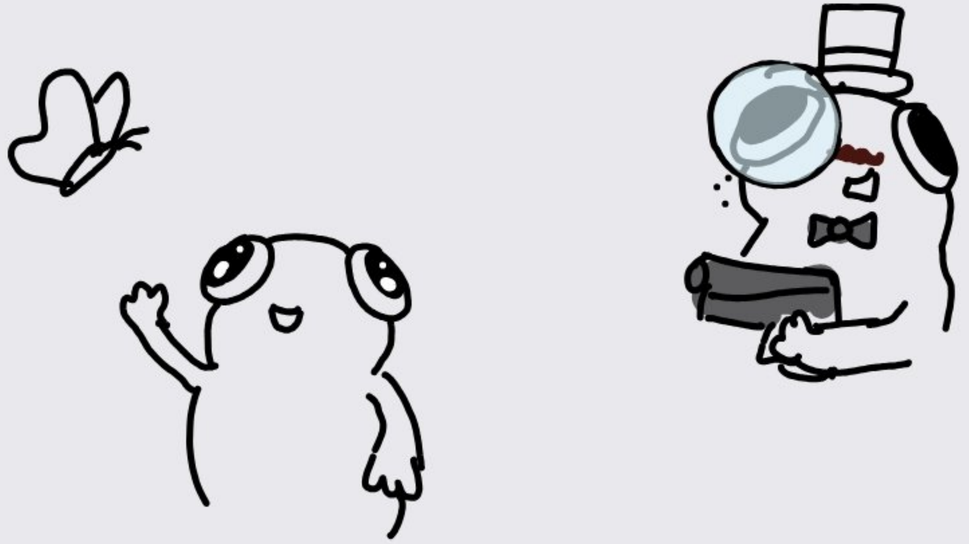
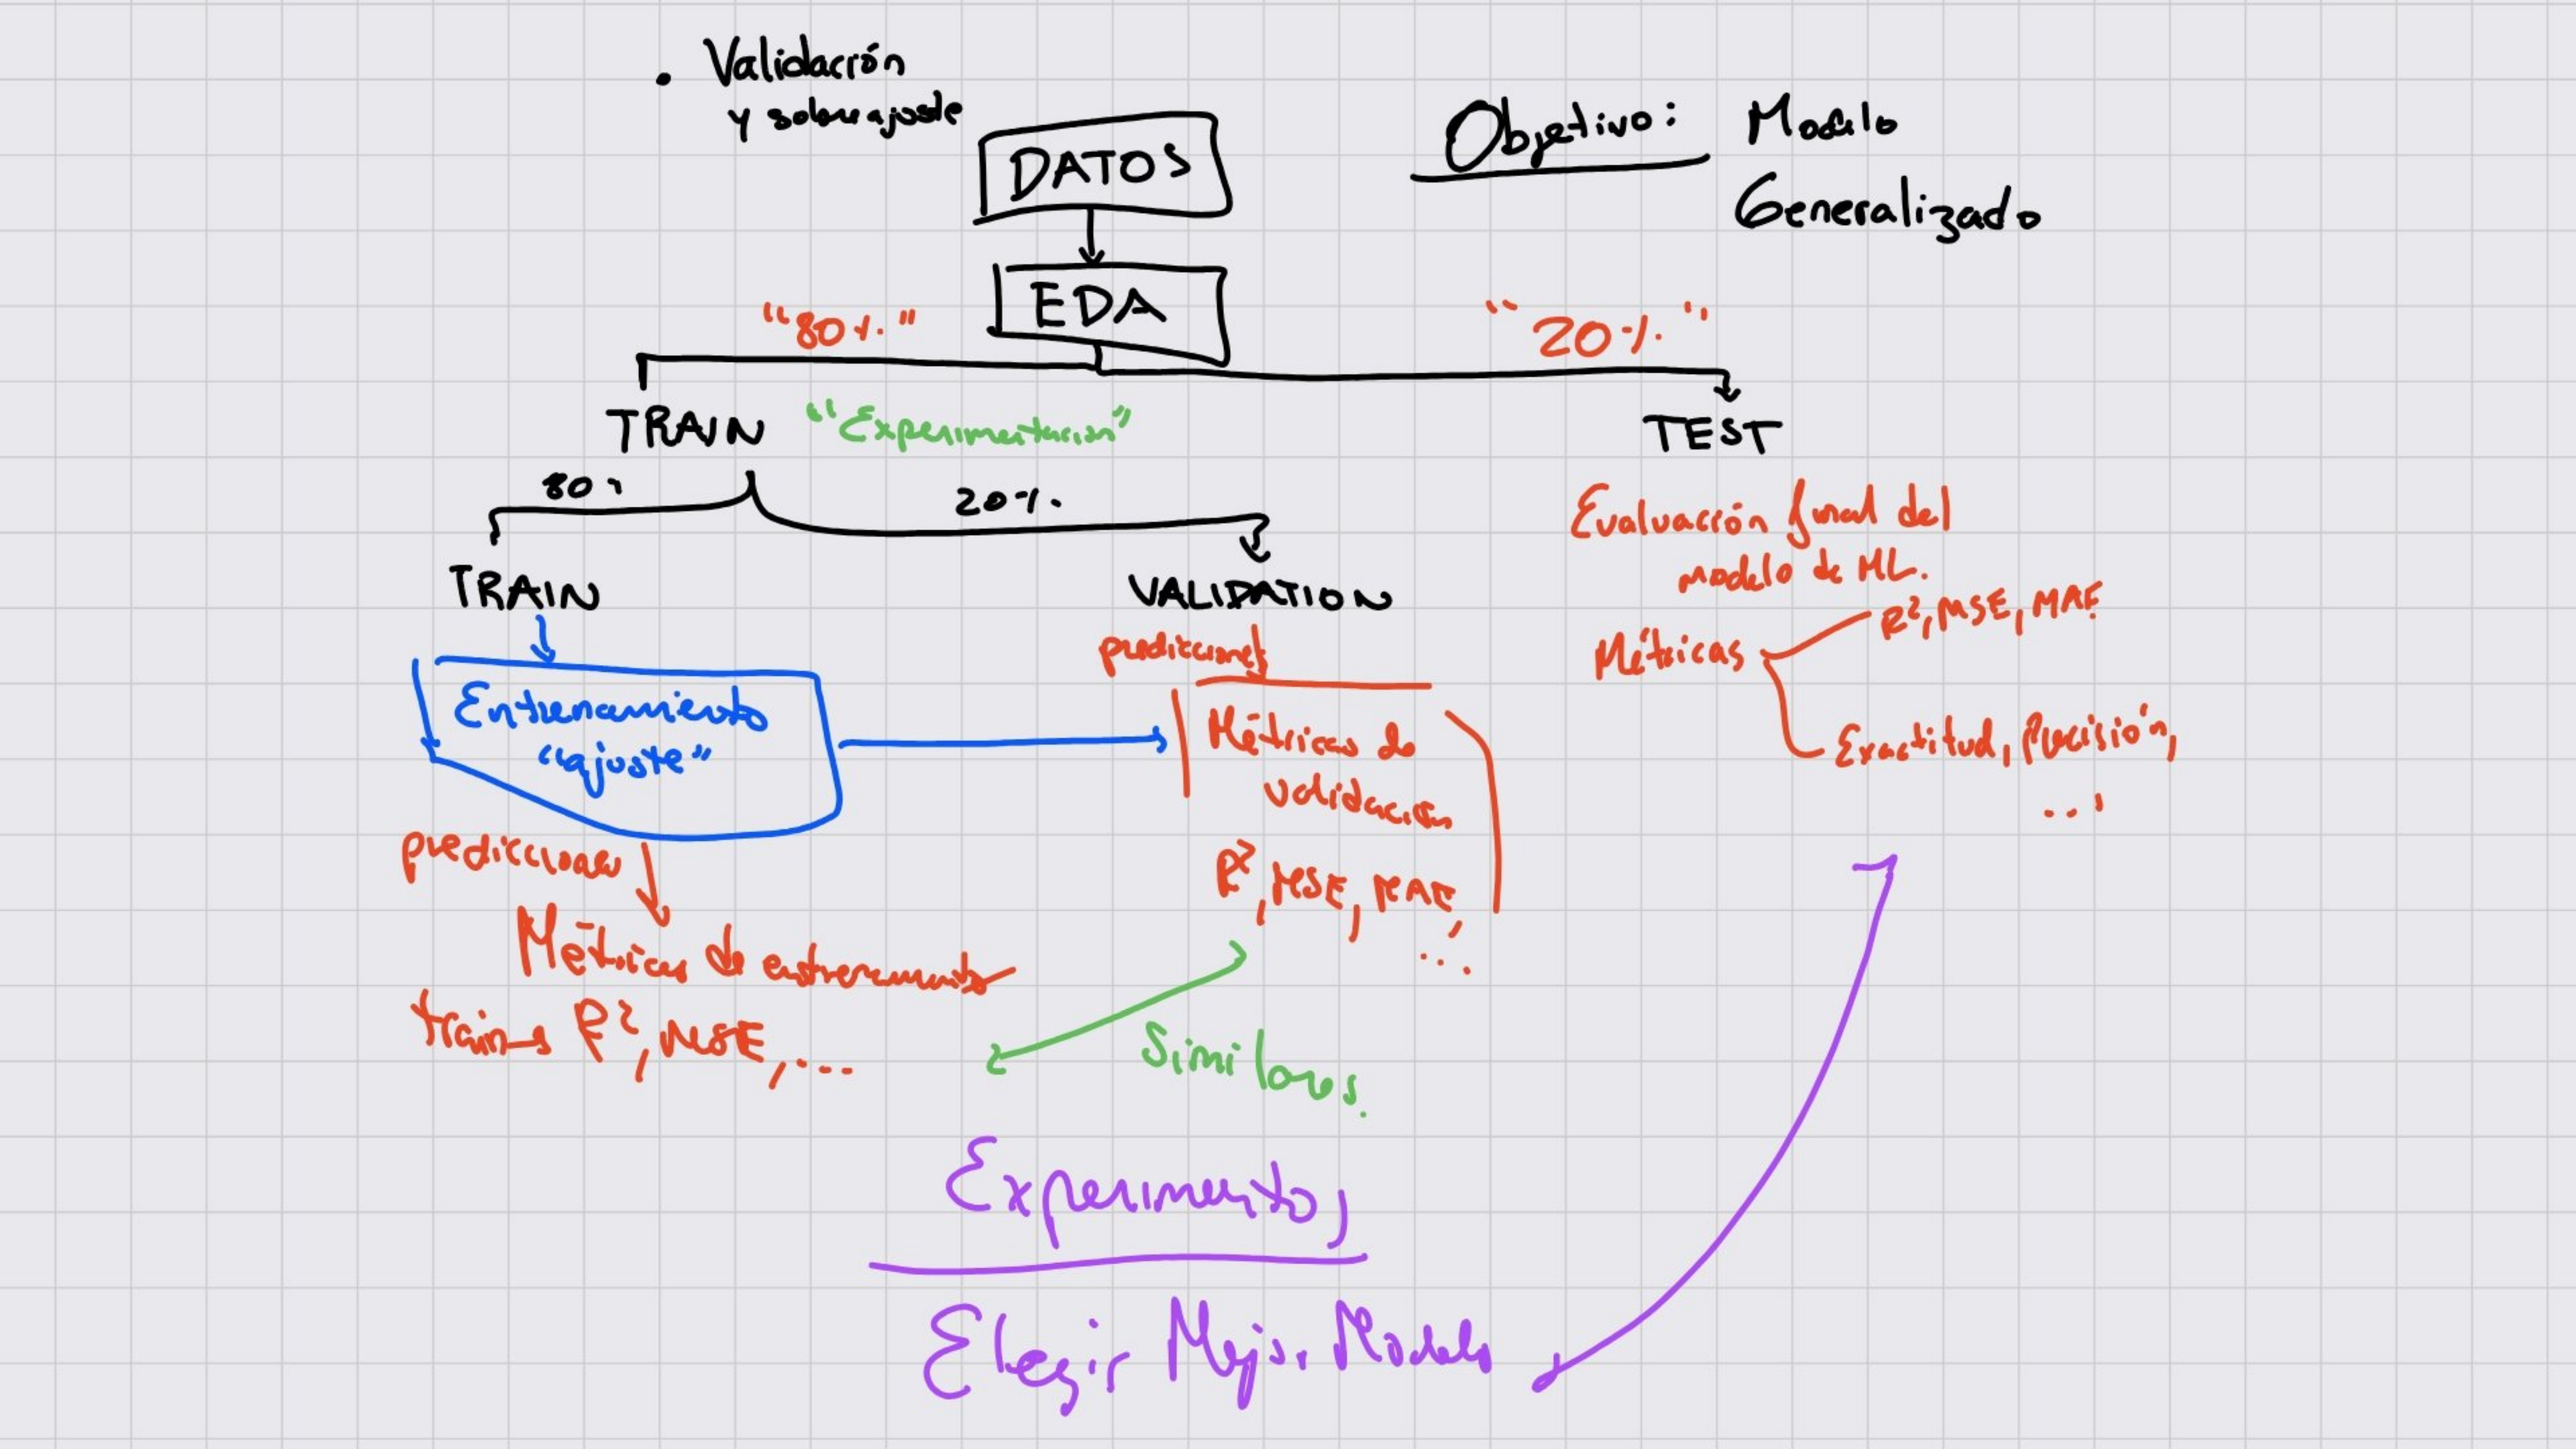


```
Import time
inicio= time .perf_counter()
=========
Fin = time. perf_counter()
tiempo = Fin - inicio
```

. .


• Validación y sobreajuste
Objetivo: Modelo Generalizado
DATOS
EDA
"80%"
"20%"
TRAIN
"Experimentación"
TEST
80%
20%
TRAIN
VALIDATION
Evaluación final del modelo de ML.
Métricas
R², MSE, MAE
Exactitud, Precisión, ...
Entrenamiento "ajuste"
predicciones
Métricas de validación
R², MSE, MAE, ...
predicciones
Métricas de entrenamiento
train R², MSE, ...
Similares
Experimento
Elegir Mejor Modelo

Si las métricas (train vs valid) no son similares

> Sobreajuste

→ Regularización → Parámetros dentro de la función de costo

Penalizar

$$\frac{L}{\frac{1}{n}\sum(\hat{y}_i - y_i)^2}$$

$$\frac{1}{n}\sum|\hat{y}_i - y_i|$$

$$\underline{L2} + \lambda\sum_{j=1}^{m}(\beta_j)^2 \rightarrow \beta \xrightarrow{\text{approx}} 0$$

suave

$$\underline{L1} + \lambda\sum_{j=1}^{m}|\beta_j| \rightarrow \beta = 0$$

violenta

ElasticNet: $pL1 + qL2$

Supernova remnant G46.8–0.3: A ne | H I Self-Absorption and the Kine | No se ha encontrado la clase | IvTole/MachineLearning_Inferen | 05_validacion_y_sobreajuste_ri

colab.research.google.com/github/IvTole/MachineLearning_InferenciaBayesiana_CUGDL/blob/main/05_validacion_y_sobreajuste/05_validacion_y_sobreajuste_ridge_lasso.ipynb

110% | VPN

Modelo base: Regresión Lineal tradicional

Comenzam... y evaluamos su d...

conjunto de...

Este model... continuación.

```
def __init__(*, fit_intercept=True, copy_X=True, n_jobs=None, positive=False)
```

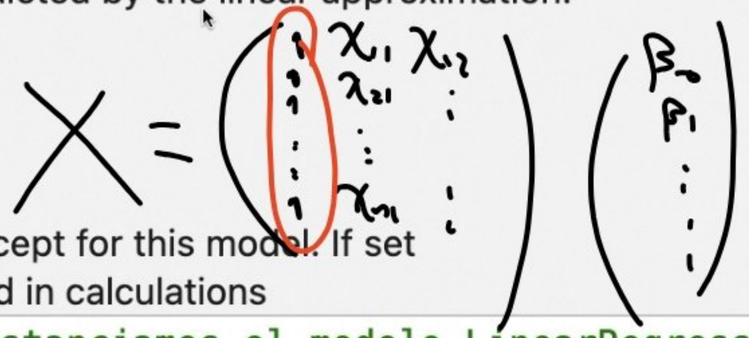
HIPERPARÁMETROS

Open in tab View source

Ordinary least squares Linear Regression.
LinearRegression fits a linear model with coefficients w = (w1, ..., wp)
to minimize the residual sum of squares between the observed targets in
the dataset, and the targets predicted by the linear approximation.

Parameters

fit_intercept : bool, default=True
    Whether to calculate the intercept for this model. If set
to False, no intercept will be used in calculations



```
def m...
    p...
    f...
```

...el.feature_name...

```
lr = LinearRegression() # 1. Instanciamos el modelo LinearRegression
lr.fit(X_train, y_train) # 2. Entrenamiento (con datos de entrenamiento)

y_pred_lr = lr.predict(X_test) # 3. Predicciones (con datos de prueba)
mae_lr = mean_absolute_error(y_test, y_pred_lr) # 4. Evaluación con métricas (con datos de prueba)
mse_lr = mean_squared_error(y_test, y_pred_lr)
r2_lr = r2_score(y_test, y_pred_lr)

model_coef(lr) # función personalizada que muestra los coeficientes beta

print("Métricas Regresión Lineal (tradicional):")
```

Vista Previa Archivo Edición Visualización Ir Herramientas Ventana Ayuda
Lun 28 de sep 9:55 a.m.
05_validacion_y_sobreajuste_slides.pdf
Página 8 de 20
Visualización Inspector Zoom Compartir Resaltado Girar Marcado Rellenar formulario Buscar Buscar

- Se realiza la media de la métrica de
  mse, r2, accuracy, etc.) de c

$$E = \frac{1}{K}\sum_{i=1}^{k} E_i$$

$R_1^2, R_2^2, R_3^2, R_4^2$

0.82 0.81 0.79 0.83

$\bar{R}^2 = 0.81$

$\sigma_{R^2} = 0.01$

R^2 [0.79, 0.82]

Supernova remnant G46.8–0.3: A ne | H I Self-Absorption and the Kine | No se ha encontrado la clase | IvTole/MachineLearning_Inferen | 05_validación_y_sobreajuste_v
colab.research.google.com/github/IvTole/MachineLearning_InferenciaBayesiana_CUGDL/blob/main/05_validacion_y_sobreajuste/05_validación_y_sobreajuste_validacion_cruzad
110% VPN
05_validación_y_sobreajuste_validacion_cruzada.ipynb Save in GitHub to keep changes
Share
File Edit View Insert Runtime Tools Help
Commands + Code + Text Run all Copy to Drive
RAM Disk

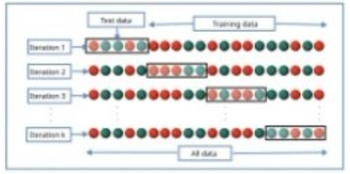
Este tipo de evaluación es más honesta y nos permite saber qué tan bien generaliza nuestro modelo. Sin embargo, aún puede depender de cómo se haya dividido el conjunto. Para abordar esto de forma más robusta, exploraremos a continuación la técnica de **validación cruzada**.

Validación cruzada: evaluación más robusta del modelo

Dividir los datos una sola vez en entrenamiento y prueba puede introducir **variabilidad** en los resultados, especialmente si el conjunto de datos es pequeño o heterogéneo. Una forma más confiable de estimar el rendimiento de un modelo es mediante la **validación cruzada**.

¿Qué es la validación cruzada?

La idea central es repetir el proceso de entrenamiento y evaluación varias veces, con diferentes particiones de los datos, y luego promediar los resultados.



El enfoque más común es la **validación cruzada k-fold**, que funciona así:

1. Se divide el conjunto de datos en `k` partes (o *folds*) del mismo tamaño.
2. En cada iteración, se entrena el modelo con `k-1` partes y se evalúa en la parte restante.
3. Se repite este proceso `k` veces, rotando el fold de evaluación.
4. Finalmente, se calcula el **promedio y la desviación estándar** de las métricas obtenidas.

Este método reduce el sesgo de la división aleatoria y nos da una mejor idea del comportamiento general del modelo.

A continuación aplicaremos validación cruzada al modelo de regresión lineal que venimos utilizando.

[33] ✓ 0s

```
# Validación cruzada con k=10
cv_scores = cross_val_score(model, X, y, cv=10, scoring='r2') # la validación se tiene que basar en un score, en este caso r2, pero puede ser otro
```

Variables Terminal
10:13 AM Python 3

- Regresión Logística

> Clasificación

y

$\{0, 1\}$ Binaria

$\{1, 2, 3, \ldots\}$ Multiclase

- Regresión Log. a partir de Regresión Lin.

Paso 1

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_m x_m$$

$\in [-\infty, \infty]$

$$= \beta \cdot x \quad [-\infty, \infty]$$

$$\hat{y} = \beta \cdot x$$

$\{0,1\}$ $\quad [-\infty, \infty)$

Paso 2

$$P_i = \beta \cdot X$$

$(0,1)$ $[-\infty, \infty]$ ✗

Paso 3

$$\frac{P_i}{1-P_i} = \beta \cdot X$$

$[0, \infty]$ $[-\infty, \infty]$ ✗

$$\frac{P_{éxito}}{P_{fracaso}}$$

- Cociente de Probabilidades, ODDS

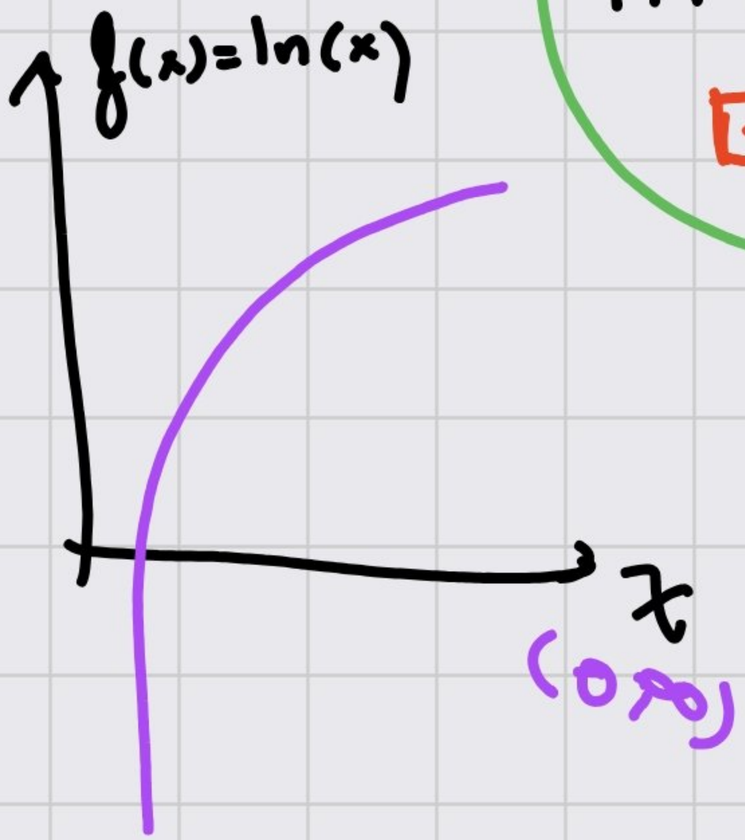
Paso 4

$$\ln\left(\frac{p_i}{1-p_i}\right) = \beta \cdot x$$

$[-\infty, \infty]$ $[\infty, \infty]$

log-odds

Una regresión lineal sobre log-odds



Modelo

Reg. Linear → $y = \beta \cdot x$

Reg. Log. → $\ln\left(\frac{p}{1-p}\right) = \beta \cdot x$

$$\ln\left(\frac{p}{1-p}\right) = \beta \cdot x \Rightarrow \frac{p}{1-p} = e^{\beta \cdot x} \Rightarrow p = (1-p)e^{\beta x} = e^{\beta \cdot x} - pe^{\beta \cdot x}$$

$$\Rightarrow p + pe^{\beta \cdot x} = e^{\beta \cdot x} \Rightarrow p(1 + e^{\beta \cdot x}) = e^{\beta x}$$

$$\Rightarrow p = \frac{e^{\beta \cdot x}}{1 + e^{\beta \cdot x}} \left(\frac{e^{-\beta \cdot x}}{e^{-\beta \cdot x}} \right) = \frac{1}{1 + e^{-\beta \cdot x}} = p$$

$\frac{e^{-\beta \cdot x}}{e^{-\beta \cdot x}} = 1$

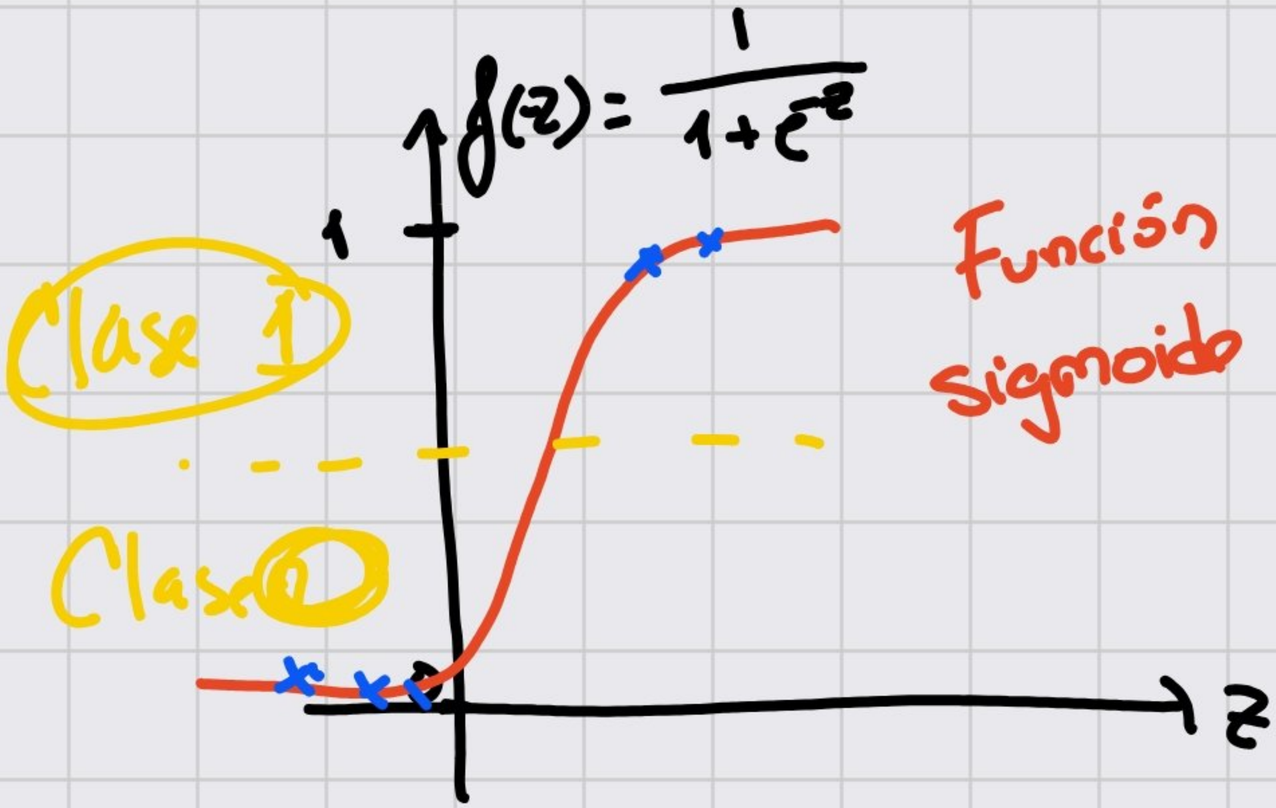
Modelo de Reg. Log.

$$\ln\left(\frac{P}{1-P}\right) = \beta \cdot x$$

ó

$$P = \frac{1}{1 + e^{\beta \cdot x}}$$

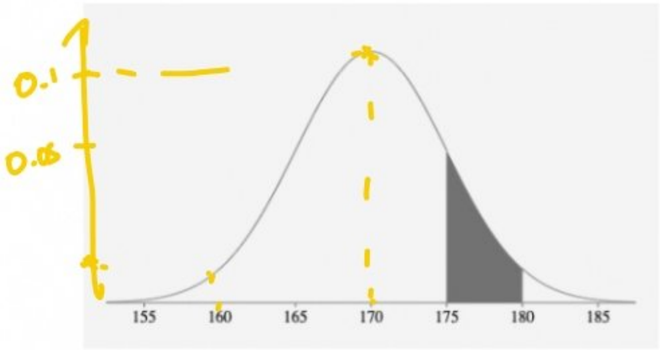
Verosimilitud.



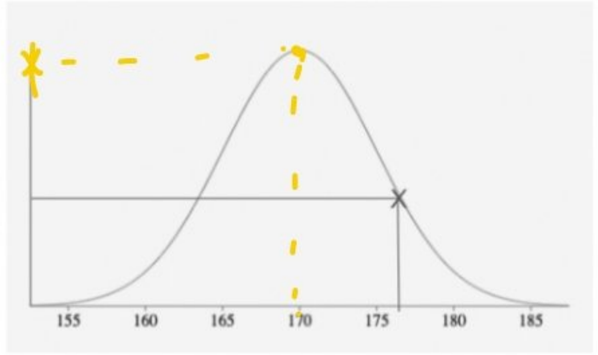
Probabilidad vs Verosimilitud

VEROSIMILITUD

Probability



Likelihood



- **Probabilidad**
- Los parámetros se suponen fijos.
- Los resultados son variables.
- Se considera el espacio de todos los posibles resultados (espacio muestral).
- La suma/integral de la probabilidad sobre todos los resultados posibles es 1.

- **Likelihood / Verosimilitud**
- Se permite que los parámetros que la generan varíen.
- Los resultados son fijos.
- Se considera el espacio de todos los posibles parámetros.
- La suma/integral sobre todos los posibles valores de los parámetros no es igual a 1.