- Regresión logística (Clasificación)

↳ y target → {0, 1} Binario

→ {1, 2, 3, ...} Multiclase

Modelo

$$\ln\left(\frac{P}{1-P}\right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_m X_m = X\beta$$

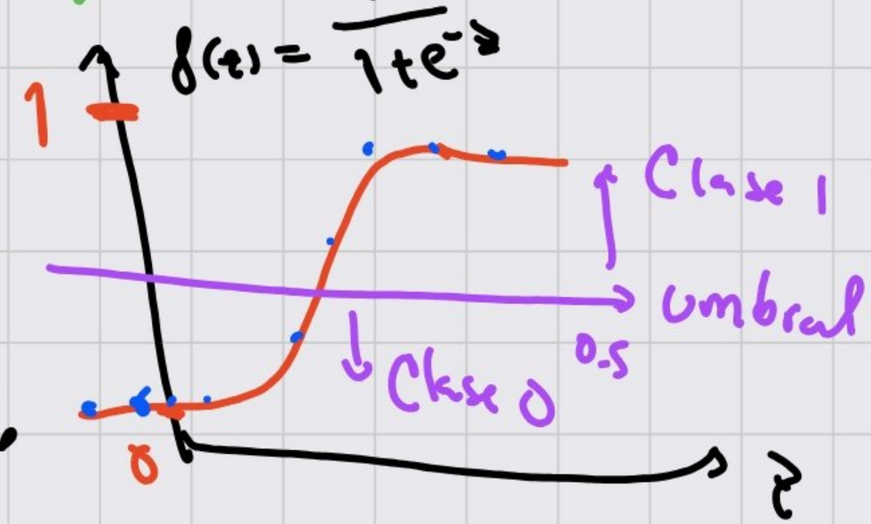
log-odds

parámetros de ajuste

$$P = \frac{1}{1 + e^{-X\beta}}$$

Función sigmoide

$$f(z) = \frac{1}{1+e^{-z}}$$



Función de Costo / Error

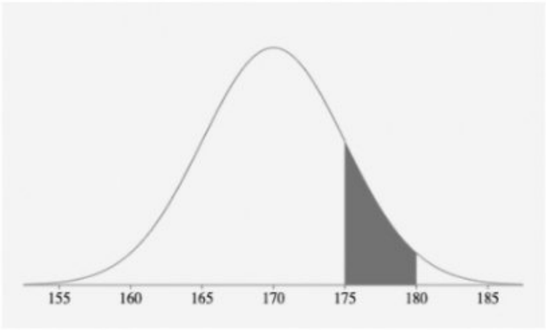
?

Vista Previa Archivo Edición Visualización Ir Herramientas Ventana Ayuda
Mié 30 de sep 9:31 a.m.
06_regresion_logistica_slides.pdf
Página 12 de 32
Visualización Inspector Zoom Compartir Resaltado Girar Marcado Rellenar formulario Buscar

Probabilidad vs Verosimilitud

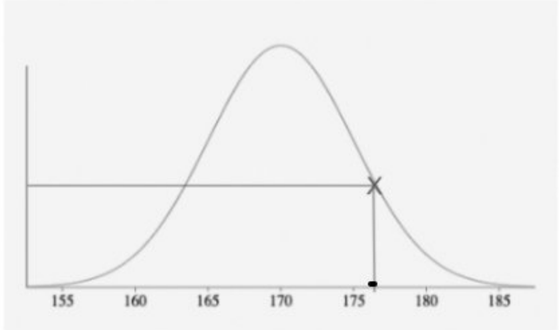
Probability

$P(x|\hat{\theta})$



- **Probabilidad**
- Los parámetros se suponen fijos.
- Los resultados son variables.
- Se considera el espacio de todos los posibles resultados (espacio muestral).
- La suma/integral de la probabilidad sobre todos los resultados posibles es 1.

Likelihood



$P(\hat{\theta}|x)$

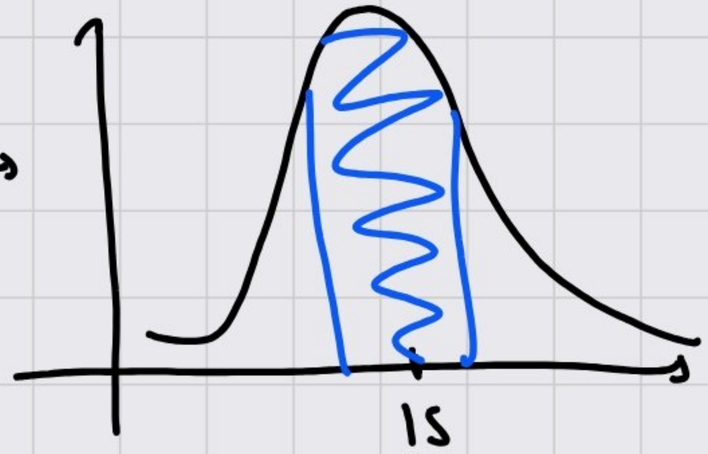
- **Likelihood / Verosimilitud**
- Se permite que los parámetros que la generan varíen.
- Los resultados son fijos.
- Se considera el espacio de todos los posibles parámetros.
- La suma/integral sobre todos los posibles valores de los parámetros no es igual a 1.

Macintosh HD › Usuarios › vanotole › Documentos › Doctorado › MachineLearning_ › Github › MachineLearning_ › 07_arboles_ensamble › 07_arboles_ensamble_slides.pdf

- Probabilidad $P(x|\vec{\theta})$ — $\vec{\theta}$: fijos

Una probabilidad (densidad/masa) $P(X|\theta)$ determina la frecuencia en la cual una variable aleatoria X toma un valor, dado algún parámetro $\vec{\theta}$.

- Normal μ, σ
- Exp. λ
- Poisson λ
- Binomial p, n
- Geométrica p



$$P(13 < x < 16)$$

$$P(13 < x < 16 \mid \underbrace{\mu = 15, \sigma = 2}_{N(\mu,\sigma)})$$

. Verosimilitud $P(\hat{\theta}|\underline{X})$ fijos

Determina la probabilidad de que un parámetro $\hat{\theta}$ haya sido el que generó una muestra X.

$$P(\vec{\theta}|x) = \frac{1}{1+e^{-x\beta}}$$

Datos fijos

Params variables

Ejemplo: Supongamos que tengo 6 características independientes $X_1, X_2, X_3, \ldots, X_6$ que siguen una dist. de Bernoulli: $B(p)$.

Calcula la prob. para $X_1 = X_2 = X_3 = 1$, $X_4 = X_5 = X_6 = 0$

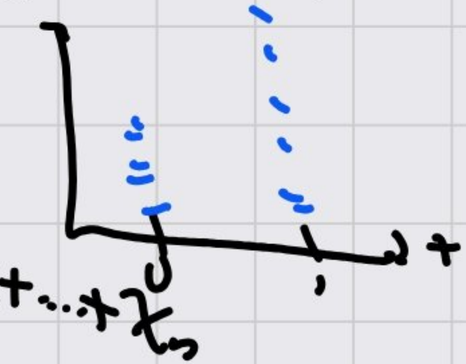
Distribución de Bernoulli

$P(X=1) = p$

$P(X=0) = 1-p$

$$P(X_1=X_2=X_3=1, X_4=X_5=X_6=0 \mid p) = P(X_1=1|p) \cdot P(X_2=1|p) \cdots P(X_6=0|p)$$

$$= \prod_{i=1}^{3} P(X_i=1|p) \prod_{i=4}^{6} P(X_i=0|p)$$



$$\sum_{i=1}^{n} X_i = X_1 + X_2 + \ldots + X_n$$

$$\prod_{i=1}^{n} = X_1 \cdot X_2 \cdot X_3 \cdots X_n$$

$$= p^3 (1-p)^3$$

$$P(X_1 \cap X_2 \cap \dots \cap X_n) \overset{\text{ind.}}{=} P(X_1) \cdot P(X_2) \cdots P(X_n)$$

Función de Costo

DATOS → Gender

X_1 weight	X_2 height	X_3 vel.	y
90	190	5 min/km	1 ← Hugo.
50	160	8	0
67	170	15	0

$$P(\theta|x) = \frac{1}{1+e^{-x\cdot\beta}} \qquad 1 - \frac{1}{1+e^{-x\beta}}$$

$$P(\theta|x) = P(\theta|y_1=1, y_2=0, y_3=0) = P(\theta|y_1=1)\,P(\theta|y_2=0)\cdot P(\theta|y_3=0)$$

$$= P_1 \cdot (1-P_2)\cdot(1-P_3)$$

Verosimilitud.

Objetivo: $\text{Max } P(\hat{\theta}|y)$

Función de Verosimilitud.

$$L = \prod_{i=1}^{n} P_i^{y_i} \cdot (1-P_i)^{1-y_i}$$

$y_i = \{0, 1\}$

$$P = \frac{1}{1+e^{-\beta x}}$$

$$\ln(L) = \ell = \sum_{i=1}^{n} y_i \ln(P_i) + (1-y_i)\ln(1-P_i)$$

$1-P_i \to 0$

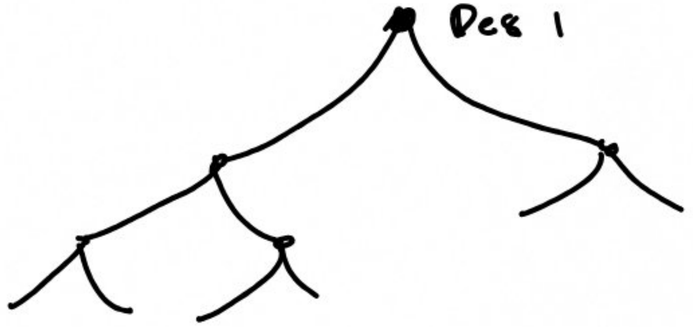
$P \to 1$

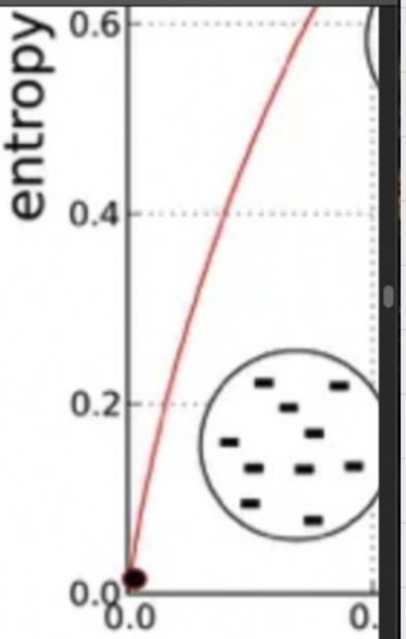
$\log(ab) = \log(a) + \log(b)$

$\log(x^a) = a\log(x)$

Función de Costo → Entropía cruzada binaria.

$$\frac{d\left(f(x)g(x)\right)}{dx} = \frac{df(x)}{dx}g(x) + f(x)\frac{dg(x)}{dx}$$





- $$H(S) = \sum_{i=1}^{n} - p_i \log_2(p_i)$$

- Donde n son las categorías para una

Funciones de Costo

Regresión

$$\frac{1}{n}\sum(\hat{y}_i - y_i) \quad \text{MBE}$$

$$\frac{1}{n}\sum(\hat{y}_i - y_i)^2 \quad \text{MSE}$$

$$\frac{1}{n}\sum|y_i - y_i| \quad \text{MAE}$$

$$\sqrt{\frac{1}{n}\sum(\hat{y}_i - y_i)^2} \quad \text{RMSE}$$

Clasificación

$$\sum y_i \ln(p_i) + (1-y_i)\ln(1-p_i) \quad \text{BCE}$$

Clasificación Binaria

Modelo

$$P = \frac{1}{1+e^{X\beta}}$$

Error

$$l = \sum y_i \ln(P_i) + (1-y_i)\ln(1-P_i)$$

Método de máxima verosimilitud.

→ Optimización $\operatorname{argmax}(l)$

$$\frac{\partial l}{\partial \beta} = 0$$

$$\frac{\partial l}{\partial \alpha} = \sum_{i=1}^{m} - \frac{e^{\alpha+\beta x_i}}{1+e^{\alpha+\beta x_i}} \cdot 1 + y_i \cdot 1 = \sum_{i=1}^{m} (-P_i + y_i)\, x_{ij}$$

$x_{ij} = 1$

$$X = \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} \quad x_{ij}$$

no β

$$\frac{\partial l}{\partial \beta} = \sum_{i=1}^{m} - \frac{e^{\alpha+\beta x_i}}{1+e^{\alpha+\beta x_i}} \cdot x_{ij} + y_i x_{ij} = \sum_{i=1}^{m} x_{ij}(y_i - P_i)$$

Vista Previa Archivo Edición Visualización Ir Herramientas Ventana Ayuda
Mié 30 de sep 10:25 a.m.
06_regresion_logistica_slides.pdf
Página 19 de 32
Visualización Inspector Zoom Compartir Resaltado Girar Marcado Rellenar formulario Buscar

- Si definimos $p_0 = a$ y que todos lo

- Tenemos la expresión general

$$\sum x_i u_i = x_1 u_1 + x_2 u_2 + \dots + x_m u_m$$

$$\bar{X} \cdot \bar{u}$$

- $$\frac{\partial l}{\partial \beta_j} = \sum_{i=1}^{m} x_{ij} \left(y_i - P_i \right)$$

u_i

- Esto da una idea de como simplific

Macintosh HD › Usuarios › vanotole › Documentos › Doctorado › MachineLearning_ › Github › MachineLearning_ › 07_arboles_ensamble › 07_arboles_ensamble_slides.pdf

Vista Previa Archivo Edición Visualización Ir Herramientas Ventana Ayuda
Mié 30 de sep 10:28 a.m.
06_regresion_logistica_slides.pdf
Página 19 de 32
Visualización Inspector Zoom Compartir Resaltado Girar Marcado Rellenar formulario Buscar

- $\frac{\partial}{\partial \beta_j} \sum_{i=1}$ ... (cut off)

- Esto da una idea de como simplific

- $$\frac{\partial l}{\partial \beta_j} = \bar{x}_j \cdot (y_i - \bar{P}_i)$$

- Incluso puedo hacer todas las deriv

Macintosh HD › Usuarios › vanotole › Documentos › Doctorado › MachineLearning_ › Github › MachineLearning_ › 07_arboles_ensamble › 07_arboles_ensamble_slides.pdf

Vista Previa Archivo Edición Visualización Ir Herramientas Ventana Ayuda
Mié 30 de sep 10:30 a.m.
06_regresion_logistica_slides.pdf
Página 19 de 32
Visualización Inspector Zoom Compartir Resaltado Girar Marcado Rellenar formulario Buscar Buscar

- $\partial \beta_j$

- Incluso puedo hacer todas las deriv

- $$\frac{\partial l}{\partial \beta} = X \cdot (Y_i - P_i)$$

Macintosh HD › Usuarios › vanotole › Documentos › Doctorado › MachineLearning › Github › MachineLearning › 07_arboles_ensamble › 07_arboles_ensamble_slides.pdf

$$\frac{\partial \ell}{\partial \beta} = X(y-p) = 0$$

$f(x)$

$f'(x)$

$$X = \begin{pmatrix} 1 & x_{11} & x_{12} & \dots & x_{1m} \\ 1 & x_{21} & x_{22} & \dots & \vdots \\ \vdots & \vdots & \ddots & & \vdots \\ 1 & & & & x_{nm} \end{pmatrix} \quad \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \quad \begin{pmatrix} p_1 \\ p_2 \\ \vdots \\ p_n \end{pmatrix}$$

$$\beta_{k+1} = \beta_k - \left(X(y-p)\right) \cdot \left(XWX^T\right)^{-1}$$

¡ No tienes solución analítica

$$\frac{\partial^2 \ell}{\partial \beta^2} = XWX^T$$

⟶ aproximar

$$W = \begin{pmatrix} p_1(1-p_1) & 0 & 0 & \dots \\ 0 & p_2(1-p_2) & \dots & \\ 0 & 0 & p_3(1-p_3) & \\ \vdots & & & \ddots \end{pmatrix}$$

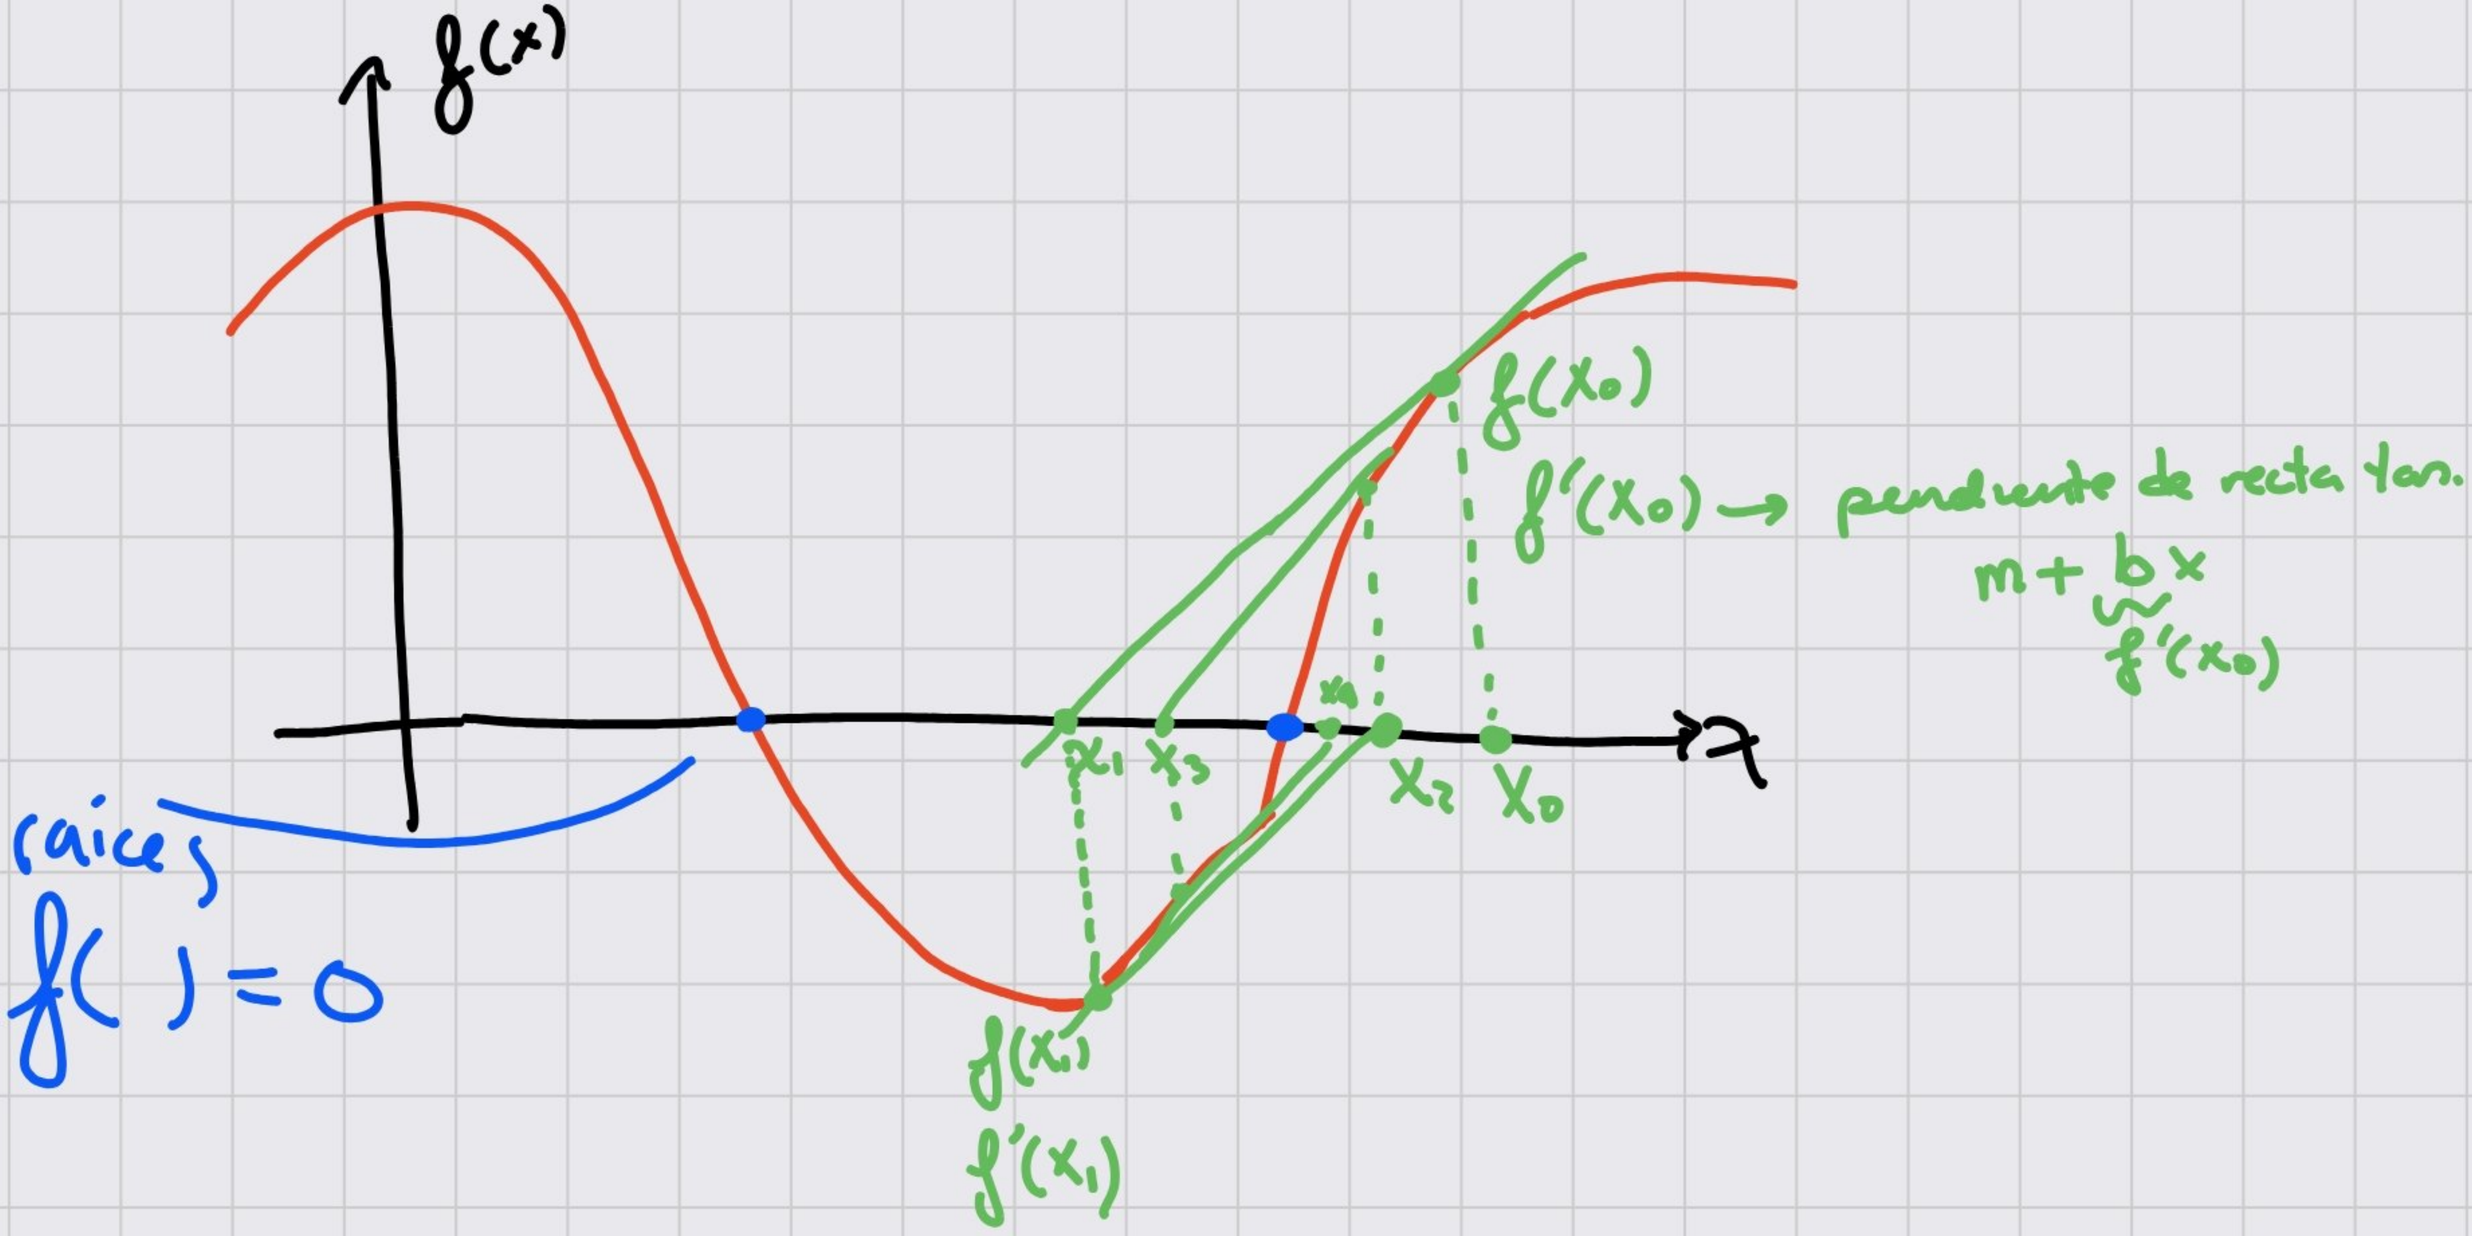
$$W = p_i(1-p_i)$$

Métodos Optimización

- Descenso del gradiente
  minimizar una función
- Newton-Raphson
  encontrar raíces.

$$\beta_{K+1} = \beta_K - \alpha \cdot \nabla \ell$$

$$x_{K+1} = x_K - \frac{f(x_K)}{f'(x_K)}$$


f(x)
x
raices
f( ) = 0
x1
x3
x4
x2
x0
f(x0)
f'(x0) → pendiente de recta tan.
m + b x
f'(x0)
f(x1)
f'(x1)

$$\frac{\partial^2 l}{\partial \beta_j^2} = \sum_{i=1}^{m} x_{ij} P_i (1 - P_i) x_{ij}$$

$$\frac{\partial^2 l}{\partial \beta^2} = \sum_{i=1}^{m} x_i \cdot P_i (1 - P_i) x_i^t = X \cdot W \cdot X^t$$